

Feature redundancy reduction per CT in vivo, CT ex vivo, Micro-CT e geni

Notebook: feature_selection_CT.ipynb

1. Sintesi del lavoro svolto

Il notebook ha come obiettivo la riduzione della ridondanza tra variabili, cioè l'identificazione di gruppi di feature altamente correlate e la selezione di una sola variabile rappresentativa per ciascun gruppo. Questa operazione è stata applicata a tre insiemi di feature radiomiche e a un insieme di dati genetici. Nel caso radiomico sono state escluse preventivamente le feature di forma, riconoscibili dal prefisso `original_shape_`, per concentrarsi sulle feature di intensità e texture.

La riduzione è stata basata sulla correlazione di Spearman. Per ogni coppia di variabili con correlazione assoluta superiore a 0,9, si è eliminata la variabile con varianza minore e mantenuto come rappresentante quella con varianza maggiore. Il risultato finale è una matrice con meno colonne, quindi più compatta e meno ridondante, ma ancora informativa.

Dataset	Variabili iniziali	Variabili valutate	Variabili finali	Variabili eliminate	Quota mantenuta	Coppie ridondanti riportate
CT in vivo	93	93	34	59	36.6%	265 coppie
CT ex vivo	93	93	46	47	49.5%	278 coppie
Micro-CT	93	93	28	65	30.1%	391 coppie
Geni	750	750	746	4	99.5%	mapping genetico mostrato in output

Nota: il numero di coppie ridondanti si riferisce al mapping prodotto dal ciclo sulle coppie di variabili. Una stessa feature può comparire in più coppie, quindi il numero di righe del mapping può essere superiore al numero di variabili eliminate in modo univoco.

2. Struttura del notebook

Cella	Tipo	Contenuto principale	Output prodotto
0	Markdown	Definizione dell'obiettivo: Feature redundancy reduction e studio delle correlazioni tra feature radiomiche.	Nessun output.
1	Codice	Import di pandas, numpy, StandardScaler, seaborn, matplotlib e montaggio di Google Drive.	Drive montato correttamente.
2	Markdown	Intestazione della sezione CT in vivo.	Nessun output.
3	Codice	Caricamento CT in vivo, rimozione shape, conversione numerica, z-score, Spearman, heatmap, soglia 0,9 e selezione feature.	Heatmap, mapping di ridondanza, 34 feature finali.
4	Markdown	Intestazione della sezione CT ex vivo.	Nessun output.
5	Codice	Caricamento CT ex vivo da Drive, rimozione shape, rimozione colonne costanti/NaN, Spearman, heatmap e selezione feature.	Heatmap, mapping di ridondanza, 46 feature finali.
6	Markdown	Intestazione della sezione Micro-CT.	Nessun output.
7	Codice	Caricamento Micro-CT, rimozione shape, controllo colonne costanti/NaN, Spearman, heatmap e selezione feature.	Heatmap, mapping di ridondanza, 28 feature finali.
8	Markdown	Intestazione della sezione FRR per i geni.	Nessun output.
9	Codice	Caricamento matrice geni-pazienti, trasposizione, correlazione Spearman tra geni, heatmap e riduzione ridondanza.	Heatmap, mapping genetico, 746 geni finali.

3. Metodologia usata nel notebook

Le analisi seguono una logica comune. In primo luogo viene caricato il dataset e viene impostata come indice la colonna identificativa del campione o del paziente. Successivamente vengono rimosse le colonne di shape nelle matrici radiomiche.

La matrice di correlazione è calcolata con il metodo di Spearman. Questa scelta è appropriata quando interessa la relazione monotona tra due variabili: non usa direttamente i valori assoluti, ma il loro ordinamento.

La soglia scelta è $|\rho| > 0,9$. In pratica, ogni coppia con correlazione maggiore di 0,9 o minore di -0,9 viene considerata ridondante. Il codice conserva la variabile con varianza maggiore e aggiunge l'altra all'insieme `to_drop`. Alla fine, le colonne in `to_drop` vengono rimosse dal dataset, ottenendo `df_reduced`.

Parametro	Valore/criterio	Significato
Metodo di correlazione	Spearman	Valuta associazioni monotone e si basa sui ranghi.
Soglia	$ \rho > 0,9$	Identifica coppie molto correlate, sia positivamente sia negativamente.
Criterio di selezione	Mantiene la variabile con varianza maggiore	La variabile più variabile viene scelta come rappresentante della coppia.
Output principale	<code>df_reduced</code>	Dataset ridotto alle variabili non eliminate.
Output interpretativo	<code>mapping_df</code>	Tabella con variabile rimossa, rappresentante e valore di ρ .

4. Analisi CT in vivo

La sezione CT in vivo carica le feature radiomiche da un foglio Google esportato in formato CSV. Dopo aver impostato come indice la prima colonna, il codice rimuove tutte le feature di shape. Il notebook stampa che, dopo questa rimozione, restano 93 feature radiomiche da analizzare. I valori vengono convertiti da stringhe a numeri, sostituendo le virgole con punti per gestire il separatore decimale.

In questa sezione viene applicata la standardizzazione z-score tramite `StandardScaler`. La matrice standardizzata viene poi usata per calcolare la correlazione di Spearman. La heatmap prodotta mostra l'intera matrice 93 x 93: la diagonale rossa corrisponde all'autocorrelazione perfetta di ogni feature con sé stessa, mentre i blocchi rossi o blu fuori diagonale indicano gruppi di feature fortemente correlate o anticorrelate.




Figura 1. Matrice di correlazione Spearman delle feature radiomiche CT in vivo.

Nella heatmap CT in vivo si osservano diverse aree compatte di correlazioni elevate. Questo comportamento è tipico delle feature radiomiche: misure diverse possono descrivere aspetti simili della distribuzione di intensità o della texture. La presenza di bande e blocchi rossi/blu indica che molte variabili non sono indipendenti tra loro. Il blocco di Feature Redundancy Reduction serve proprio a ridurre questo effetto, evitando di portare in analisi successive un numero eccessivo di variabili quasi duplicate.

Il risultato numerico della riduzione è: 93 feature iniziali e 34 feature finali. Sono quindi state eliminate 59 feature, pari a circa il 63,4% delle feature valutate. Il mapping stampato contiene 265 coppie ridondanti, perché una stessa feature può essere coinvolta in più correlazioni sopra soglia.

Indicatore	Valore	
Feature dopo rimozione shape	93	
Feature iniziali nella riduzione	93	
Feature finali selezionate	34	
Feature eliminate	59	
Percentuale mantenuta	36,6%	
Coppie nel mapping di ridondanza	265	
Feature rimossa	Feature rappresentativa	Spearman rho
original_firstorder_InterquartileRange	original_firstorder_10Percentile	-0.944385
original_firstorder_Entropy	original_firstorder_Kurtosis	-0.921622
original_firstorder_MeanAbsoluteDeviation	original_firstorder_10Percentile	-0.984866
original_firstorder_MeanAbsoluteDeviation	original_firstorder_InterquartileRange	0.941186
original_firstorder_Mean	original_firstorder_10Percentile	0.963518

Esempio tratto dalle prime righe del mapping CT in vivo. Le correlazioni negative indicano anticorrelazioni forti; anche queste vengono considerate ridondanti perché il criterio usa il valore assoluto di rho.

5. Analisi CT ex vivo

La sezione CT ex vivo carica il file out_CTconv_FIXED.csv da Google Drive e usa la colonna Patient come indice. Anche in questo caso vengono eliminate le colonne con prefisso original_shape_. Il notebook stampa 93 feature residue dopo la rimozione shape. Successivamente converte le colonne in formato numerico e rimuove eventuali colonne costanti. In questo dataset il controllo non riduce ulteriormente le colonne: restano 93 feature.

La matrice di correlazione viene calcolata direttamente sul dataframe numerico.




Figura 2. Matrice di correlazione Spearman delle feature radiomiche CT ex vivo.

La heatmap CT ex vivo mostra ancora una forte struttura a blocchi, ma con un pattern non identico a quello CT in vivo. Questo indica che, pur partendo da un insieme di feature con la stessa numerosità, la ridondanza interna cambia a seconda della modalità o del dataset. Alcuni gruppi di feature appaiono fortemente correlati positivamente, mentre altre aree blu segnalano anticorrelazioni marcate. Questi pattern giustificano la riduzione della dimensionalità prima di eventuali analisi predittive o correlazioni radiogenomiche successive.

Il risultato finale del blocco CT ex vivo è una riduzione da 93 a 46 feature. Sono state quindi eliminate 47 feature, pari a circa il 50,5% delle variabili valutate. Rispetto al CT in vivo, il dataset ex vivo mantiene una quota più alta di feature, suggerendo una ridondanza complessivamente meno drastica secondo il criterio adottato.

Indicatore	Valore	
Feature dopo rimozione shape	93	
Feature dopo rimozione colonne costanti o NaN	93	
Feature iniziali nella riduzione	93	
Feature finali selezionate	46	
Feature eliminate	47	
Percentuale mantenuta	49,5%	
Coppie nel mapping di ridondanza	278	
Feature rimossa	Feature rappresentativa	Spearman rho
original_firstorder_MeanAbsoluteDeviation	original_firstorder_InterquartileRange	0.961573
original_firstorder_Median	original_firstorder_Mean	0.946959
original_firstorder_RobustMeanAbsoluteDeviation	original_firstorder_InterquartileRange	0.994355
original_firstorder_RobustMeanAbsoluteDeviation	original_firstorder_MeanAbsoluteDeviation	0.976859
original_firstorder_TotalEnergy	original_firstorder_Energy	1.000000

Esempio tratto dalle prime righe del mapping CT ex vivo. La correlazione pari a 1,000000 tra TotalEnergy ed Energy mostra un caso di ridondanza praticamente perfetta.

6. Analisi Micro-CT

La sezione Micro-CT carica il file radiomics_microCT.csv da Google Drive e imposta la colonna ID come indice. Come negli altri blocchi radiomici, vengono rimosse tutte le feature di forma. Il notebook stampa 93 feature dopo questa rimozione e, dopo la conversione numerica e il controllo delle colonne costanti, rimangono ancora 93 feature.

La heatmap della correlazione mostra un pattern di ridondanza particolarmente evidente, con numerosi blocchi intensi sia positivi sia negativi.




Figura 3. Matrice di correlazione Spearman delle feature radiomiche Micro-CT.

Nel caso Micro-CT la matrice risulta visivamente molto strutturata. Le bande verticali e orizzontali intense indicano feature correlate con molti altri descrittori. Questo si riflette anche nel risultato numerico: il mapping riporta 391 coppie ridondanti e il numero finale di feature selezionate è il più basso tra i tre dataset radiomici.

Il dataset Micro-CT passa da 93 a 28 feature finali. Sono quindi eliminate 65 feature, pari a circa il 69,9% delle variabili valutate. Questo risultato segnala che, secondo la soglia $|\rho| > 0,9$, molte feature Micro-CT portavano informazioni molto sovrapponibili.

Indicatore	Valore	
Feature dopo rimozione shape	93	
Feature dopo rimozione colonne costanti o NaN	93	
Feature iniziali nella riduzione	93	
Feature finali selezionate	28	
Feature eliminate	65	
Percentuale mantenuta	30,1%	
Coppie nel mapping di ridondanza	391	
Feature rimossa	Feature rappresentativa	Spearman rho
original_firstorder_MeanAbsoluteDeviation	original_firstorder_InterquartileRange	0.919644
original_firstorder_10Percentile	original_firstorder_Mean	0.963043
original_firstorder_Mean	original_firstorder_90Percentile	0.972326
original_firstorder_10Percentile	original_firstorder_Median	0.955652
original_firstorder_Median	original_firstorder_90Percentile	0.979605

Esempio tratto dalle prime righe del mapping Micro-CT. Le prime coppie coinvolgono soprattutto feature first-order, che nel dataset risultano fortemente correlate tra loro.

7. Feature redundancy reduction sui geni

L'ultima sezione applica la stessa logica di riduzione della ridondanza a una matrice di espressione genica. Il file viene caricato da Google Sheets; la prima colonna viene rinominata Gene e usata come indice. Il notebook stampa una matrice iniziale di 750 geni per 56 pazienti. Successivamente la matrice viene trasposta, ottenendo 56 pazienti per 750 geni, così che le colonne siano i geni e la correlazione venga calcolata tra geni.

Dopo la conversione numerica, viene calcolata la matrice di correlazione Spearman tra tutti i geni. Il numero di variabili è molto più alto rispetto alle feature radiomiche: la heatmap rappresenta quindi una matrice 750 x 750. Per questo motivo la figura non è utile per leggere singoli nomi di geni, ma è utile per valutare visivamente la presenza o assenza di grandi blocchi di correlazione.




Figura 4. Matrice di correlazione Spearman tra geni.

La heatmap genetica appare molto più diffusa e meno organizzata in blocchi compatti rispetto alle heatmap radiomiche. La diagonale principale è rossa perché ogni gene è perfettamente correlato con sé stesso. Fuori diagonale prevalgono colori più tenui, segno che la maggior parte delle coppie geniche non supera la soglia di ridondanza scelta. Coerentemente con questa osservazione, il numero finale di geni rimane quasi invariato.

Il risultato finale è una riduzione da 750 a 746 geni. I geni eliminati in modo univoco sono 4, quindi viene mantenuto circa il 99,5% dei geni iniziali. Le prime righe del mapping stampato indicano ridondanze tra CD27 e CD79A, ADAM12 e COL11A1, FAM30A con CD27/CD79A e HLA-DQB1 con HLA-DQA1.

Indicatore	Valore	
Shape iniziale	750 geni x 56 pazienti	
Shape dopo trasposizione	56 pazienti x 750 geni	
Geni iniziali nella riduzione	750	
Geni finali selezionati	746	
Geni eliminati in modo univoco	4	
Percentuale mantenuta	99,5%	
Gene rimosso	Gene rappresentativo	Spearman rho
CD27	CD79A	0.918316
ADAM12	COL11A1	0.912326
FAM30A	CD27	0.907716
FAM30A	CD79A	0.934805
HLA-DQB1	HLA-DQA1	0.915899

Nel blocco geni il notebook stampa le prime righe del mapping di ridondanza. Il numero finale di geni selezionati permette di dedurre che le variabili eliminate in modo univoco sono quattro.

8. Confronto trasversale dei risultati radiomici

Confrontando i tre dataset radiomici, emerge che la riduzione non ha la stessa intensità in tutte le modalità. Il CT ex vivo conserva il numero maggiore di feature, mentre il Micro-CT conserva il numero minore. Questa differenza deriva dalla struttura di correlazione interna a ciascun dataset e dalla regola di eliminazione basata su $|\rho| > 0,9$.

Classe radiomica	CT in vivo	CT ex vivo	Micro-CT
firstorder	9	11	7
glcm	8	8	6
glrlm	3	5	4
glszm	7	12	5
gldm	6	8	5
ngtdm	1	2	1

Le feature mantenute non sono distribuite nello stesso modo tra le classi. Nel CT in vivo rimangono 9 feature first-order e 8 GLCM; nel CT ex vivo rimane un numero elevato di GLSZM; nel Micro-CT la selezione è più restrittiva ma conserva comunque rappresentanti di tutte le principali famiglie radiomiche.

Sono presenti 17 feature selezionate in tutti e tre i dataset radiomici. Questa intersezione può essere utile come nucleo comune di descrittori robusti rispetto alla modalità di acquisizione o al tipo di dataset.

Feature selezionate in tutti e tre i dataset radiomici

N.	Feature selezionata
1	original_firstorder_90Percentile
2	original_firstorder_Energy
3	original_firstorder_Kurtosis
4	original_firstorder_Minimum
5	original_firstorder_Range
6	original_firstorder_Variance
7	original_glcm_ClusterProminence
8	original_glcm_ClusterShade
9	original_glcm_Correlation
10	original_gldm_DependenceEntropy
11	original_gldm_LargeDependenceHighGrayLevelEmphasis
12	original_gldm_SmallDependenceLowGrayLevelEmphasis
13	original_glrlm_RunEntropy
14	original_glszm_GrayLevelVariance
15	original_glszm_LargeAreaHighGrayLevelEmphasis
16	original_glszm_SizeZoneNonUniformity
17	original_ngtdm_Complexity

L'intersezione non implica che queste feature siano necessariamente le più importanti biologicamente o predittivamente; indica però che, secondo la procedura di riduzione della ridondanza, esse sono sopravvissute in tutti e tre i contesti radiomici analizzati.

9. Conclusioni

1. Si è implementata una procedura coerente di Feature Redundancy Reduction basata sulla correlazione di Spearman e su una soglia stringente pari a $|\rho| > 0,9$.
2. Nei tre dataset radiomici, la rimozione delle feature di shape ha lasciato 93 feature da valutare in ciascun blocco.
3. La riduzione è stata marcata per Micro-CT, intermedia per CT in vivo e meno intensa per CT ex vivo.
4. Nel dataset genico la riduzione è stata minima: da 750 a 746 geni, suggerendo una ridondanza molto meno concentrata rispetto alle feature radiomiche alla soglia scelta.
5. Le heatmap confermano visivamente i risultati numerici: le matrici radiomiche presentano blocchi e bande di correlazioni forti, mentre la matrice genica è più diffusa e meno blocchettata.
6. I dataset ridotti ottenuti dal notebook sono adatti a essere usati come input per analisi successive, perché contengono meno variabili ridondanti e riducono il rischio di multicollinearità.

Appendice A - Feature radiomiche selezionate

Di seguito sono riportate le liste complete delle feature radiomiche mantenute dopo la riduzione della ridondanza per ciascun dataset.

CT in vivo - 34 feature selezionate

N.	Feature selezionata	N.	Feature selezionata
1	original_firstorder_90Percentile	18	original_glrlm_LongRunLowGrayLevelEmphasis
2	original_firstorder_Energy	19	original_glrlm_RunEntropy
3	original_firstorder_Kurtosis	20	original_glrlm_ShortRunHighGrayLevelEmphasis
4	original_firstorder_Maximum	21	original_glszm_GrayLevelVariance
5	original_firstorder_Median	22	original_glszm_HighGrayLevelZoneEmphasis
6	original_firstorder_Minimum	23	original_glszm_LargeAreaHighGrayLevelEmphasis
7	original_firstorder_Range	24	original_glszm_LowGrayLevelZoneEmphasis
8	original_firstorder_Skewness	25	original_glszm_SizeZoneNonUniformity
9	original_firstorder_Variance	26	original_glszm_SizeZoneNonUniformityNormalized
10	original_glcmm_Autocorrelation	27	original_glszm_ZoneEntropy
11	original_glcmm_ClusterProminence	28	original_gldm_DependenceEntropy
12	original_glcmm_ClusterShade	29	original_gldm_LargeDependenceEmphasis
13	original_glcmm_Contrast	30	original_gldm_LargeDependenceHighGrayLevelEmphasis
14	original_glcmm_Correlation	31	original_gldm_LargeDependenceLowGrayLevelEmphasis
15	original_glcmm_Imc1	32	original_gldm_LowGrayLevelEmphasis
16	original_glcmm_InverseVariance	33	original_gldm_SmallDependenceLowGrayLevelEmphasis
17	original_glcmm_JointEntropy	34	original_ngtdm_Complexity

CT ex vivo - 46 feature selezionate

N.	Feature selezionata	N.	Feature selezionata
1	original_firstorder_10Percentile	24	original_glrlm_ShortRunHighGrayLevelEmphasis
2	original_firstorder_90Percentile	25	original_glszm_GrayLevelNonUniformity
3	original_firstorder_Energy	26	original_glszm_GrayLevelNonUniformityNormalized
4	original_firstorder_Kurtosis	27	original_glszm_GrayLevelVariance
5	original_firstorder_Maximum	28	original_glszm_HighGrayLevelZoneEmphasis
6	original_firstorder_Mean	29	original_glszm_LargeAreaHighGrayLevelEmphasis
7	original_firstorder_Minimum	30	original_glszm_LowGrayLevelZoneEmphasis
8	original_firstorder_Range	31	original_glszm_SizeZoneNonUniformity
9	original_firstorder_RootMeanSquared	32	original_glszm_SmallAreaEmphasis
10	original_firstorder_Skewness	33	original_glszm_SmallAreaHighGrayLevelEmphasis
11	original_firstorder_Variance	34	original_glszm_SmallAreaLowGrayLevelEmphasis
12	original_glcmm_Autocorrelation	35	original_glszm_ZoneEntropy
13	original_glcmm_ClusterProminence	36	original_glszm_ZonePercentage
14	original_glcmm_ClusterShade	37	original_gldm_DependenceEntropy
15	original_glcmm_ClusterTendency	38	original_gldm_DependenceNonUniformity
16	original_glcmm_Correlation	39	original_gldm_DependenceNonUniformityNormalized
17	original_glcmm_Imc1	40	original_gldm_DependenceVariance
18	original_glcmm_Imc2	41	original_gldm_LargeDependenceEmphasis
19	original_glcmm_MCC	42	original_gldm_LargeDependenceHighGrayLevelEmphasis
20	original_glrlm_LongRunEmphasis	43	original_gldm_SmallDependenceHighGrayLevelEmphasis

21	original_glrlm_LongRunLowGrayLevelEmphasis	44	original_gldm_SmallDependenceLowGrayLevelEmphasis
22	original_glrlm_RunEntropy	45	original_ngtdm_Complexity
23	original_glrlm_RunLengthNonUniformity	46	original_ngtdm_Strength

Micro-CT - 28 feature selezionate

N.	Feature selezionata	N.	Feature selezionata
1	original_firstorder_90Percentile	15	original_glrlm_LongRunHighGrayLevelEmphasis
2	original_firstorder_Energy	16	original_glrlm_RunEntropy
3	original_firstorder_InterquartileRange	17	original_glrlm_RunLengthNonUniformity
4	original_firstorder_Kurtosis	18	original_glszm_GrayLevelVariance
5	original_firstorder_Minimum	19	original_glszm_LargeAreaEmphasis
6	original_firstorder_Range	20	original_glszm_LargeAreaHighGrayLevelEmphasis
7	original_firstorder_Variance	21	original_glszm_SizeZoneNonUniformity
8	original_glcmm_ClusterProminence	22	original_glszm_SmallAreaEmphasis
9	original_glcmm_ClusterShade	23	original_gldm_DependenceEntropy
10	original_glcmm_ClusterTendency	24	original_gldm_DependenceNonUniformity
11	original_glcmm_Correlation	25	original_gldm_HighGrayLevelEmphasis
12	original_glcmm_InverseVariance	26	original_gldm_LargeDependenceHighGrayLevelEmphasis
13	original_glcmm_MCC	27	original_gldm_SmallDependenceLowGrayLevelEmphasis
14	original_glrlm_GrayLevelNonUniformity	28	original_ngtdm_Complexity

Correlazioni tra geni normalizzati e feature radiomiche microCT

Notebook: correlazioni_microCT.ipynb

1. Sintesi esecutiva

Il notebook ha esplorato associazioni radiogenomiche tra espressione genica normalizzata e feature radiomiche microCT ex vivo ricavate da blocchetti di tessuto. Le analisi sono state svolte con correlazioni di Spearman, correzione FDR Benjamini-Hochberg, filtri di variabilità sui geni e sulle feature, e riduzione dimensionale tramite PCA.

Area	Risultato chiave
Dataset principale	56 pazienti con dati sia genomici sia microCT; 750 geni normalizzati; 93 feature radiomiche dopo rimozione delle feature shape.
Correlazioni dirette	La scansione esaustiva geni-feature ha trovato correlazioni moderate, fino a rho circa 0,55, ma nessuna associazione è risultata significativa dopo FDR.
Filtri per variabilità	Sono stati provati top 50, 100, 200 geni per IQR, top 5%, soglia IQR > 4000, CV e combinazioni con feature selezionate; in generale nessun risultato diretto ha superato FDR < 0,05.
PCA radiomica e geni	La PCA delle feature radiomiche ha selezionato 5 componenti per spiegare circa l'83,4% della varianza; la PCA sui geni ha selezionato 25 componenti per arrivare a circa l'80% della varianza. Dato che la varianza dei dataset viene spiegata con un numero alto di componenti, è meglio non usare questo metodo.
Risultati significativi	Nelle correlazioni tra PC radiomiche e top 50 geni IQR, PC5 è risultata associata a TPI1 e ALDOA con p aggiustato circa 0,011. In una variante CC/PCA, PC5 è risultata associata a ALDOA e TPI1 con p aggiustato circa 0,012. Questo risultato è di difficile analisi e interpretazione biologica a causa della bassa varianza che raccoglie la PCA.

2. Dati, librerie e preprocessing

Il notebook importa pandas, seaborn, matplotlib, numpy, scipy.stats, statsmodels, networkx, math e re. In Colab viene montato Google Drive per accedere ai file radiomici salvati nel percorso Drive.

2.1 Fonti dati

Fonte	Uso nel notebook
Geni normalizzati	Google Sheet esportato in CSV. Il file è letto con pandas, la prima colonna viene usata come indice dei geni, poi la tabella viene trasposta in formato pazienti x geni. Output iniziale: 56 pazienti x 750 geni.
Feature radiomiche microCT	File radiomics_microCT.csv su Google Drive. In diverse celle la forma è 60 campioni x 108 colonne; dopo rimozione della colonna ID e/o delle feature shape rimangono 93 feature.
Allineamento pazienti	Gli identificativi paziente vengono normalizzati estraendo il primo numero dalla stringa. In tutte le analisi risultano 56 pazienti comuni tra dati genomici e radiomici.

- Funzione `normalize_patient_id`: converte stringhe come MICRO_TC_1, MICRO TC 1 o 1.0 nello stesso ID numerico, ad esempio "1".
- Conversione numerica: i valori genomici e radiomici sono convertiti con `pd.to_numeric(errors="coerce")` per rendere le matrici usabili nelle correlazioni e nella PCA.
- Rimozione feature shape: nelle analisi dirette iniziali le colonne contenenti "shape" vengono rimosse, lasciando 93 feature radiomiche.

- Allineamento: le matrici vengono filtrate sui pazienti comuni e ordinate/verificate per garantire che l'ordine dei pazienti sia uguale tra feature e geni.

3. Metodi statistici applicati

Metodo	Descrizione operativa
Spearman	Usato per misurare associazioni monotone non necessariamente lineari tra feature radiomiche, geni e componenti principali.
FDR Benjamini-Hochberg	Applicato con statsmodels.stats.multitest.multipletests per correggere i p-value su molteplici test. La soglia interpretativa usata nel notebook è FDR < 0,05.
IQR	Usato per selezionare geni e feature a maggiore variabilità. Sono stati testati top 50, top 100, top 200, top 5% e soglia IQR > 4000.
CV	È stata testata una selezione per coefficiente di variazione dopo filtro su espressione media > 30, ma questo criterio è molto dipendente dalla media quindi si preferisce usare IQR.
PCA	Usata per ridurre la dimensionalità delle feature radiomiche e dei geni. Le componenti sono selezionate fino a superare una varianza cumulativa di circa 80%.
Feature redundancy reduction	In una cella finale, le feature altamente correlate tra loro con Spearman assoluto > 0,9 vengono ridotte mantenendo il gene con IQR maggiore.

4. Correlazioni dirette geni-feature

La prima parte del notebook esegue correlazioni Spearman tra feature radiomiche e geni. Per ogni coppia feature-gene vengono salvati rho, p-value, p-value corretto FDR e indicatore fdr_reject.

Feature	Gene	rho Spearman	p-value	FDR	FDR < 0,05
original_ngtdm_Busyness	CCNB1	0.553	1.00e-05	0.187	False
original_glszm_LargeAreaHighGrayLevelEmphasis	CCNB1	0.541	1.70e-05	0.187	False
original_firstorder_Median	HMGB1	0.538	1.90e-05	0.187	False
original_gldm_GrayLevelNonUniformity	CCNB1	0.537	2.00e-05	0.187	False
original_glszm_LargeAreaHighGrayLevelEmphasis	MKI67	0.533	2.30e-05	0.187	False
original_firstorder_10Percentile	HMGB1	0.532	2.40e-05	0.187	False
original_firstorder_90Percentile	HMGB1	0.532	2.50e-05	0.187	False
original_firstorder_RootMeanSquared	HMGB1	0.531	2.50e-05	0.187	False
original_firstorder_Mean	HMGB1	0.531	2.60e-05	0.187	False
original_ngtdm_Busyness	UBE2T	0.528	2.90e-05	0.187	False

Tabella: prime dieci correlazioni ordinate per valore assoluto di p_value corretto nell'analisi esaustiva di 750 geni x 93 feature. Nessuna supera la soglia FDR < 0,05.

Analisi	Dimensione	Miglior risultato salvato	rho	p	FDR	Esito
---------	------------	---------------------------	-----	---	-----	-------

Tutti i geni vs tutte le feature no shape	750 geni x 93 feature = 69.750 test	original_ngtdm_Buyness - CCNB1	0,5525	1,0e-05	0,1866	Non significativo
Top 50 geni per IQR vs 93 feature	50 x 93 = 4.650 test	original_ngtdm_Buyness - TPI1	0,5071	6,6e-05	0,2704	Non significativo
Top 100 geni per IQR vs 93 feature	100 x 93 = 9.300 test	original_ngtdm_Buyness - TPI1	0,5071	6,6e-05	0,5405	Non significativo
Top 200 geni per IQR vs 93 feature	200 x 93 = 18.600 test	original_glszm_LargeAreaHighGrayLevelEmphasis - MKI67	0,5334	2,3e-05	0,2293	Non significativo
Top 5% geni per IQR vs 93 feature	38 x 93 = 3.534 test	original_ngtdm_Buyness - TPI1	0,5071	6,6e-05	0,2055	Non significativo
Geni con IQR > 4000 vs 93 feature	20 x 93 = 1.860 test	original_gldm_LowGrayLevelEmphasis - SPP1	0,4818	1,7e-04	0,2101	Non significativo
Top 50 geni per CV vs 93 feature	50 x 93 = 4.650 test	Output ordinato con FDR = 1,0 nelle righe mostrate	max mostrato rho 0,2983	0,0255	1,0000	Non significativo
Top 50 geni IQR vs 28 feature selezionate	50 x 28 = 1.400 test	original_glcm_ClusterProminence - SERPINA1	0,4693	2,64e-04	0,2026	Non significativo
Top 100 geni IQR vs 28 feature selezionate	100 x 28 = 2.800 test	original_glcm_ClusterProminence - SERPINA1	0,4693	2,64e-04	0,4052	Non significativo
Top 5% geni IQR vs 28 feature selezionate	38 x 28 = 1.064 test	original_glcm_ClusterProminence - SERPINA1	0,4693	2,64e-04	0,1540	Non significativo
Top 30 geni IQR vs top 30 feature IQR	30 x 30 = 900 test	original_ngtdm_Buyness - TPI1	0,5071	6,6e-05	0,0598	Quasi significativo, ma FDR > 0,05

Interpretazione: le correlazioni dirette evidenziano segnali biologicamente interessanti ma, dopo correzione per il numero elevato di test, non emergono associazioni FDR-significative. La riduzione a 30 geni e 30 feature produce il valore FDR più vicino alla soglia, pari a circa 0,0598 per Busyness - TPI1.

4.1 Selezione di geni ad alta variabilità

Il notebook confronta più strategie per limitare il numero di geni da correlare con le feature: top N per IQR, top 5% per IQR, soglia IQR > 4000. La lista top 50 per IQR include, tra gli altri: CD74, B2M, HLA-B, LYZ, HLA-A, RPL23, RPL7A, SPP1, S100A9, PKM, NFKBIA, **A2M**, HLA-DQA1, DUSP1, HLA-DRB1, THBS1, ALDOA, HLA-DRA, GLUL, IFI27, ENO1, APOE, COL6A3, LDHA, S100A8, HIF1A, EPCAM, HLA-C, **TPI1** e SERPINA1.

4.2 Feature selezionate tramite feature redundancy reduction

In più celle viene usata una lista di 28 feature radiomiche selezionate, comprendente feature first-order, GLCM, GLRLM, GLSZM, GLDM e NGTDM. Esempi: original_firstorder_90Percentile, original_firstorder_Energy, original_firstorder_InterquartileRange, original_glcm_ClusterProminence, original_glcm_MCC, **original_glrlm_GrayLevelNonUniformity**, original_glszm_LargeAreaHighGrayLevelEmphasis, original_gldm_DependenceEntropy e original_ngtdm_Complexity.

5. Analisi PCA e riduzione dimensionale

La seconda parte del notebook usa PCA per ridurre la dimensionalità di feature e geni, quindi correla componenti principali e/o geni selezionati. Le matrici vengono standardizzate con StandardScaler prima della PCA.

Analisi PCA	Impostazione	Risultato principale	Dettaglio numerico
-------------	--------------	----------------------	--------------------

PCA feature radiomiche	Feature radiomiche no shape: 93 variabili. Soglia varianza cumulativa 0,80.	5 PC selezionate; varianza cumulativa raggiunta 0,8338.	PC1=0,3729; PC2=0,1906; PC3=0,1205; PC4=0,0913; PC5=0,0584.
PCA geni	750 geni x 56 pazienti, standardizzati.	25 PC selezionate; varianza cumulativa raggiunta circa 0,8008.	PC1=0,1092; PC2=0,0896; PC3=0,0666; PC4=0,0527; PC5=0,0444.
PCA feature vs top 50 geni IQR	Correlazione Spearman tra PC1-PC5 radiomiche e 50 geni più variabili per IQR.	Due associazioni FDR-significative.	PC5 - TPI1 : rho 0,5163, p 4,6e-05, p_adj 0,0112; PC5 - ALDOA : rho 0,4993, p 8,9e-05, p_adj 0,0112.
CC/PCA variante	Top 50 geni IQR e PCA sulle radiomiche; output presentato come correlazioni PC-gene.	Due associazioni FDR-significative.	PC5 - ALDOA : rho -0,5064, p 6,8e-05, p_adj 0,0124; PC5 - TPI1 : rho -0,4967, p 9,9e-05, p_adj 0,0124.
PCA radiomiche vs PCA geni	5 PC radiomiche contro 25 PC geniche.	Nessuna correlazione FDR-significativa.	Migliore: Radiomic_PC5 - Gene_PC1, rho 0,3941, p 0,002656, FDR 0,2944.
PCA geni vs top 50 feature IQR	25 PC geniche contro 50 feature radiomiche top IQR.	Nessuna correlazione FDR-significativa.	Migliore: PC24 - original_firstorder_Variance, rho -0,5129, p 5,3e-05, FDR 0,0664.
PCA geni vs 28 feature selezionate	25 PC geniche contro 28 feature selezionate FRR.	Nessuna correlazione FDR-significativa.	Migliore: PC24 - original_firstorder_Variance, rho -0,4921, p 0,000117, FDR 0,0819.
PCA geni dopo riduzione ridondanza	Geni ridotti da 750 a 746 rimuovendo correlazioni Spearman > 0,9; poi PCA e top 50 feature per IQR.	Nessuna correlazione FDR-significativa.	Migliore: PC24 - original_firstorder_Variance, rho -0,4930, p 0,000113, FDR 0,1418.

5.1 Driver delle componenti geniche

Per la PCA genica, il notebook estrae i geni con loading assoluto più alto sulle prime componenti. I principali driver di PC1 e PC2 aiutano a interpretare biologicamente le componenti.

Componente	Geni driver riportati nel notebook
PC1	CDC20, EXO1, CDK6, NECTIN1, CCNB1, CENPF, SLC16A1, A2M, FBP1, RRM2, TYMP, PKM, TLR3, BIRC5, RAD51, TYMS, GBP2, VCAN, MKI67, IL6R
PC2	CD48, SH2D1A, CD3E, ITGAL, IL2RB, JAK3, CD2, CD3D, CD6, PDCD1

6. Conclusioni

1. Il preprocessing è coerente: gli ID paziente sono normalizzati, i dati vengono convertiti in numerico e le matrici sono allineate sui 56 pazienti comuni.
2. Le correlazioni dirette gene-feature mostrano valori rho moderati, ma non resistono alla correzione FDR quando il numero di test è elevato.
3. La strategia più promettente tra quelle salvate è la correlazione tra PCA radiomica e geni ad alta variabilità: PC5 risulta associata a TPI1 e ALDOA con p aggiustato circa 0,011-0,012, a questa strada non è ottimale a causa della bassa varianza che rappresentano le prime componenti (Lescai).

Appendice A - Tracciamento delle celle del notebook

Cella	Cosa fa	Output/risultato
0	Import librerie e mount Google Drive.	Drive già montato.
1	Markdown introduttivo sulle correlazioni tra geni normalizzati e feature microCT ex vivo.	Descrive obiettivo della prima analisi.
2	Correlazione Spearman tra tutte le feature no shape e tutti i geni.	56 pazienti comuni, 750 geni, 93 feature, 69.750 test; top rho 0,5525, nessun FDR significativo.
3	Markdown sui filtri per geni più variabili.	Propone IQR, deviazione standard senza outlier, top N, top 5% e soglia IQR.
4	Top 50 geni per IQR vs tutte le feature.	4.650 test; top TP11/Busyness rho 0,5071; FDR 0,2704.
5	Top 100 geni per IQR vs tutte le feature.	9.300 test; top TP11/Busyness rho 0,5071; FDR 0,5405.
6	Top 200 geni per IQR vs tutte le feature.	18.600 test; top MKI67/LargeAreaHighGrayLevelEmphasis rho 0,5334; FDR 0,2293.
7	Top 5% geni per IQR.	38 geni; 3.534 test; nessun FDR significativo.
8	Geni con IQR > 4000.	20 geni; 1.860 test; nessun FDR significativo.
9	Selezione top 50 geni per CV dopo filtro espressione media > 30.	698 geni dopo filtro; output con FDR = 1,0 nelle righe mostrate.
10	Top 50 geni IQR vs 28 feature selezionate.	1.400 test; top SERPINA1/ClusterProminence rho 0,4693; FDR 0,2026.
11	Top 100 geni IQR vs 28 feature selezionate.	2.800 test; nessun FDR significativo.
12	Top 5% geni IQR vs 28 feature selezionate.	1.064 test; nessun FDR significativo.
13	Top 30 geni IQR vs top 30 feature IQR.	900 test; top TP11/Busyness rho 0,5071; FDR 0,0598.
14	Tentativo con geni selezionati dal professore.	Errore ParserError nella lettura del CSV da Google Drive.
15	Seconda versione della stessa analisi manuale.	Nessun output salvato nel notebook.
16	Markdown su PCA e riduzione non supervisionata.	Spiega PCA, ICA, ZV, NZV, Consensus Clustering e CC + PCA.
17	PCA sulle feature radiomiche.	Output figura varianza cumulativa; shape originale 60 x 108.
18	Correlazione PC radiomiche (5 PC) con top 50 geni IQR.	Significative PC5-TP11 e PC5-ALDOA con p_adj 0,011187.
19	CC-PCA / PCA radiomica con top 50 geni IQR.	Significative PC5-ALDOA e PC5-TP11 con p_adj 0,012364.
20	Markdown PCA geni.	Apri la sezione PCA sui geni.
21	PCA su tutti i geni.	PC1-PC5 spiegano circa il 36,25%; top driver PC1 e PC2 riportati.
22	Correlazione PC1-PC5 radiomiche con PC1-PC25 geniche.	Nessuna FDR significativa; migliore PC5 radiomica vs PC1 genica rho 0,3941, FDR 0,2944.
23	PCA geni vs top 50 feature IQR.	Nessuna FDR significativa; migliore PC24 vs Variance rho -0,5129, FDR 0,0664.
24	PCA geni vs 28 feature selezionate FRR.	Nessuna FDR significativa; migliore PC24 vs Variance rho -0,4921, FDR 0,0819.
25	Riduzione ridondanza geni, PCA e top 50 feature IQR.	Geni da 750 a 746; nessuna FDR significativa; migliore PC24 vs Variance rho -0,4930, FDR 0,1418.

Correlazioni tra geni normalizzati e feature radiomiche CT ex vivo

Notebook: correlazioni_CT_exvivo.ipynb

Sintesi esecutiva

Il notebook analizza l'associazione tra profili di espressione genica normalizzati e feature radiomiche estratte da CT ex vivo del blocchetto di tessuto. L'obiettivo è capire se alcune caratteristiche quantitative dell'immagine CT siano correlate a specifici geni o a pattern molecolari.

Dopo l'allineamento degli identificativi del paziente, l'analisi lavora su **50 pazienti** comuni tra dataset genico e dataset radiomico. Il dataset genico contiene 750 geni, mentre il dataset radiomico, dopo esclusione delle feature di forma nelle analisi principali, contiene 93 feature CT.

Nelle correlazioni dirette estese, cioè tutti i geni contro tutte le feature CT, non emergono associazioni significative dopo correzione FDR. Le correlazioni nominalmente più forti coinvolgono GBP2, REN, CCR5, A2M e PTEN, ma la penalizzazione per il grande numero di test porta a valori FDR non significativi.

Il segnale più consistente nelle analisi dirette riguarda A2M, che mostra correlazioni negative con feature di energia/intensità e non uniformità del grigio. Quando lo spazio dei test viene ristretto ai top 30 geni per variabilità e alle top 30 feature per variabilità, quattro associazioni A2M-feature CT diventano significative dopo FDR.

Le analisi PCA forniscono i seguenti risultati: la riduzione della ridondanza radiomica seguita da PCA evidenzia una correlazione significativa tra la componente radiomica PC5 e COL17A1; la PCA genica mostra invece che la componente genica PC11 è significativamente associata a feature CT di intensità/varianza; infine, una correlazione significativa collega direttamente la PC4 radiomica alla PC11 genica. Anche in questo caso, come con la micro CT, non è chiaro il valore di queste affermazioni a causa della bassa varianza rappresentata e della difficile deduzione biologica delle componenti.

Blocco di analisi	Risultato principale	Interpretazione
Correlazioni dirette complete	Nessuna associazione FDR<0,05 su 69.750 test	Il segnale nominale esiste, ma il numero di confronti è molto elevato.
Selezione per alta variabilità genica	A2M ricorre con feature Energy, TotalEnergy e GrayLevelNonUniformity	A2M è il gene più stabile tra i segnali diretti, soprattutto con feature di intensità e disomogeneità.
Top 30 geni x top 30 feature	4 correlazioni A2M significative dopo FDR	La significatività emerge quando l'analisi è fortemente prefiltrata.
CC-PCA radiomica	Radiomic PC5 - COL17A1: rho 0,579, FDR 0,002658	La riduzione di ridondanza fa emergere un segnale legato a COL17A1.
PCA genica	Gene PC11 - Variance/RootMeanSquared: FDR circa 0,015-0,017	Una componente molecolare multigenica è associata a feature CT di distribuzione dell'intensità.
PCA radiomica vs PCA genica	Radiomic PC4 - Gene PC11: rho 0,512, FDR 0,018143	Conferma di un collegamento a livello di pattern globali immagine-genomica.

1. Obiettivo e logica complessiva

Il notebook è strutturato come una progressione di analisi radiogenomiche. Prima vengono testate correlazioni dirette tra ogni feature CT e ogni gene; poi vengono applicati filtri di variabilità per ridurre il numero di ipotesi; infine vengono usate tecniche di PCA per cercare associazioni tra pattern radiomici e pattern genici più globali.

La scelta della correlazione di Spearman è coerente con un contesto esplorativo in cui non è necessario assumere relazioni lineari tra espressione genica e feature radiomiche. **Spearman misura infatti l'associazione monotona tra i ranghi: una correlazione positiva indica che valori più alti di una feature tendono ad accompagnarsi a valori più alti del gene o della componente; una correlazione negativa indica il contrario.**

Poiché vengono effettuati molti test contemporaneamente, il notebook applica la correzione Benjamini-Hochberg per il controllo del False Discovery Rate. Questo passaggio è essenziale: molte correlazioni nominalmente piccole di p-value possono non rimanere significative quando si corregge per migliaia di confronti.

2. Dati di partenza e preprocessing

2.1 Dataset genico

Il dataset genico viene letto da un foglio Google esportato in formato CSV. La matrice contiene 750 geni e 56 pazienti. Le righe rappresentano i geni e le colonne rappresentano i pazienti. Nel corso delle analisi la matrice viene trasposta quando serve lavorare in formato pazienti x geni, soprattutto per la PCA.

Una parte importante del notebook è la normalizzazione degli identificativi del paziente. La funzione di normalizzazione trasforma gli ID in stringhe standardizzate, elimina spazi e differenze di maiuscole/minuscole ed estrae il numero del paziente tramite espressione regolare. Questo permette di allineare campioni provenienti da fonti diverse anche quando gli ID non hanno esattamente lo stesso formato.

2.2 Dataset radiomico CT ex vivo

Le feature radiomiche vengono lette dal file out_CTconv_FIXED.csv salvato su Google Drive. Il dataset radiomico contiene 53 pazienti. Nelle analisi principali vengono escluse le feature di forma, cioè quelle il cui nome contiene shape, per concentrarsi su feature di intensità e texture. Dopo questa esclusione, il numero di feature CT usate nelle correlazioni dirette è 93.

Le feature radiomiche includono famiglie diverse: first order, GLCM, GLRLM, GLSZM, GLDM e NGTDM. Le feature first order descrivono la distribuzione dei valori di intensità; le classi di texture descrivono invece eterogeneità, non uniformità, co-occorrenza dei livelli di grigio, dimensione delle zone e dipendenze locali.

2.3 Allineamento dei pazienti e controlli

Dopo la normalizzazione degli ID, i **pazienti comuni tra dataset genico e radiomico sono 50**. Tutte le correlazioni vengono calcolate su questi 50 pazienti condivisi. Il notebook controlla anche la presenza di NaN e converte le colonne radiomiche in formato numerico, in modo da evitare errori nei calcoli statistici.

Elemento	Valore/descrizione
Pazienti nel dataset genico	56
Geni disponibili	750
Pazienti nel dataset CT ex vivo	53
Feature CT non-shape usate nelle analisi principali	93
Pazienti comuni dopo normalizzazione ID	50
Metodo di correlazione	Spearman
Correzione multipla	Benjamini-Hochberg FDR

3. Correlazioni dirette gene-feature CT

3.1 Analisi completa: 750 geni x 93 feature CT

La prima analisi confronta ogni gene con ogni feature radiomica CT non-shape. In totale vengono eseguiti 69.750 test validi. Le correlazioni vengono ordinate per valore assoluto di rho, cioè dalla più forte alla più debole indipendentemente dal segno.

Il risultato principale è che nessuna associazione supera la soglia $FDR < 0,05$. Questo non significa che non esistano segnali biologicamente interessanti, ma che, nel contesto di un numero molto elevato di test e di 50 pazienti, le associazioni osservate non sono abbastanza robuste da superare la correzione multipla.

Feature CT	Gene	rho	p-value	FDR	Significativa
original_gldm_DependenceNonUniformity	GBP2	0.600	4.00e-06	0.236751	No
original_glszm_SmallAreaLowGrayLevelEmphasis	REN	0.587	7.00e-06	0.236751	No
original_ngtdm_Strength	CCR5	-0.580	1.00e-05	0.236751	No
original_glrlm_RunLengthNonUniformity	GBP2	0.572	1.40e-05	0.244335	No
original_ngtdm_Strength	GBP2	-0.559	2.50e-05	0.334640	No
original_ngtdm_Strength	TDO2	-0.549	3.70e-05	0.334640	No
original_ngtdm_Busyness	CCR5	0.543	4.70e-05	0.334640	No
original_firstorder_Energy	A2M	-0.540	5.20e-05	0.334640	No
original_firstorder_TotalEnergy	A2M	-0.540	5.20e-05	0.334640	No
original_firstorder_Energy	PTEN	-0.540	5.30e-05	0.334640	No

A2M compare già tra i primi risultati con Energy e TotalEnergy, anticipando un pattern che ritornerà nelle analisi filtrate.

3.2 Selezione dei geni ad alta variabilità

Il notebook introduce una riflessione metodologica sulla selezione dei geni. Vengono considerati IQR, deviazione standard e coefficiente di variazione. **La scelta operativa privilegia l'IQR perché è robusto agli outlier e identifica geni con reale variabilità inter-paziente senza dipendere troppo dalla media di espressione.**

Sono state provate diverse soglie: top 50, top 100, top 200 geni per IQR, top 5% dei geni per IQR e geni con IQR superiore a 3000. In tutte queste versioni il numero di test si riduce rispetto all'analisi completa, ma quasi tutte le associazioni restano non significative dopo FDR.

Analisi	Geni	Feature	Test validi	FDR minimo	Segnale migliore	Esito
Tutti i geni x tutte le feature CT	750	93	69.750	0,236751	GBP2 - DependenceNonUniformity (rho 0,600)	No
Top 50 geni per IQR	50	93	4.650	0,120531	A2M - Energy/TotalEnergy (rho -0,540)	No
Top 50 geni per IQR, feature z-score	50	93	4.650	0,120531	Risultati invariati rispetto al caso non scalato	No
Top 100 geni per IQR	100	93	9.300	0,241061	A2M - Energy/TotalEnergy (rho -0,540)	No
Top 200 geni per IQR	200	93	18.600	0,076073	GBP2 - DependenceNonUniformity (rho 0,600)	No
Top 5% geni per IQR	38	93	3.534	0,091603	A2M - Energy/TotalEnergy (rho -0,540)	No
Geni con IQR > 3000	26	93	2.418	0,062676	A2M - Energy/TotalEnergy (rho -0,540)	No

Analisi	Geni	Feature	Test validi	FDR minimo	Segnale migliore	Esito
Top 50 geni per coefficiente di variazione	50	93	4.650	~0,955718	Nessun pattern robusto	No
Top 50 geni IQR x 46 feature selezionate	50	46	2.300	0,119235	A2M - Energy (rho -0,540)	No
Top 100 geni IQR x 46 feature selezionate	100	46	4.600	0,238469	A2M - Energy (rho -0,540)	No
Top 5% geni IQR x 46 feature selezionate	38	46	1.748	0,090618	A2M - Energy (rho -0,540)	No
Top 30 geni IQR x top 30 feature IQR	30	30	900	0,023329	A2M - Energy/TotalEnergy	Sì, 4 associazioni
Geni indicati dal professore x feature selezionate	11	46	506	0,211272	COL17A1/MMP1/MM P9 nominali	No

La tabella mostra un aspetto importante: ridurre i geni può migliorare la penalizzazione FDR, ma il risultato dipende dall'equilibrio tra forza della correlazione e numero totale di confronti. La soglia IQR > 3000 e la selezione top 5% si avvicinano alla significatività per A2M, ma non la raggiungono. **La selezione top 30 geni x top 30 feature, invece, riduce molto lo spazio dei test e fa emergere risultati significativi.**

Sottoanalisi IQR	Associazione nominale più forte	rho	p-value	FDR	Commento
Top 50 IQR	A2M - Energy/TotalEnergy	-0.540	5.20e-05	0.120531	A2M emerge come gene dominante ma resta sopra FDR 0,05.
Top 100 IQR	A2M - Energy/TotalEnergy	-0.540	5.20e-05	0.241061	Aggiungere altri geni aumenta il numero di test e peggiora la correzione.
Top 200 IQR	GBP2 - DependenceNonUniformity	0.600	4.00e-06	0.076073	GBP2 diventa il segnale nominale più forte, quasi significativo ma non sotto 0,05.
Top 5% IQR	A2M - Energy/TotalEnergy	-0.540	5.20e-05	0.091603	Restrizione più severa dei geni, ma ancora non sufficiente per FDR 0,05.
IQR > 3000	A2M - Energy/TotalEnergy	-0.540	5.20e-05	0.062676	Soglia assoluta sulla variabilità: risultato vicino alla significatività.

3.3 Effetto dello z-score sulle feature

Il notebook ripete l'analisi con le feature radiomiche standardizzate tramite z-score. I risultati principali restano invariati. Questo è atteso perché la correlazione di Spearman si basa sui ranghi: una trasformazione lineare monotona come lo z-score non cambia l'ordine dei campioni e quindi non cambia rho o p-value, salvo differenze numeriche trascurabili.

3.4 Selezione tramite coefficiente di variazione

Viene esplorata anche la selezione dei geni con maggiore coefficiente di variazione (CV). Per evitare che geni con media molto bassa risultino artificialmente variabili, il notebook applica prima un filtro di espressione media maggiore di 30, lasciando 698 geni candidati. Da questi vengono selezionati i top 50 per coefficiente di variazione.

Questa strategia non produce associazioni robuste: i migliori FDR sono molto elevati, circa 0,956. Il risultato supporta la scelta metodologica di non usare il coefficiente di variazione come filtro principale in questa analisi.

Top geni per coefficiente di variazione considerati: IL24, IFIT2, SPIB, CTAG1B, SFRP1, MAGEC2, BAMBI, NGFR, WNT10A, MAGEA4, CXCL5, HLA-DQA2, CCNA1, MAGEA1, HLA-DRB5, TNFSF10, MAGEA3/A6, MAGEA12, S100A8, IL1B, IL1A, CCL20, IDO1, PDZK1IP1, WNT2B, S100A9, ERBB2, CXCL13, NOS2, FGFR1, MAGEB2, CXCL14, NDUFA4L2, S100A12, CXCL6, ESR1, IFIT1, CXCL1, CCL19, MMP1, VTCN1, VCAM1, LAMC2, FCAR, SOX2, ARG2, SERPINB5, PTGS2, CXCL8, HLA-DQB1.

3.5 Analisi con feature radiomiche selezionate

Il notebook utilizza anche un pannello di feature radiomiche selezionate, pari a 46 feature in diverse analisi. Questa selezione riduce il numero di confronti e si concentra su feature ritenute più informative o meno ridondanti.

Famiglia radiomica	Feature incluse nel pannello selezionato
First order	10Percentile, 90Percentile, Energy, Kurtosis, Maximum, Mean, Minimum, Range, RootMeanSquared, Skewness, Variance
GLCM	Autocorrelation, ClusterProminence, ClusterShade, ClusterTendency, Correlation, Imc1, Imc2, MCC
GLRLM	LongRunEmphasis, LongRunLowGrayLevelEmphasis, RunEntropy, RunLengthNonUniformity, ShortRunHighGrayLevelEmphasis
GLSZM	GrayLevelNonUniformity, GrayLevelNonUniformityNormalized, GrayLevelVariance, HighGrayLevelZoneEmphasis, LargeAreaHighGrayLevelEmphasis, LowGrayLevelZoneEmphasis, SizeZoneNonUniformity, SmallAreaEmphasis, SmallAreaHighGrayLevelEmphasis, SmallAreaLowGrayLevelEmphasis, ZoneEntropy, ZonePercentage
GLDM	DependenceEntropy, DependenceNonUniformity, DependenceNonUniformityNormalized, DependenceVariance, LargeDependenceEmphasis, LargeDependenceHighGrayLevelEmphasis, SmallDependenceHighGrayLevelEmphasis, SmallDependenceLowGrayLevelEmphasis
NGTDM	Complexity, Strength

Anche limitando le feature a questo pannello, le analisi con top 50, top 100 e top 5% geni per IQR non producono associazioni FDR<0,05. A2M resta il segnale nominale più ricorrente, soprattutto con Energy, ma non supera la correzione multipla in queste configurazioni.

3.6 Analisi top 30 geni x top 30 feature: risultato diretto significativo

La prima evidenza significativa nelle correlazioni dirette emerge quando si restringe contemporaneamente entrambi i lati dell'analisi: vengono scelti i top 30 geni per IQR e le top 30 feature radiomiche per IQR. In questo modo i confronti scendono a 900, riducendo in modo importante il peso della correzione multipla.

In questa configurazione quattro correlazioni con A2M risultano significative dopo FDR. Tutte hanno segno negativo: pazienti con valori più alti delle feature CT indicate tendono ad avere valori più bassi di A2M, e viceversa.

Feature CT	Gene	rho	p-value	FDR	Significativa
original_firstorder_Energy	A2M	-0.540	5.20e-05	0.023329	Si
original_firstorder_TotalEnergy	A2M	-0.540	5.20e-05	0.023329	Si
original_glrlm_GrayLevelNonUniformity	A2M	-0.512	1.43e-04	0.042817	Si
original_gldm_GrayLevelNonUniformity	A2M	-0.500	2.20e-04	0.049492	Si

Le feature significative appartengono a due tipi di informazione radiomica: Energy/TotalEnergy descrivono la grandezza complessiva del segnale di intensità, mentre GrayLevelNonUniformity in GLRLM e GLDM descrive la non uniformità dei livelli di grigio. Il fatto che tutte le associazioni significative riguardino A2M suggerisce che questo gene sia il candidato più rilevante nelle analisi dirette, pur richiedendo validazione indipendente.

4. Analisi PCA e riduzione dimensionale

Dopo le correlazioni dirette, il notebook passa alle PCA. La logica cambia: invece di testare singole coppie gene-feature, si cercano relazioni tra componenti principali. Una componente principale riassume una combinazione di variabili correlate; quindi una correlazione significativa tra una componente radiomica e un gene, o tra una componente genica e una feature radiomica, può rappresentare un pattern più stabile rispetto a una singola misura isolata.

4.1 PCA delle feature CT: primi 5 PC contro top 50 geni IQR

La prima PCA viene calcolata sulle 93 feature CT non-shape dopo standardizzazione. Vengono estratte 5 componenti principali. La quota di varianza spiegata dai primi cinque PC è: PC1 35,5%, PC2 15,6%, PC3 13,3%, PC4 9,1% e PC5 7,0%. Insieme, i 5 PC spiegano circa l'80,6% della variabilità radiomica.

Questi 5 PC vengono poi correlati con i top 50 geni selezionati per IQR. Non emergono correlazioni significative dopo FDR. Il risultato indica che, senza ridurre prima la ridondanza tra feature CT, i principali assi globali di variazione radiomica non si associano in modo sufficientemente robusto ai singoli geni del pannello top 50.

4.2 Riduzione della ridondanza radiomica e CC-PCA

Per affrontare la forte correlazione tra molte feature radiomiche, il notebook applica una riduzione della ridondanza. Le coppie di feature con correlazione di Spearman superiore a 0,90 vengono considerate ridondanti e viene mantenuta la feature con IQR più elevato. In questo modo il set radiomico passa da 93 a 46 feature.

Dopo la riduzione, viene eseguita una PCA sulle 46 feature selezionate. I primi componenti spiegano quote più distribuite di varianza: PC1 22,6%, PC2 18,6%, PC3 14,2%, PC4 11,4%, PC5 9,0%. I primi 5 PC spiegano circa il 75,9%; aggiungendo PC6 si supera l'82%.

Questa strategia produce un risultato significativo: PC5 radiomica correla con COL17A1 con rho 0,579, p-value circa $1,1 \times 10^{-5}$ e p_adj 0,002658.

Analisi	Componente	Gene/feature	rho	p-value	FDR	Interpretazione
CC-PCA feature CT	Radiomic PC5	COL17A1	0.579	1.10×10^{-5}	0.002658	Associazione più forte dopo riduzione della ridondanza radiomica.

Dal punto di vista interpretativo, COL17A1 compare qui come gene collegato a un asse radiomico non immediatamente visibile nelle correlazioni dirette.

4.3 PCA dei geni contro top 50 feature CT per IQR

Il notebook esegue poi una PCA sul dataset genico. La matrice viene organizzata in formato pazienti x geni e standardizzata. Il numero di componenti viene scelto in modo da spiegare almeno l'80% della varianza complessiva. Servono 25 componenti principali geniche per raggiungere una varianza cumulativa di circa 80,08%.

Le 25 componenti geniche vengono correlate con le top 50 feature CT selezionate per IQR. Questa analisi identifica due associazioni significative dopo FDR, entrambe legate alla componente genica PC11: PC11 con RootMeanSquared e PC11 con Variance. Entrambe hanno rho positivo intorno a 0,559 e FDR 0,015494.

Analisi	Componente	Gene/feature	rho	p-value	FDR	Interpretazione
PCA geni vs top 50 feature IQR	Gene PC11	original_firstorder_RootMeanSquared	0.559	2.40×10^{-5}	0.015494	Segnale positivo tra componente genica e intensità media/scala del segnale CT.
PCA geni vs top 50 feature IQR	Gene PC11	original_firstorder_Variance	0.559	2.50×10^{-5}	0.015494	Segnale quasi identico a RootMeanSquared, coerente con feature di intensità/distribuzione.

4.4 PCA dei geni contro 28 feature CT selezionate

Si ripete l'analisi PC geniche-feature CT usando un pannello più ristretto di 28 feature radiomiche selezionate. La PCA genica resta la stessa: 25 componenti sono necessarie per spiegare circa l'80,08% della varianza genica. Le feature radiomiche, invece, vengono limitate a un set selezionato e controllato.

Anche in questa configurazione la PC11 genica resta il segnale principale. La correlazione significativa è PC11 con original_firstorder_Variance, con rho 0,559856, p-value 0,000024 e FDR 0,016559.

Analisi	Componente	Gene/feature	rho	p-value	FDR	Interpretazione
PCA geni vs 28 feature selezionate	Gene PC11	original_firstorder_Variance	0.560	2.40e-05	0.016559	Conferma del legame PC11-Variance anche su un pannello di feature ridotto.

4.5 Correlazione tra componenti principali radiomiche e componenti principali geniche

L'ultima analisi PCA confronta direttamente i pattern globali dei due domini. Dal lato radiomico, le 93 feature CT non-shape vengono riassunte in 5 componenti principali, sufficienti a spiegare circa l'80,6% della varianza. Dal lato genico, i 750 geni vengono riassunti in 25 componenti, sufficienti a spiegare circa l'80,08% della varianza.

Le correlazioni sono quindi calcolate tra 5 PC radiomiche e 25 PC geniche. Il risultato significativo è la correlazione tra Radiomic PC4 e Gene PC11: rho 0,511837, p-value 0,000145 e FDR 0,018143.

Analisi	Componente	Gene/feature	rho	p-value	FDR	Interpretazione
PCA radiomica vs PCA genica	Radiomic PC4	Gene PC11	0.512	1.45e-04	0.018143	Collega una componente globale CT con una componente globale di espressione genica.

4.6 Geni che contribuiscono maggiormente alla Gene PC11

Poiché Gene PC11 ricorre in più analisi significative, il notebook estrae i geni con loading maggiore su questa componente. I loading indicano quanto ciascun gene contribuisce alla costruzione del PC: valori più alti in valore assoluto indicano maggiore peso nella componente.

Gene	Loading su Gene PC11
BMP2	0.120644
CXCL13	0.106460
BRCA1	0.103420
SPIB	0.098738
TNFAIP3	0.095112
ENO1	0.094286
NF1	0.093939
RPL23	0.093774
TNF	0.093285
MAPK10	0.091679
TNFRSF9	0.091616
VCAM1	0.090517
PRKAA2	0.089842
ICOS	0.088794
SOX10	0.088031
BCL2	0.087915
IFIH1	0.087097
ACVR1C	0.086239
ICAM1	0.084880

Gene	Loading su Gene PC11
CCL2	0.084437

Tra i geni con maggiore contributo a Gene PC11 compaiono BMP2, CXCL13, BRCA1, SPIB, TNFAIP3, TNF, VCAM1, ICAM1 e CCL2.

5. Lettura integrata dei risultati

Quando si testano direttamente molte migliaia di coppie gene-feature, la correzione multipla rende difficile ottenere significatività. Tuttavia, alcuni segnali ritornano più volte e meritano attenzione, in particolare A2M.

A2M è il risultato più forte nelle correlazioni dirette filtrate. Le correlazioni significative nella sottoanalisi top 30 x top 30 sono tutte negative e coinvolgono Energy, TotalEnergy e due misure di non uniformità dei livelli di grigio. Questo suggerisce un possibile legame tra A2M e proprietà CT legate all'intensità globale e all'eterogeneità del tessuto.

La Gene PC11 è il filo conduttore delle analisi PCA più robuste. PC11 correla con feature first order come Variance e RootMeanSquared, e correla anche con Radiomic PC4.

Risultato chiave	Tipo di analisi	Valore statistico	Messaggio biologico/statistico
A2M - Energy/TotalEnergy	Top 30 geni x top 30 feature	rho -0,540; FDR 0,023329	Segnale diretto più forte e significativo dopo prefiltraggio severo.
A2M - GrayLevelNonUniformity	Top 30 geni x top 30 feature	rho circa -0,50/-0,51; FDR 0,043-0,049	A2M associato anche a non uniformità radiomica.
Radiomic PC5 - COL17A1	CC-PCA radiomica	rho 0,579; FDR 0,002658	Segnale robusto legato a un pattern radiomico multifeature.
Gene PC11 - Variance/RootMeanSquared	PCA genica vs feature CT	rho circa 0,56; FDR 0,015-0,017	Una componente molecolare globale è associata alla distribuzione dell'intensità CT.
Radiomic PC4 - Gene PC11	PCA radiomica vs PCA genica	rho 0,512; FDR 0,018143	Collegamento significativo tra pattern latenti dei due domini.

6. Limiti e raccomandazioni

- Il numero di pazienti comuni è 50: è sufficiente per un'analisi esplorativa, ma limitato rispetto al numero di geni e feature testati.
- La significatività di A2M nelle correlazioni dirette emerge solo dopo un prefiltraggio forte; andrebbe quindi validata su coorti indipendenti o con una strategia pre-registrata.
- Le PCA producono risultati robusti, ma le componenti principali sono combinazioni statistiche di variabili: richiedono interpretazione tramite validazione biologica. Inoltre in questo caso la PCA è molto limitata a causa della bassa varianza che viene rappresentata da ciascuna componente principale.

7. Riepilogo cella per cella

La tabella seguente riassume l'intero notebook cella per cella, collegando ciascun blocco di codice o markdown al risultato principale prodotto.

Cella	Cosa fa	Risultato/nota
0	Import delle librerie e collegamento a Google Drive.	Ambiente preparato con pandas, numpy, scipy, statsmodels, scikit-learn, seaborn/matplotlib e funzioni per Spearman, FDR e PCA.
1	Titolo e obiettivo del notebook.	Analisi delle correlazioni tra geni normalizzati e feature radiomiche CT ex vivo del blocchetto di tessuto.
2	Prima analisi completa: tutti i geni contro tutte le feature CT non-shape.	56 pazienti nei geni, 53 nella radiomica, 50 pazienti comuni, 69.750 test validi. Nessuna associazione significativa dopo FDR.
3	Scelta dei geni a maggiore variabilità.	Decisione metodologica: preferire IQR/deviazione standard e non il coefficiente di variazione, per evitare effetti troppo dipendenti dalla media.

Cella	Cosa fa	Risultato/nota
4	Top 50 geni per IQR contro tutte le feature CT.	A2M emerge con Energy, TotalEnergy e indici di non uniformità, ma FDR minimo 0,120531.
5	Ripetizione con feature radiomiche scalate z-score.	Stessi risultati principali, coerenti con il fatto che Spearman usa ranghi e non dipende dalla scala lineare.
6	Top 100 geni per IQR.	Aumentando i geni aumentano i test; il segnale A2M resta nominale ma FDR minimo sale a 0,241061.
7	Top 200 geni per IQR.	GBP2 diventa il segnale nominale più forte con DependenceNonUniformity; FDR minimo 0,076073.
8	Top 5% geni per IQR, pari a 38 geni.	A2M torna come segnale principale; FDR minimo 0,091603.
9	Geni con IQR > 3000, pari a 26 geni.	A2M con Energy/TotalEnergy arriva a FDR 0,062676, vicino alla soglia ma non significativo.
10	Selezione dei top 50 geni per coefficiente di variazione.	Dopo filtro media >30 restano 698 geni; nessuna associazione robusta, FDR molto alto.
11	Top 50 geni IQR contro 46 feature radiomiche selezionate.	Riduzione delle feature secondo lista selezionata; nessun risultato FDR<0,05.
12	Top 100 geni IQR contro 46 feature selezionate.	Nessuna associazione significativa; A2M resta tra i segnali nominali.
13	Top 5% geni IQR contro 46 feature selezionate.	FDR minimo 0,090618 su A2M-Energy; non significativo.
14	Top 30 geni IQR contro top 30 feature IQR.	Riduzione forte dello spazio dei test a 900 confronti: 4 correlazioni A2M-feature CT diventano significative dopo FDR.
15	Geni scelti dal professore contro tutte le feature CT.	Panel mirato di geni extracellular matrix/invasione/adesione. Segnali nominali per MMP1, COL17A1, LAMA1/LAMC2, MMP9, ITGA6, ma non FDR-significativi.
16	Geni scelti dal professore contro 46 feature selezionate.	Conferma dei segnali nominali, FDR migliore circa 0,211272, ancora non significativo.
17	Inizio sezione PCA.	Passaggio dalle correlazioni gene-feature dirette ad analisi su componenti principali.
18	PCA sulle feature CT e correlazione dei primi 5 PC con top 50 geni IQR.	I 5 PC radiomici spiegano circa 80,6% della varianza; nessun gene significativo dopo FDR.
19	Riduzione della ridondanza tra feature CT e PCA, poi correlazione con top 50 geni IQR.	Le feature passano da 93 a 46; emerge una correlazione significativa tra PC5 radiomica e COL17A1.
20	PCA sui geni e correlazione con top 50 feature CT per IQR.	25 PC geniche spiegano 80% della varianza; PC11 correla significativamente con RootMeanSquared e Variance.
21	PCA sui geni e correlazione con 28 feature CT selezionate.	Il risultato PC11-Variance rimane significativo anche su un pannello radiomico ridotto.
22	Correlazione tra PC radiomiche e PC geniche.	5 PC radiomiche e 25 PC geniche; Radiomic PC4 correla con Gene PC11 con FDR 0,018143. Vengono estratti i geni che pesano di più su Gene PC11.

8. Conclusione

Il notebook costruisce un'analisi radiogenomica completa su CT ex vivo, passando da correlazioni dirette ad approcci di riduzione dimensionale. Le correlazioni complete non identificano risultati significativi dopo FDR, ma i filtri di variabilità mettono in evidenza A2M come candidato ricorrente. La sottoanalisi top 30 x top 30 rende significative quattro associazioni A2M-feature CT.

La riduzione della ridondanza radiomica tramite PCA evidenzia un'associazione significativa tra PC5 e COL17A1; la PCA genica identifica PC11 come componente associata a feature CT di intensità/varianza; la correlazione diretta tra PC radiomiche e PC geniche conferma il ruolo di PC11 collegandola a Radiomic PC4.

Correlazioni tra geni normalizzati e feature CT in vivo

Notebook: correlazioni_CT_invivo.ipynb

1. Sintesi dei risultati principali

Il notebook studia l'associazione tra espressione genica normalizzata e feature radiomiche CT in vivo. Le analisi usano correlazioni di Spearman e correzione FDR Benjamini-Hochberg. Il campione comune usato nelle correlazioni è di **54 pazienti**.

- La matrice completa 750 geni x 93 feature produce 69.750 test validi. Il miglior FDR è 0,0519, quindi nessuna associazione supera formalmente $FDR < 0,05$ nella scansione completa.
- La selezione dei geni più variabili tramite IQR cambia nettamente l'esito: con 50 geni IQR emergono 26 associazioni significative, con 100 geni 17, con il top 5% dei geni 28 e con soglia IQR > 1000 22.
- Il segnale ricorrente è **TPI1**. TPI1 risulta associato a feature di uniformità, energia/entropia GLCM, grande area GLSZM, run length GLRLM e dipendenze GLDM.
- Le 34 feature selezionate tramite feature redundancy reduction mantengono un sottoinsieme del segnale: top 50 geni IQR x 34 feature producono 5 associazioni significative, ancora su TPI1.
- Le analisi PCA mostrano un risultato significativo tra PC1 radiomica e TPI1. Le altre analisi PCA, incluse CC-PCA, PCA genica e PC radiomiche contro PC geniche, non producono associazioni FDR-significative.

Sintesi delle analisi di correlazione diretta

Analisi	Geni	Feature/PC	Test validi	Miglior segnale	rho	FDR min	N sig. FDR<0,05
Tutti i geni x tutte le feature CT	750	93	69.750	SizeZoneNonUniformity - HNF1A	-0,606	0,0519	0
Top 50 geni IQR x 93 feature	50	93	4.650	Uniformity - TPI1	0,559	0,0221	26
Top 100 geni IQR x 93 feature	100	93	9.300	Uniformity - TPI1	0,559	0,0443	17
Top 200 geni IQR x 93 feature	200	93	18.600	Uniformity - TPI1 / Median - HMGA1	0,559 / 0,545	0,0791	0
Top 5% geni IQR x 93 feature	38	93	3.534	Uniformity - TPI1	0,559	0,0168	28
Geni con IQR > 1000 x 93 feature	76	93	7.068	Uniformity - TPI1	0,559	0,0336	22
Top 50 geni per coefficiente di variazione	50	93	4.650	Maximum - CTAG1B	-0,535	0,1408	0
Top 50 geni IQR x 34 feature FRR	50	34	1.700	JointEntropy - TPI1	-0,544	0,0285	5
Top 100 geni IQR x 34 feature FRR	100	34	3.400	JointEntropy - TPI1	-0,544	0,0569	0
Top 5% geni IQR x 34 feature FRR	38	34	1.292	JointEntropy - TPI1	-0,544	0,0216	5
Top 30 geni IQR x top 30 feature IQR	30	30	900	LongRunHighGrayLevelEmphasis - TPI1	0,532	0,0090	9

Sintesi delle analisi PCA

Analisi PCA	Blocco radiomico	Blocco genico	N sig.	Risultato principale
PCA feature CT x top 50 geni IQR	93 feature -> 5 PC	50 geni	1	PC1 radiomica - TPI1: rho=-0,541, p_adj=0,00599.
CC-PCA feature x top 50 geni IQR	93 feature -> 31 feature -> 5 PC	50 geni	0	Miglior segnale PC2 - TPI1: rho=0,481, p_adj=0,0578.

Analisi PCA	Blocco radiomico	Blocco genico	N sig.	Risultato principale
PCA geni x top 50 feature IQR	750 geni -> 25 PC	50 feature	0	Miglior segnale PC15 - GLCM DifferenceVariance: rho=-0,402, FDR=0,728.
PCA geni x 34 feature FRR	750 geni -> 25 PC	34 feature	0	Miglior segnale PC1 - JointEntropy: rho=-0,404, FDR=0,800.
PC radiomiche x PC geniche	93 feature -> 4 PC	750 geni -> 25 PC	0	Migliore coppia PC1 radiomica - PC1 genica: rho=-0,383, FDR=0,430.

2. Dati, preprocessing e strategia statistica

Il notebook utilizza due sorgenti dati: una matrice di espressione genica normalizzata e una matrice di feature radiomiche CT in vivo. Le feature radiomiche vengono lette da CSV, convertite a numerico e filtrate eliminando le feature shape.

Elemento	Dimensione / valore	Interpretazione
Matrice genica iniziale	56 pazienti x 750 geni	La matrice viene trasposta: righe = pazienti, colonne = geni.
Matrice radiomica CT iniziale	58 pazienti x 93 feature non-shape	Le feature shape vengono escluse; restano first order e texture.
Pazienti comuni	54	Intersezione tra identificativi del paziente nei due dataset.
Correlazione usata	Spearman	Misura relazioni monotone basate sui ranghi, senza assumere linearità.
Correzione multipla	FDR Benjamini-Hochberg	Risultati considerati significativi se FDR < 0,05.

2.1 Normalizzazione e allineamento degli ID paziente

Nelle sezioni PCA viene definita una funzione di normalizzazione degli ID paziente. La logica è ricondurre etichette eterogenee come MICRO TC 10, 10 o 10.0 allo stesso identificativo numerico testuale. Questo passaggio evita che lo stesso paziente venga perso a causa di differenze di formattazione.

Schema concettuale: "MICRO TC 24" -> "24"; "24.0" -> "24"; " 24 " -> "24"

2.2 Scelta di Spearman e FDR

Per ogni coppia variabile radiomica - variabile genica viene calcolata la correlazione di Spearman. Successivamente tutte le p-value della stessa famiglia di test vengono corrette tramite `multipletests(..., method="fdr_bh")`. Questo è importante perché il numero di confronti è elevato: nella matrice completa si passa da un singolo confronto a 69.750 ipotesi simultanee.

2.3 Selezione dei geni variabili: IQR, SD senza outlier e CV

La parte centrale del notebook riduce il numero di geni testati selezionando quelli più variabili tra i pazienti. Il criterio principale scelto è l'IQR, cioè la differenza tra terzo e primo quartile. Il notebook confronta anche l'ordinamento per deviazione standard senza outlier e mostra che le due liste top 50 sono quasi sovrapponibili.

Confronto	Risultato
Top 50 IQR vs top 50 SD senza outlier	48 geni in comune su 50
Presenti in IQR ma non in SD senza outlier	MYC, TNFSF10
Presenti in SD senza outlier ma non in IQR	FBP1, TGFB1
Controllo manuale A2M	Q1=5648,25; Q3=12012,25; IQR=6364,0

Confronto	Risultato
Controllo manuale ACVR1C	Q1=20,75; Q3=43,0; IQR=22,25

Primi 10 geni per IQR

Gene	IQR
CD74	17714.75
B2M	15808.75
HLA-B	15236.00
LYZ	10039.00
HLA-A	8677.50
RPL23	7882.25
RPL7A	7516.25
SPP1	7199.00
S100A9	6974.25
PKM	6470.50

Lista top 50 geni selezionati per IQR

1	2	3	4	5
CD74	B2M	HLA-B	LYZ	HLA-A
RPL23	RPL7A	SPP1	S100A9	PKM
NFKBIA	A2M	HLA-DQA1	DUSP1	HLA-DRB1
THBS1	ALDOA	HLA-DRA	GLUL	IFI27
ENO1	APOE	COL6A3	LDHA	S100A8
HIF1A	EPCAM	HLA-C	TPI1	SERPINA1
LDHB	EGR1	NECTIN1	VCAN	SGK1
CCL2	CD44	CEBPB	COL17A1	CTNNA1
TPSAB1/B2	CXCR4	ITGAV	LAMB3	HLA-E
HLA-DPB1	MYC	ICAM1	TNFSF10	CXCL2

Il coefficiente di variazione (CV) viene testato come alternativa, dopo filtro dei geni con media di espressione maggiore di 30. Questa metrica, però, è troppo dipendente dalla media.

3. Correlazioni dirette gene-feature

Questa sezione documenta le correlazioni dirette, cioè il confronto di ciascun gene con ciascuna feature CT. Il filo conduttore è valutare come cambiano i risultati quando si restringe lo spazio delle ipotesi sui geni, sulle feature o su entrambi.

3.1 Matrice completa: 750 geni x 93 feature

La prima analisi include tutti i 750 geni e tutte le 93 feature CT non-shape. Sono validi tutti i 69.750 confronti. I primi risultati hanno correlazioni anche relativamente alte in valore assoluto, ma la correzione FDR porta il miglior valore a 0,0519. Quindi la matrice completa identifica segnali candidati ma non risultati statisticamente significativi al livello FDR < 0,05.

Matrice completa: prime 10 associazioni ordinate per FDR

Feature	Gene	rho	p-value	FDR	Sig.
original_gldm_LowGrayLevelEmphasis	BRCA1	-0.588	3.00e-06	0.0519	No
original_glszm_GrayLevelNonUniformity	HNFI1A	-0.591	3.00e-06	0.0519	No
original_glszm_SizeZoneNonUniformity	HNFI1A	-0.606	1.00e-06	0.0519	No
original_glrlm_LowGrayLevelRunEmphasis	BRCA1	-0.591	3.00e-06	0.0519	No
original_glszm_LowGrayLevelZoneEmphasis	BRCA1	-0.580	4.00e-06	0.0605	No
original_ngtdm_Strength	HNFI1A	0.572	6.00e-06	0.0631	No
original_glrlm_ShortRunLowGrayLevelEmphasis	BRCA1	-0.572	6.00e-06	0.0631	No
original_firstorder_Uniformity	TPI1	0.559	1.10e-05	0.0957	No
original_firstorder_Median	HMGA1	0.545	2.10e-05	0.1407	No
original_glcmm_JointEntropy	TPI1	-0.544	2.20e-05	0.1407	No

3.2 Analisi con geni ad alta variabilità IQR

La selezione per IQR è la parte più informativa delle correlazioni dirette. Riducendo i geni ai più variabili, **il numero di test si abbassa e il segnale TPI1 diventa FDR-significativo in più configurazioni**. La tabella seguente mostra le associazioni TPI1 che ricorrono in modo stabile.

Segnali TPI1 ricorrenti nelle analisi IQR

Feature	Gene	rho	FDR top 50	FDR top 100	FDR top 5%	FDR IQR>1000
original_firstorder_Uniformity	TPI1	0.559	0.022127	0.044255	0.016817	0.033634
original_glcmm_JointEntropy	TPI1	-0.544	0.022127	0.044255	0.016817	0.033634
original_glcmm_JointEnergy	TPI1	0.541	0.022127	0.044255	0.016817	0.033634
original_glrlm_LongRunHighGrayLevelEmphasis	TPI1	0.532	0.022127	0.044255	0.016817	0.033634
original_gldm_LargeDependenceHighGrayLevelEmphasis	TPI1	0.526	0.022127	0.044255	0.016817	0.033634
original_glszm_LargeAreaEmphasis	TPI1	0.524	0.022127	0.044255	0.016817	0.033634
original_glszm_ZoneVariation	TPI1	0.524	0.022127	0.044255	0.016817	0.033634
original_glszm_LargeAreaHighGrayLevelEmphasis	TPI1	0.523	0.022127	0.044255	0.016817	0.033634
original_glcmm_Id	TPI1	0.519	0.022127	0.044255	0.016817	0.033634
original_glcmm_Idm	TPI1	0.515	0.022127	0.044255	0.016817	0.033634
original_gldm_DependenceNonUniformityNormalized	TPI1	-0.514	0.022127	0.044255	0.016817	0.033634

L'interpretazione biologico-radiomica più prudente è che TPI1 si comporta come asse molecolare associato a pattern radiomici di omogeneità/eterogeneità e organizzazione dei livelli di grigio. Le correlazioni positive con Uniformity, JointEnergy, Id/Idm, LargeAreaEmphasis e LargeDependenceHighGrayLevelEmphasis vanno nella direzione di valori radiomici più ordinati o più concentrati; le correlazioni negative con JointEntropy,

SumEntropy, RunPercentage e alcune misure low-gray indicano l'opposto. Questa interpretazione resta esplorativa e richiede validazione indipendente.

Risultato diretto più robusto

Il gene TPI1 è il protagonista delle analisi IQR. Con 50 geni IQR compaiono 26 associazioni FDR-significative; con il top 5% dei geni si arriva a 28 associazioni significative; con top 30 geni e top 30 feature si ottengono 9 associazioni significative, tutte su TPI1.

3.3 Top 200 geni IQR: effetto del numero di test

Quando il numero di geni viene aumentato a 200, il segnale nominale resta simile ma l'onere della correzione multipla aumenta. Il miglior FDR diventa 0,0791 e nessuna coppia è significativa. Questo dimostra che non è solo la grandezza della correlazione a contare, ma anche il numero complessivo di ipotesi testate.

3.4 Geni con soglia IQR > 1000

La soglia assoluta IQR > 1000 seleziona 76 geni e genera 7.068 test. Anche qui TPI1 mantiene molte associazioni significative. Il numero di risultati significativi è inferiore rispetto al top 5% perché il numero di geni è maggiore, ma le feature principali restano coerenti.

4. Analisi con feature selezionate tramite riduzione di ridondanza

Una seconda strategia riduce il numero di feature radiomiche. Il notebook usa una lista di 34 feature derivate da feature redundancy reduction. La lista conserva misure first-order e texture distribuite tra GLCM, GLRLM, GLSZM, GLDM e NGTDM.

Le 34 feature CT usate nelle analisi FRR

Famiglia	Feature include
First order	90Percentile, Energy, Kurtosis, Maximum, Median, Minimum, Range, Skewness, Variance
GLCM	Autocorrelation, ClusterProminence, ClusterShade, Contrast, Correlation, Imc1, InverseVariance, JointEntropy
GLRLM	LongRunLowGrayLevelEmphasis, RunEntropy, ShortRunHighGrayLevelEmphasis
GLSZM	GrayLevelVariance, HighGrayLevelZoneEmphasis, LargeAreaHighGrayLevelEmphasis, LowGrayLevelZoneEmphasis, SizeZoneNonUniformity, SizeZoneNonUniformityNormalized, ZoneEntropy
GLDM	DependenceEntropy, LargeDependenceEmphasis, LargeDependenceHighGrayLevelEmphasis, LargeDependenceLowGrayLevelEmphasis, LowGrayLevelEmphasis, SmallDependenceLowGrayLevelEmphasis
NGTDM	Complexity

Con 50 geni IQR e 34 feature si ottengono 1.700 test e 5 associazioni significative. Anche in questa configurazione tutte le associazioni significative sono con TPI1. Con 100 geni le stesse coppie restano nominalmente forti, ma la FDR minima sale a 0,0569; con il top 5% dei geni si recuperano 5 associazioni significative.

Top 50 geni IQR x 34 feature FRR

Feature	Gene	rho	p-value	FDR	Sig.
original_glcm_JointEntropy	TPI1	-0.544	2.20e-05	0.0285	Si
original_gldm_LargeDependenceHighGrayLevelEmphasis	TPI1	0.526	4.50e-05	0.0285	Si
original_glszm_LargeAreaHighGrayLevelEmphasis	TPI1	0.523	5.00e-05	0.0285	Si

Feature	Gene	rho	p-value	FDR	Sig.
original_gldm_SmallDependenceLowGrayLevelEmphasis	TPI1	-0.514	7.10e-05	0.0302	Si
original_gldm_LargeDependenceEmphasis	TPI1	0.502	1.11e-04	0.0377	Si
original_firstorder_Maximum	SGK1	-0.445	7.47e-04	0.2117	No
original_glcmm_Contrast	TPI1	-0.438	9.29e-04	0.2257	No

Top 5% geni IQR x 34 feature FRR

Feature	Gene	rho	p-value	FDR	Sig.
original_gldm_LargeDependenceHighGrayLevelEmphasis	TPI1	0.526	4.50e-05	0.0216	Si
original_glcmm_JointEntropy	TPI1	-0.544	2.20e-05	0.0216	Si
original_glszm_LargeAreaHighGrayLevelEmphasis	TPI1	0.523	5.00e-05	0.0216	Si
original_gldm_SmallDependenceLowGrayLevelEmphasis	TPI1	-0.514	7.10e-05	0.0229	Si
original_gldm_LargeDependenceEmphasis	TPI1	0.502	1.11e-04	0.0287	Si
original_firstorder_Maximum	SGK1	-0.445	7.47e-04	0.1609	No
original_glcmm_Contrast	TPI1	-0.438	9.29e-04	0.1715	No

5. Riduzione simultanea: top 30 geni IQR x top 30 feature IQR

La cella finale delle correlazioni dirette restringe contemporaneamente i due assi. L'output mostra matrici finali 54 x 30 e 54 x 30: quindi i test effettivi sono 900. Questa è la configurazione diretta più selettiva.

Top 30 geni IQR x top 30 feature IQR: risultati principali

Feature	Gene	rho	p-value	FDR	Sig.
original_glszm_LargeAreaEmphasis	TPI1	0.524	4.80e-05	0.0090	Si
original_glszm_LargeAreaHighGrayLevelEmphasis	TPI1	0.523	5.00e-05	0.0090	Si
original_glrmm_LongRunHighGrayLevelEmphasis	TPI1	0.532	3.50e-05	0.0090	Si
original_glszm_ZoneVariance	TPI1	0.524	4.80e-05	0.0090	Si
original_gldm_LargeDependenceHighGrayLevelEmphasis	TPI1	0.526	4.50e-05	0.0090	Si
original_gldm_GrayLevelNonUniformity	TPI1	0.514	6.90e-05	0.0104	Si
original_gldm_LargeDependenceEmphasis	TPI1	0.502	1.11e-04	0.0143	Si
original_glrmm_GrayLevelNonUniformity	TPI1	0.483	2.15e-04	0.0242	Si
original_glszm_LargeAreaLowGrayLevelEmphasis	TPI1	0.466	3.88e-04	0.0388	Si
original_gldm_GrayLevelNonUniformity	PKM	0.444	7.72e-04	0.0579	No

Tutte le 9 associazioni significative sono con TPI1. Le feature coinvolte sono soprattutto GLSZM e GLDM di grande area/dipendenza, più GLRLM GrayLevelNonUniformity e LongRunHighGrayLevelEmphasis. Questo rafforza l'idea che il segnale TPI1 sia concentrato su pattern texture di organizzazione dei livelli di grigio.

6. Analisi PCA

La seconda parte del notebook usa PCA per riassumere feature radiomiche o geni in componenti principali. Questo riduce dimensionalità e ridondanza, e consente di testare associazioni tra componenti riassuntive e geni o feature selezionate.

6.1 PCA delle feature CT e correlazione con i top 50 geni IQR

In questa analisi vengono calcolate 5 componenti principali dalle 93 feature radiomiche. Le varianze spiegate sono 0,3849, 0,2462, 0,1012, 0,0769 e 0,0524. Complessivamente le 5 PC riassumono circa l'86,2% della variabilità radiomica.

Risultato significativo della PCA radiomica x geni

PC	Gene	rho	p-value	p_adj/FDR	Sig.
PC1	TPI1	-0.541	2.40e-05	0.0060	Si

Il risultato significativo è PC1 - TPI1, con $\rho = -0,541$ e $p_{\text{adj}} = 0,00599$. Il segno negativo indica che, al crescere dello score della prima componente radiomica, l'espressione di TPI1 tende a diminuire in modo monotono.

6.2 CC-PCA: riduzione della ridondanza radiomica prima della PCA

La CC-PCA rimuove feature radiomiche fortemente correlate tra loro usando una soglia di correlazione pari a 0,90. Le feature passano da 93 a 31. Sulle 31 feature rimanenti vengono calcolate 5 PC; PC1-PC5 spiegano cumulativamente circa l'82,2% della varianza.

CC-PCA: prime correlazioni PC-gene

PC	Gene	rho	p-value	FDR	Sig.
PC2	TPI1	0.481	2.31e-04	0.0578	No
PC2	PKM	0.400	0.0027	0.2775	No
PC2	ALDOA	0.392	0.0033	0.2775	No
PC5	DUSP1	-0.378	0.0048	0.3013	No
PC5	CXCR4	-0.360	0.0075	0.3618	No
PC3	APOE	0.354	0.0087	0.3618	No

6.3 PCA dei geni e correlazione con le top 50 feature IQR

Il notebook calcola una PCA sulla matrice genica completa. Per superare l'80% di varianza cumulativa sono necessarie 25 componenti. Questo suggerisce che la variabilità genica sia distribuita su molti assi, non concentrata in poche componenti (cosa negativa).

PCA genica x top 50 feature IQR: prime correlazioni

Gene PC	Feature	rho	p-value	FDR	Sig.
PC15	original_glcm_DifferenceVariance	-0.402	0.0026	0.7275	No
PC1	original_gldm_LargeDependenceHighGrayLevelEmphasis	0.387	0.0039	0.7275	No

Gene PC	Feature	rho	p-value	FDR	Sig.
PC1	original_glrIm_LongRunHighGrayLevelEmphasis	0.374	0.0054	0.7275	No
PC4	original_glrIm_HighGrayLevelRunEmphasis	0.372	0.0056	0.7275	No
PC1	original_glszm_LargeAreaHighGrayLevelEmphasis	0.368	0.0061	0.7275	No

6.4 PCA dei geni e 34 feature selezionate FRR

La PCA genica viene ripetuta contro le 34 feature FRR. La PCA dei geni resta sostanzialmente la stessa: 25 PC per superare l'80% della varianza. La riduzione delle feature non produce associazioni FDR-significative.

PCA genica x 34 feature FRR: prime correlazioni

Gene PC	Feature	rho	p-value	FDR	Sig.
PC1	original_glcM_JointEntropy	-0.404	0.0025	0.8000	No
PC1	original_gldm_LargeDependenceHighGrayLevelEmphasis	0.387	0.0039	0.8000	No
PC1	original_glszm_LargeAreaHighGrayLevelEmphasis	0.368	0.0061	0.8000	No
PC1	original_gldm_SmallDependenceLowGrayLevelEmphasis	-0.364	0.0069	0.8000	No
PC1	original_firstorder_Skewness	-0.363	0.0069	0.8000	No

6.5 Correlazione tra PC radiomiche e PC geniche

Nell'ultima analisi PCA, si confrontano direttamente componenti radiomiche e componenti geniche. Per le feature CT bastano 4 PC per raggiungere l'80,9% della varianza; per i geni servono 25 PC per raggiungere circa l'80,1%.

Correlazioni PC radiomiche x PC geniche: primi risultati

Radiomic PC	Gene PC	rho	p-value	FDR	Sig.
Radiomic PC1	Gene PC1	-0.383	0.0043	0.4302	No
Radiomic PC1	Gene PC15	-0.332	0.0141	0.7038	No
Radiomic PC3	Gene PC18	-0.311	0.0221	0.7372	No
Radiomic PC2	Gene PC22	-0.262	0.0553	0.8339	No
Radiomic PC4	Gene PC15	0.257	0.0606	0.8339	No

Top 20 geni driver della PC1 genica nella correlazione PC-PC

Gene driver PC1	Loading
CDC20	0.082484
EXO1	0.082007
CDK6	0.081355
NECTIN1	0.080265
CCNB1	0.078620
CENPF	0.078529
SLC16A1	0.078059
A2M	0.077839

Gene driver PC1	Loading
FBP1	0.077068
RRM2	0.076720
TYMP	0.075886
PKM	0.075721
TLR3	0.075590
BIRC5	0.075523
RAD51	0.074952
TYMS	0.073969
GBP2	0.073876
VCAN	0.073649
MKI67	0.073605
IL6R	0.073410

7. Interpretazione complessiva

Il notebook mostra due livelli di evidenza. Il primo livello è esplorativo globale: usando tutti i geni e tutte le feature si vedono correlazioni nominali forti ma nessuna FDR significativa. Il secondo livello è mirato: quando si riducono le ipotesi selezionando geni ad alta variabilità o feature non ridondanti, emergono risultati significativi concentrati soprattutto su TPI1.

- TPI1 è il risultato più coerente: compare nelle analisi top 50, top 100, top 5%, IQR > 1000, feature FRR, top 30 x top 30 è PCA feature-gene.
- COL11A1 emerge come risultato mirato: non supera la FDR con 93 feature, ma diventa significativo con la lista di 34 feature selezionate.
- La PCA radiomica è compatta, mentre la PCA genica richiede molte componenti: questo indica strutture di variabilità molto diverse tra imaging e trascrittomica.
- Le analisi PC-PC non sono significative, quindi non si osserva una relazione globale robusta tra lo spazio radiomico riassunto e lo spazio genico riassunto.

Conclusione

I risultati più solidi del notebook CT in vivo sono le associazioni tra TPI1 e un gruppo ricorrente di feature radiomiche di texture/eterogeneità, più il risultato COL11A1 - LowGrayLevelEmphasis nel pannello mirato con feature selezionate. Le analisi PCA supportano parzialmente TPI1 tramite PC1 radiomica, ma non mostrano una correlazione globale significativa tra componenti radiomiche e geniche.

7.1 Limiti da riportare

- Il campione comune è di 54 pazienti: sufficiente per analisi esplorative, ma limitato per conclusioni definitive.
- Le soglie e le liste di selezione sono state definite sullo stesso dataset: i risultati vanno validati su dati indipendenti.
- La significatività dipende molto dal numero di test: top 100 e top 200 cambiano l'esito pur mantenendo correlazioni nominali simili.

8. Riepilogo dettagliato cella per cella

La tabella seguente ricostruisce la funzione di ogni cella del notebook è il risultato generato. Questo rende il documento utilizzabile anche come descrizione metodologica del Colab.

Cella	Blocco	Cosa fa	Output / risultato
1	Setup librerie	Import di pandas, seaborn, matplotlib, numpy, scipy, statsmodels e networkx.	Definisce gli strumenti per gestione dati, correlazioni, correzione FDR e grafici.
2	Titolo analisi completa	Obiettivo: correlare tutti i geni normalizzati con tutte le feature CT sul paziente.	Definisce il blocco di analisi CT in vivo.
3	Tutti i geni x tutte le feature	Carica geni e feature CT, elimina feature shape, allinea 54 pazienti e calcola Spearman su 750 x 93 coppie.	69.750 test validi; nessuna FDR < 0,05. FDR minima 0,0519.
4	Motivazione IQR	Spiega perché selezionare geni variabili: IQR, deviazione standard senza outlier, top percentuale o soglia IQR.	Introduce la riduzione del numero di ipotesi.
5	Confronto IQR vs SD senza outlier	Ordina i geni con entrambe le strategie e confronta le liste top 50.	48 geni su 50 in comune; IQR e SD senza outlier sono quasi equivalenti.
6	Top 50 geni IQR	Seleziona 50 geni a maggiore IQR e li correla con 93 feature.	4.650 test; 26 associazioni FDR-significative, tutte guidate da TPI1.
7	Top 100 geni IQR	Ripete la correlazione aumentando a 100 geni.	9.300 test; 17 associazioni FDR-significative, ancora legate a TPI1.
8	Top 200 geni IQR	Ripete la correlazione con 200 geni variabili.	18.600 test; nessuna FDR < 0,05, per aumento del carico di test.
9	Top 5% geni IQR	Seleziona il 5% dei 750 geni, pari a 38 geni.	3.534 test; 28 associazioni significative, tutte su TPI1 nelle prime righe.
10	Soglia IQR > 1000	Usa una soglia assoluta di variabilità genica.	76 geni; 7.068 test; 22 associazioni FDR-significative, principalmente TPI1.
11	Controllo IQR manuale	Calcola Q1, Q3 e IQR per A2M e ACVR1C.	A2M: IQR 6364; ACVR1C: IQR 22,25.
12	Top 50 geni per CV	Filtra geni con media > 30 e ordina per coefficiente di variazione.	CV meno informativo; nessuna FDR significativa.
13	Top 50 IQR x 34 feature FRR	Usa una lista di 34 feature dopo riduzione di ridondanza.	1.700 test; 5 associazioni significative con TPI1.
14	Top 100 IQR x 34 feature FRR	Aumenta a 100 geni mantenendo le 34 feature.	3.400 test; nessuna FDR significativa, FDR minima 0,0569.
15	Top 5% IQR x 34 feature FRR	Usa 38 geni e 34 feature selezionate.	1.292 test; 5 associazioni significative con TPI1.
16	11 geni selezionati x 93 feature	Testa un pannello mirato: COL17A1, COL4A5, COL11A1, MMP1, MMP9, ITGA2, ITGA6, ITGB8, LAMA1, LAMC2, SERPINB5.	Nessuna FDR significativa; COL11A1 vicino alla soglia.
17	11 geni selezionati x 34 feature	Ripete il pannello mirato sulle 34 feature FRR.	1 associazione significativa: COL11A1 con LowGrayLevelEmphasis.
18	Top 30 geni x top 30 feature IQR	Riduce simultaneamente gene e feature ai 30 elementi più variabili.	900 test; 9 associazioni significative, tutte con TPI1.
19	Sezione PCA	Segnaposto markdown della parte di riduzione dimensionale.	Introduce le analisi su componenti principali.
20	PCA feature x geni	Calcola 5 PC radiomiche e le correla con 50 geni IQR.	PC1 radiomica - TPI1 significativa: rho=-0,541, p_adj=0,00599.
21	CC-PCA feature	Rimuove feature radiomiche ridondanti, poi PCA su 31 feature e correlazione con 50 geni.	Nessuna FDR < 0,05; PC2 - TPI1 e il segnale più vicino.
22	PCA geni x top 50 feature	PCA su 750 geni fino a 80% varianza, poi correlazione con 50 feature IQR.	25 PC geniche; nessuna correlazione significativa.
23	PCA geni x 34 feature FRR	Ripete PCA genica contro le 34 feature selezionate.	Nessuna correlazione significativa.
24	PC radiomiche x PC geniche	Correle 4 PC radiomiche con 25 PC geniche.	Nessuna FDR significativa; migliore coppia PC1-PC1 con rho=-0,383.

Correlazioni CT in vivo con feature shape

correlazioni_CT_invivo_conshape.ipynb

Messaggio chiave

L'analisi è focalizzata solo sulle feature shape della CT in vivo. Le associazioni più ricorrenti coinvolgono TP11 e PKM con misure di volume/diametro; tuttavia la significatività dopo correzione FDR compare solo quando il numero di confronti viene ridotto in modo più mirato, in particolare nel set del 5% dei geni più variabili e nell'analisi con top 30 geni/top feature per IQR. Le analisi PCA producono correlazioni non significative dopo FDR.

1. Obiettivo e struttura dell'analisi

Il notebook analizza il legame tra espressione genica normalizzata e caratteristiche radiomiche CT in vivo, restringendo la parte radiomica alle sole feature di forma, cioè alle variabili che descrivono dimensioni, volume, superficie, sfericità, elongazione, flatness e rapporti superficie/volume della lesione.

La strategia generale è la seguente: prima sono stati testati tutti i geni contro tutte le feature shape; successivamente sono state provate diverse selezioni di geni ad alta variabilità per ridurre il numero di confronti multipli e concentrare l'analisi sui geni più informativi.

- Correlazioni Spearman gene-feature, con p-value e correzione FDR Benjamini-Hochberg.
- Selezione dei geni tramite IQR: top 50, top 100, top 200, top 5% e soglia IQR > 1000.
- Analisi PCA sulle feature radiomiche e sui geni, con confronto tra componenti principali e ricerca dei geni driver.

2. Preprocessing dei dati

I dati genici vengono caricati da un foglio Google contenente geni normalizzati. La tabella originaria ha i geni sulle righe e i pazienti sulle colonne; per lavorare con Spearman e PCA viene quindi trasposta, ottenendo una matrice pazienti x geni. Le feature CT vengono caricate da un secondo foglio Google e indicizzate per paziente.

Nel dataset radiomico, i valori con virgola decimale vengono convertiti in formato numerico sostituendo la virgola con il punto. Subito dopo viene applicato un filtro sulle colonne per mantenere solo quelle che contengono la parola "shape". Questo porta a 14 feature radiomiche finali.

Pipeline di preparazione dati

Passaggio	Descrizione	Risultato nel notebook
Caricamento geni	Lettura del foglio genico, indice sui geni, trasposizione della matrice.	56 pazienti x 750 geni
Caricamento CT	Lettura del foglio CT, indice su Patient, conversione valori numerici.	58 pazienti x feature radiomiche
Filtro shape	Mantenimento delle sole colonne radiomiche con "shape" nel nome.	14 feature shape
Allineamento pazienti	Intersezione tra ID dei pazienti presenti nei due dataset.	54 pazienti comuni
Normalizzazione ID	Nelle analisi successive viene usata una funzione regex che estrae il numero dal nome paziente.	ID coerenti tra geni e CT

Elenco compatto delle feature radiomiche usate

Feature shape considerate
VoxelVolume, MeshVolume, SurfaceArea
Maximum3DDiameter, Maximum2DDiameterRow, Maximum2DDiameterColumn, Maximum2DDiameterSlice
MajorAxisLength, MinorAxisLength, LeastAxisLength
SurfaceVolumeRatio, Flatness, Sphericity, Elongation

3. Correlazione tra tutti i geni e tutte le feature shape

La prima analisi calcola la correlazione di Spearman tra ognuna delle 14 feature shape e ciascuno dei 750 geni. Il numero totale di test è $14 \times 750 = 10.500$; tutti i p-value risultano validi. La tabella seguente riporta le associazioni migliori mostrate dal notebook.

Top 10 associazioni nella matrice completa 14 feature x 750 geni

Feature shape	Gene	rho	p	FDR	Sign. FDR
Maximum2DDiameterColumn	HNF1A	-0.479	2.51e-04	0.2704	No
Maximum2DDiameterSlice	HNF1A	-0.475	2.87e-04	0.2704	No
MinorAxisLength	CD69	-0.473	3.00e-04	0.2704	No
VoxelVolume	ALDOC	0.466	3.87e-04	0.2704	No
Maximum2DDiameterRow	CD69	-0.452	5.97e-04	0.2704	No
MajorAxisLength	HNF1A	-0.469	3.47e-04	0.2704	No
Maximum3DDiameter	HNF1A	-0.471	3.20e-04	0.2704	No
MeshVolume	HNF1A	-0.461	4.49e-04	0.2704	No
SurfaceArea	ALDOC	0.462	4.31e-04	0.2704	No
LeastAxisLength	HNF1A	-0.458	5.00e-04	0.2704	No

Interpretazione

Nella matrice completa emergono correlazioni non corrette con valore assoluto intorno a 0.45-0.48. Esempi ricorrenti sono HNF1A con diametri/assi e ALDOC con volume/superficie. Dopo correzione FDR, però, il miglior FDR riportato è circa 0.270: quindi nessuna associazione supera la soglia $FDR < 0.05$.

4. Selezione dei geni ad alta variabilità

Si provano più criteri per ridurre il numero di geni testati. Il razionale è che geni con bassa variabilità tra pazienti possono essere meno informativi nelle correlazioni, mentre geni con IQR elevato o CV elevato possono evidenziare meglio differenze biologiche tra campioni.

Confronto globale delle strategie di selezione

Analisi	Geni	Feature	Test	FDR minimo	N. sign. FDR
Tutti i geni	750	14	10.500	0.270	0
Top 50 geni per IQR	50	14	700	0.063	0
Top 100 geni per IQR	100	14	1.400	0.125	0
Top 200 geni per IQR	200	14	2.800	0.222	0
Top 5% geni per IQR	38	14	532	0.048	16
IQR > 1000	76	14	1.064	0.095	0
Top 50 geni per CV	50	14	700	0.855	0
Geni selezionati dal prof.	11	14	154	0.383	0
Top 30 geni IQR + feature shape	30	14	420	0.038	21

Lettura del confronto

La riduzione del numero di test migliora la possibilità di mantenere associazioni significative dopo FDR. Le prove con 50, 100 e 200 geni IQR evidenziano gli stessi segnali biologici ricorrenti, ma non superano $FDR < 0.05$. Il set al 5% dei geni più variabili e l'analisi top 30/top feature sono invece quelle che restituiscono risultati FDR significativi.

4.1 Top 50, top 100 e top 200 geni per IQR

Le tre celle successive ripetono lo stesso schema: calcolo dell'IQR per ogni gene, selezione dei geni più variabili e correlazione con le 14 feature shape. In tutte e tre le prove i pazienti comuni sono 54 e le feature radiomiche restano 14.

Top 10 con top 50 geni IQR - 700 test validi

Feature shape	Gene	rho	p	FDR	Sign. FDR
VoxelVolume	TPI1	0.450	6.36e-04	0.0626	No
SurfaceArea	TPI1	0.424	0.0014	0.0626	No
Sphericity	NFKBIA	0.430	0.0012	0.0626	No
MinorAxisLength	TPI1	0.442	8.13e-04	0.0626	No
MinorAxisLength	PKM	0.429	0.0012	0.0626	No
MeshVolume	TPI1	0.450	6.36e-04	0.0626	No
Maximum2DDiameterRow	TPI1	0.425	0.0014	0.0626	No
Maximum2DDiameterRow	PKM	0.425	0.0014	0.0626	No
Maximum2DDiameterColumn	TPI1	0.455	5.42e-04	0.0626	No
Maximum2DDiameterSlice	PKM	0.429	0.0012	0.0626	No

Top 10 con top 100 geni IQR - 1.400 test validi

Feature shape	Gene	rho	p	FDR	Sign. FDR
SurfaceVolumeRatio	TPI1	-0.431	0.0011	0.1251	No
SurfaceArea	TPI1	0.424	0.0014	0.1251	No
MinorAxisLength	TPI1	0.442	8.13e-04	0.1251	No
Sphericity	NFKBIA	0.430	0.0012	0.1251	No
MinorAxisLength	PKM	0.429	0.0012	0.1251	No
Maximum2DDiameterSlice	PKM	0.429	0.0012	0.1251	No
Maximum2DDiameterSlice	TPI1	0.432	0.0011	0.1251	No
MeshVolume	TPI1	0.450	6.36e-04	0.1251	No
Maximum3DDiameter	PKM	0.423	0.0014	0.1251	No
VoxelVolume	TPI1	0.450	6.36e-04	0.1251	No

Top 10 con top 200 geni IQR - 2.800 test validi

Feature shape	Gene	rho	p	FDR	Sign. FDR
SurfaceArea	TPI1	0.424	0.0014	0.2225	No
Maximum2DDiameterColumn	ANLN	0.434	0.0011	0.2225	No
VoxelVolume	TPI1	0.450	6.36e-04	0.2225	No
MeshVolume	TPI1	0.450	6.36e-04	0.2225	No
MinorAxisLength	PKM	0.429	0.0012	0.2225	No
Maximum2DDiameterColumn	TPI1	0.455	5.42e-04	0.2225	No
Maximum3DDiameter	PKM	0.423	0.0014	0.2225	No
MajorAxisLength	PKM	0.459	4.86e-04	0.2225	No
Maximum2DDiameterRow	TPI1	0.425	0.0014	0.2225	No
Maximum2DDiameterColumn	PKM	0.441	8.38e-04	0.2225	No

Il risultato è coerente tra le tre prove: TPI1 e PKM compaiono ripetutamente in associazione positiva con misure di volume, diametro o lunghezza; SurfaceVolumeRatio mostra invece una correlazione negativa con TPI1. Tuttavia, all'aumentare del numero di geni selezionati aumenta anche il numero di test e la correzione FDR diventa più severa: nessuna delle tre prove raggiunge $FDR < 0.05$.

4.2 Top 5% dei geni più variabili per IQR

In questa analisi viene selezionato il 5% dei 750 geni, pari a 38 geni. Il numero totale di correlazioni scende a 532. Questa è una delle analisi più informative del notebook perché diverse associazioni diventano significative dopo correzione FDR.

Associazioni significative nel set top 5% IQR - 16 risultati $FDR < 0.05$

Feature shape	Gene	rho	p	FDR	Sign. FDR
SurfaceVolumeRatio	TPI1	-0.431	0.0011	0.0476	Si
MinorAxisLength	TPI1	0.442	8.13e-04	0.0476	Si
Sphericity	NFKBIA	0.430	0.0012	0.0476	Si
SurfaceArea	TPI1	0.424	0.0014	0.0476	Si
MajorAxisLength	PKM	0.459	4.86e-04	0.0476	Si
Maximum3DDiameter	PKM	0.423	0.0014	0.0476	Si
MeshVolume	TPI1	0.450	6.36e-04	0.0476	Si
MinorAxisLength	PKM	0.429	0.0012	0.0476	Si
MajorAxisLength	TPI1	0.441	8.47e-04	0.0476	Si
Maximum2DDiameterColumn	TPI1	0.455	5.42e-04	0.0476	Si
Maximum2DDiameterRow	PKM	0.425	0.0014	0.0476	Si
VoxelVolume	TPI1	0.450	6.36e-04	0.0476	Si
Maximum2DDiameterRow	TPI1	0.425	0.0014	0.0476	Si
Maximum2DDiameterSlice	PKM	0.429	0.0012	0.0476	Si
Maximum2DDiameterSlice	TPI1	0.432	0.0011	0.0476	Si
Maximum2DDiameterColumn	PKM	0.441	8.38e-04	0.0476	Si

Risultato principale del top 5%

Le correlazioni significative sono dominate da TPI1 e PKM. TPI1 è associato positivamente a volume, mesh volume, superficie, diametri e assi, e negativamente a SurfaceVolumeRatio. PKM è associato positivamente a MajorAxisLength, diametri, MinorAxisLength e volume. NFKBIA mostra una correlazione positiva con Sphericity.

4.3 Soglia IQR > 1000

Il notebook prova poi una soglia assoluta sull'IQR: vengono mantenuti 76 geni con $IQR > 1000$, per un totale di 1.064 correlazioni. I segnali migliori restano simili a quelli osservati nelle analisi IQR precedenti, ma il miglior FDR è circa 0.095 e quindi non raggiunge la significatività corretta.

Top 10 con soglia $IQR > 1000$ - 76 geni, 1.064 test validi

Feature shape	Gene	rho	p	FDR	Sign. FDR
Maximum2DDiameterSlice	PKM	0.429	0.0012	0.0951	No
Sphericity	NFKBIA	0.430	0.0012	0.0951	No
SurfaceArea	TPI1	0.424	0.0014	0.0951	No
Maximum2DDiameterSlice	TPI1	0.432	0.0011	0.0951	No
Maximum2DDiameterRow	TPI1	0.425	0.0014	0.0951	No
MeshVolume	TPI1	0.450	6.36e-04	0.0951	No

Feature shape	Gene	rho	p	FDR	Sign. FDR
Maximum2DDiameterRow	PKM	0.425	0.0014	0.0951	No
MinorAxisLength	PKM	0.429	0.0012	0.0951	No
MajorAxisLength	TPI1	0.441	8.47e-04	0.0951	No
MinorAxisLength	TPI1	0.442	8.13e-04	0.0951	No

5. Correlazione top geni IQR e top feature radiomiche IQR

Poiché in questo notebook sono disponibili solo 14 feature shape, il set radiomico rimane composto da tutte le 14 feature shape. Dopo normalizzazione degli ID paziente, l'allineamento è verificato come corretto e il numero di test validi è 420.

Associazioni significative con top 30 geni IQR e feature shape - 21 risultati FDR < 0.05

Feature shape	Gene	rho	p	FDR	Sign. FDR
VoxelVolume	TPI1	0.450	6.36e-04	0.0375	Si
Sphericity	NFKBIA	0.430	0.0012	0.0375	Si
MeshVolume	TPI1	0.450	6.36e-04	0.0375	Si
SurfaceVolumeRatio	TPI1	-0.431	0.0011	0.0375	Si
Maximum2DDiameterRow	PKM	0.425	0.0014	0.0375	Si
Maximum3DDiameter	PKM	0.423	0.0014	0.0375	Si
SurfaceArea	TPI1	0.424	0.0014	0.0375	Si
Maximum2DDiameterSlice	TPI1	0.432	0.0011	0.0375	Si
Maximum2DDiameterColumn	TPI1	0.455	5.42e-04	0.0375	Si
MinorAxisLength	PKM	0.429	0.0012	0.0375	Si
Maximum2DDiameterSlice	PKM	0.429	0.0012	0.0375	Si
MinorAxisLength	TPI1	0.442	8.13e-04	0.0375	Si
MajorAxisLength	TPI1	0.441	8.47e-04	0.0375	Si
Maximum2DDiameterColumn	PKM	0.441	8.38e-04	0.0375	Si
Maximum2DDiameterRow	TPI1	0.425	0.0014	0.0375	Si
MajorAxisLength	PKM	0.459	4.86e-04	0.0375	Si
Maximum2DDiameterColumn	A2M	-0.419	0.0016	0.0402	Si
SurfaceArea	PKM	0.417	0.0017	0.0402	Si
MeshVolume	PKM	0.406	0.0023	0.0480	Si
Maximum3DDiameter	TPI1	0.405	0.0024	0.0480	Si
VoxelVolume	PKM	0.406	0.0023	0.0480	Si

Risultato principale della sezione top 30

Questa è la sezione con il miglior supporto statistico corretto: 21 associazioni superano FDR < 0.05. Anche qui le associazioni sono concentrate su TPI1 e PKM. A2M compare con correlazione negativa per Maximum2DDiameterColumn, mentre NFKBIA è associato a Sphericity. Il pattern complessivo suggerisce che le misure di dimensione tumorale siano le variabili shape più legate ai geni più variabili.

6. Analisi PCA sulle feature radiomiche e sui geni

La seconda parte dell'analisi usa la PCA per sintetizzare le informazioni radiomiche o geniche in componenti principali. L'obiettivo è ridurre la dimensionalità e poi correlare componenti principali o geni specifici, riducendo il problema di ridondanza tra feature altamente correlate.

6.1 PCA delle feature shape e correlazione con i 50 geni IQR

La prima analisi PCA prende le 14 feature shape, le standardizza e calcola 5 componenti principali. Le prime due componenti spiegano già gran parte della varianza: PC1 spiega circa il 73.3% e PC2 circa il 15.6%, arrivando insieme a circa l'88.8%.

Varianza spiegata dalle prime 5 PC radiomiche

Componente	Varianza spiegata
PC1	0.732831
PC2	0.155583
PC3	0.045696
PC4	0.031580
PC5	0.020190

Esito correlativo

Le 5 PC radiomiche sono state correlate con i 50 geni più variabili per IQR. Non sono state trovate correlazioni significative dopo FDR.

6.2 CC-PCA: riduzione di ridondanza tra feature shape

La cella successiva applica una procedura di riduzione della collinearità tra feature radiomiche. Viene calcolata la correlazione assoluta tra feature e, se due feature superano la soglia 0.90, viene eliminata quella con IQR minore. In questo modo le 14 feature iniziali vengono ridotte a 5 feature non ridondanti, sulle quali viene poi calcolata una PCA a 5 componenti.

Risultati della CC-PCA radiomica

Elemento	Risultato
Geni iniziali	56 x 750
Geni dopo filtro IQR	56 x 50
Feature radiomiche iniziali	14
Feature dopo riduzione ridondanza	5
Pazienti comuni	54
NaN totali nei dati allineati	0 nei geni, 0 nelle feature
Varianza cumulativa PC1-PC2	0.7783
Varianza cumulativa PC1-PC3	0.9039

Top 10 correlazioni PC radiomiche - geni nella CC-PCA

PC radiomica	Gene	rho	p	FDR
PC2	PKM	0.407	0.0022	0.5173
PC2	TPI1	0.384	0.0041	0.5173
PC5	PKM	-0.338	0.0124	0.6331
PC2	NFKBIA	-0.333	0.0138	0.6331
PC2	EGR1	-0.329	0.0152	0.6331

PC radiomica	Gene	rho	p	FDR
PC4	DUSP1	0.320	0.0184	0.6331
PC2	NECTIN1	0.319	0.0186	0.6331
PC2	ALDOA	0.315	0.0203	0.6331
PC2	CXCR4	-0.302	0.0263	0.6787
PC5	HLA-DRB1	0.300	0.0277	0.6787

6.3 PCA dei geni e correlazione con feature shape

In questa sezione la PCA viene applicata all'intera matrice genica. La soglia di varianza cumulativa è fissata a 0.80: per raggiungerla servono 25 componenti principali geniche. Questo indica che la variabilità genica è distribuita su molte direzioni, non concentrata in una o due componenti come accade per le feature shape.

Sintesi della varianza spiegata dalle PC geniche

PC	Varianza	Cumulativa
PC1	0.109176	0.109176
PC2	0.089616	0.198791
PC3	0.066617	0.265409
PC4	0.052689	0.318098
PC5	0.044394	0.362492
PC10	0.028801	0.533667
PC15	0.020235	0.648331
PC20	0.014934	0.733161
PC25	0.012194	0.800588

Le 25 PC geniche vengono poi correlate con le feature shape selezionate per IQR. Poiché le feature shape disponibili sono 14, il set radiomico finale resta formato da 14 feature. Il notebook riporta 54 pazienti comuni e nessuna correlazione significativa dopo FDR.

Top 10 correlazioni tra PC geniche e feature shape

PC genica	Feature shape	rho	p	FDR
PC9	Maximum2DDiameterRow	-0.325	0.0163	0.6025
PC2	Flatness	-0.324	0.0168	0.6025
PC2	LeastAxisLength	-0.320	0.0182	0.6025
PC9	Elongation	0.317	0.0194	0.6025
PC2	SurfaceVolumeRatio	0.306	0.0245	0.6025
PC9	MajorAxisLength	-0.305	0.0250	0.6025
PC1	Maximum2DDiameterColumn	0.302	0.0262	0.6025
PC2	Maximum2DDiameterRow	-0.296	0.0296	0.6025
PC5	Sphericity	-0.296	0.0299	0.6025
PC1	SurfaceVolumeRatio	-0.295	0.0301	0.6025

6.4 Correlazione tra PC radiomiche e PC geniche

L'ultima cella calcola separatamente una PCA sulle feature shape e una PCA sui geni, scegliendo automaticamente il numero di componenti necessario a superare l'80% di varianza cumulativa. Per la radiomica bastano 2 PC; per i geni servono 25 PC. Le due matrici di score vengono allineate sui 54 pazienti comuni e poi vengono correlate tutte le coppie PC radiomica - PC genica.

Top 10 correlazioni PC radiomiche - PC geniche

PC radiomica	PC genica	rho	p	FDR
PC2	PC2	-0.311	0.0222	0.4896
PC1	PC1	0.279	0.0414	0.4896
PC1	PC9	-0.270	0.0487	0.4896
PC1	PC2	-0.264	0.0535	0.4896
PC2	PC17	0.254	0.0634	0.4896
PC2	PC5	-0.243	0.0766	0.4896
PC2	PC9	0.241	0.0792	0.4896
PC1	PC18	-0.241	0.0796	0.4896
PC2	PC10	0.234	0.0881	0.4896
PC2	PC18	0.219	0.1116	0.5582

Top 20 geni driver della PC genica 2, associata alla migliore correlazione PC-PC

Gene driver PC2	Loading assoluto
CD48	0.104272
SH2D1A	0.103496
CD3E	0.097458
ITGAL	0.094319
IL2RB	0.094005
JAK3	0.093177
CD2	0.092966
CD3D	0.092785
CD6	0.091747
PDCD1	0.089431
NKG7	0.087714
GZMK	0.087136
IL21R	0.086900
LTB	0.086756
CSF2RB	0.086483
PTPRC	0.086469
KLRB1	0.086430
CD5	0.085516
CD19	0.084486
TRAT1	0.084287

7. Conclusioni

- Il dataset finale usato nelle analisi principali contiene 54 pazienti comuni, 750 geni normalizzati e 14 feature CT di shape.
- Le correlazioni più ricorrenti coinvolgono TPI1 e PKM con feature dimensionali come VoxelVolume, MeshVolume, SurfaceArea, diametri e assi.
- Nella matrice completa tutti i geni x feature shape non emergono risultati FDR significativi, nonostante alcune correlazioni non corrette abbiano $|\rho|$ vicino a 0.48.
- Le selezioni più mirate riducono il peso della correzione multipla: il top 5% per IQR produce 16 associazioni significative e l'analisi top 30 geni/top feature produce 21 associazioni significative.
- La PCA mostra che le feature shape sono fortemente ridondanti: 2 PC radiomiche superano l'80% della varianza cumulativa. Al contrario, l'espressione genica richiede 25 PC per raggiungere lo stesso livello.

- Le analisi PCA e PC-PC sono utili per sintetizzare pattern globali, ma non producono correlazioni significative dopo FDR.

Appendice - riepilogo cella per cella

Tabella riepilogativa delle celle del notebook

Cella	Tipo	Cosa fa	Risultato principale
0	Codice	Importa pandas, seaborn, matplotlib, numpy, scipy, statsmodels, networkx e math.	Nessun output.
1	Markdown	Titolo: correlazioni tra geni normalizzati e feature CT sul paziente.	Nessun output.
2	Codice	Correla tutti i 750 geni con le 14 feature shape CT.	10.500 p-value validi; nessun FDR < 0.05.
3	Markdown	Spiega la motivazione della selezione dei geni più variabili tramite IQR/varianza.	Nessun output.
4	Codice	Seleziona i top 50 geni per IQR e li correla con le feature shape.	700 test validi; miglior FDR circa 0.063.
5	Codice	Ripete l'analisi con top 100 geni per IQR.	1.400 test validi; nessun FDR significativo.
6	Codice	Ripete l'analisi con top 200 geni per IQR.	2.800 test validi; nessun FDR significativo.
7	Codice	Seleziona il 5% dei geni più variabili, pari a 38 geni.	532 test validi; 16 associazioni FDR significative.
8	Codice	Seleziona i geni con IQR > 1000.	76 geni; 1.064 test; nessun FDR significativo.
9	Codice	Seleziona i top 50 geni per coefficiente di variazione dopo il filtro di media.	Nessun FDR significativo; FDR minimo alto.
10	Codice	Correla le feature shape con un set di 11 geni scelti a priori.	Nessun FDR significativo.
11	Codice	Normalizza gli ID paziente e correla top 30 geni IQR con le feature shape.	420 test; 21 associazioni FDR significative.
12	Markdown	Titolo della sezione PCA.	Nessun output.
13	Codice	PCA sulle feature shape e correlazione delle 5 PC con top 50 geni IQR.	Figura varianza cumulativa; nessuna correlazione FDR significativa.
14	Codice	CC-PCA: rimuove feature ridondanti, calcola 5 PC e le correla con top 50 geni.	Heatmap PC-gene; nessun FDR significativo.
15	Codice	PCA sui geni e correlazione delle PC geniche con feature shape.	25 PC geniche per 80% varianza; heatmap; nessun FDR significativo.
16	Codice	Confronta PC radiomiche e PC geniche e identifica driver della PC genica più correlata.	2 PC radiomiche, 25 PC geniche; best rho = -0.311, FDR = 0.490.

Report delle analisi di pathway score e correlazioni radiogenomiche

Notebook: pathway_score_geni_normalizzati_R.ipynb e correlazioni_pathwayscore_R_feature.ipynb.

Pathway processate: 26

Criterio di significatività usato nel report: $FDR < 0,05$ dopo correzione Benjamini-Hochberg

Risultati FDR-significativi trovati: 369 correlazioni, concentrate in 8 pathway.

Nel documento sono riportate solo le associazioni con $FDR < 0,05$. Le associazioni con p_value nominale $< 0,05$ ma $FDR \geq 0,05$ non sono elencate come risultati significativi.

1. Obiettivo dell'analisi

L'obiettivo dell'analisi era costruire uno score sintetico per ciascuna pathway genomica e poi valutare se tale punteggio fosse associato alle feature radiomiche derivate da microCT, CT ex vivo e CT in vivo. Il report segue la struttura dei file prodotti: prima descrive la generazione dei pathway score, poi la pipeline di correlazione e infine riporta esclusivamente le correlazioni risultate significative dopo correzione FDR.

Il primo notebook parte dai fogli di espressione genica normalizzati in R, calcola media e deviazione standard di ciascun gene, produce valori z-score e sintetizza ogni pathway in un pathway score per paziente. Il secondo notebook allinea questi score alle feature radiomiche tramite ID numerico del paziente, calcola le correlazioni di Spearman e salva nei fogli Google i risultati con p_value, numerosità e FDR.

2. Notebook 1 - Calcolo dei pathway score

Il notebook `pathway_score_geni_normalizzati_R.ipynb` costruisce un file Google Fogli separato per ciascuna pathway. La sorgente è il foglio `geni_normalizzati_R_pathway`, nel quale ogni tab rappresenta una pathway e contiene i geni in riga e i pazienti in colonna.

- Calcolo di media e deviazione standard di ciascun gene sui pazienti disponibili.
- Normalizzazione gene-per-gene tramite z-score: $\text{valore normalizzato} = (\text{valore} - \text{media del gene}) / \text{deviazione standard del gene}$.
- Calcolo del pathway score di ciascun paziente come media dei valori z-score dei geni appartenenti alla pathway.
- Creazione del Google Foglio `geni_normalizzati_R_<pathway>` con cinque fogli iniziali: originali, `media_ds`, `normalizzati`, `pathway_score` e `pathway_score_T`.

2.1 Pathway create e dimensioni dei pannelli genici

La tabella seguente riassume le pathway effettivamente create dal primo notebook. Il numero di pazienti è 56 in tutti i pathway score esportati; il numero di geni varia molto, da pathway piccole di 5-7 geni fino alla pathway IMMUNITY con 165 geni.

Pathway	Geni	Pazienti con score	Score minimo	Score massimo
APM	7	56	-1.038	1.199
APMloss	6	56	-1.201	1.274
APOPTOSIS	5	56	-0.805	1.980
B-CELL	9	56	-0.880	2.134
CITOTOXICITY	5	56	-1.128	2.445
CYTOTOXIC CELLS	10	56	-1.150	2.366
ENDOTHELIAL CELLS	11	56	-1.146	2.807
GLYCOLITIC-ACVD	13	56	-0.786	1.469
HYPERMUTATION	10	56	-0.621	0.991
HYPOXIA	10	56	-0.913	1.089
IFN-DOWNREGULATION	20	56	-0.830	2.407
IMMUNITY	165	56	-0.605	0.774
INFLAMMATORY-CHEMOKINES	5	56	-1.016	2.105
LYMPHOID	56	56	-0.958	1.267
MAGEs	7	56	-0.386	3.418
MHC2	8	56	-0.943	1.564
MICROENVIRONMENT	39	56	-0.779	0.915
MSI-predictor	14	56	-0.694	1.057
MYELOID	42	56	-0.697	1.215
MYELOID-INFLAMMATION	10	56	-0.713	2.554

Pathway	Geni	Pazienti con score	Score minimo	Score massimo
NEUTROPHILS	7	56	-0.937	3.371
PROLIFERATION	11	56	-1.281	1.776
STROMA	6	56	-1.162	1.937
T-CELLS	5	56	-1.510	1.936
TIS	18	56	-0.770	1.459
TUMOR	55	56	-0.571	0.678

3. Notebook 2 - Correlazione tra pathway score e feature radiomiche

Il notebook correlazioni_pathwayscore_R_feature.ipynb aggiunge ai file di ciascuna pathway i fogli di correlazione. L'analisi utilizza la correlazione di Spearman, quindi valuta relazioni monotone tra il pathway score e ciascuna feature radiomica senza assumere linearità o distribuzione normale.

- Gli ID paziente vengono normalizzati estraendo la parte numerica: per esempio MICRO TC 60 diventa 60. Questo consente di allineare in modo coerente pathway score e feature radiomiche anche quando i nomi hanno formati diversi.
- Per microCT vengono considerate 56 osservazioni comuni; per CT ex vivo 50; per CT in vivo 54.
- Le analisi non-shape escludono le colonne che iniziano con original_shape. Il foglio CTinvivo_shape, invece, usa solo le feature shape della CT in vivo.
- Per ogni coppia pathway-feature vengono salvati: nome feature, rho di Spearman, p_value, N valido e FDR calcolato con metodo Benjamini-Hochberg.
- I fogli + FRR ripetono la correlazione su subset di feature selezionate nel notebook: 28 feature per microCT, 46 per CT ex vivo e 34 per CT in vivo.

3.1 Fogli di risultato e significatività osservata

Ogni riga della tabella corrisponde a un foglio di correlazione presente nei file delle pathway. La colonna "test totali" indica quante coppie pathway-feature sono state valutate complessivamente in quel foglio, considerando tutte le pathway.

Foglio	Contenuto	N comune	Test totali	FDR < 0,05	Pathway con risultati FDR-significativi
MICRO_CT	Micro CT - tutte le feature non shape	56	2418	14	PROLIFERATION, TUMOR
MICRO_CT + FRR	Micro CT - feature selezionate FRR	56	728	7	NEUTROPHILS, PROLIFERATION, TUMOR
CTexvivo	CT ex vivo - tutte le feature non shape	50	2418	0	Nessuna pathway con FDR < 0,05
CTexvivo + FRR	CT ex vivo - feature selezionate FRR	50	1196	1	TIS
CTinvivo	CT in vivo - tutte le feature non shape	54	2418	254	GLYCOLITIC-ACYD, HYPERMUTATION, HYPOXIA, MSI-predictor, PROLIFERATION, TUMOR
CTinvivo + FRR	CT in vivo - feature selezionate FRR	54	884	38	GLYCOLITIC-ACYD, MSI-predictor, PROLIFERATION, TUMOR
CTinvivo_shape	CT in vivo - sole feature di shape	54	364	55	GLYCOLITIC-ACYD, HYPERMUTATION, MSI-predictor, PROLIFERATION, TUMOR

4. Risultati principali

Applicando il filtro FDR < 0,05 sono emerse 369 correlazioni significative. Le pathway con almeno un risultato significativo sono 8: GLYCOLITIC-ACYD, HYPERMUTATION, HYPOXIA, MSI-predictor, NEUTROPHILS,

PROLIFERATION, TIS, TUMOR. Le restanti 18 pathway non hanno prodotto correlazioni FDR-significative nei fogli allegati.




Figura 2. Numero di correlazioni FDR-significative per foglio.

Il grafico mostra che la maggior parte dei risultati significativi proviene dalla CT in vivo. Il foglio CTin vivo contiene 254 associazioni significative, a cui si aggiungono 38 associazioni nel subset CTin vivo + FRR e 55 nelle feature di shape CTin vivo_shape. MicroCT produce un numero più limitato ma chiaro di risultati, mentre CT ex vivo mostra una sola associazione significativa dopo filtro FRR e nessuna nel foglio completo.




Figura 3. Distribuzione dei risultati significativi per pathway e tipologia di foglio.

La heatmap evidenzia le pathway che guidano il segnale. TUMOR, PROLIFERATION, GLYCOLITIC-ACYD e MSI-predictor sono le più ricche di risultati FDR-significativi. HYPERMUTATION e HYPOXIA mostrano risultati soprattutto in CT in vivo; NEUTROPHILS e TIS emergono ciascuna con un singolo risultato significativo in un foglio filtrato FRR.




Figura 4. Associazioni significative con rho di Spearman più alto in valore assoluto.

Le barre riportano il coefficiente rho delle venti associazioni FDR-significative più forti in valore assoluto. Valori positivi indicano che pathway score più alti si associano a feature radiomiche più alte; valori negativi indicano l'andamento opposto. Le associazioni più forti includono TUMOR e PROLIFERATION con feature microCT di busyness e non uniformità, e PROLIFERATION con feature CT in vivo a basso livello di grigio.




Figura 5. Famiglie di feature radiomiche presenti nei risultati significativi.

I risultati significativi non sono limitati a una sola famiglia: compaiono soprattutto feature GLSZM, GLCM, GLDM, shape e GLRLM, con un contributo anche di feature first-order e NGTDM. Questo suggerisce che le associazioni tra pathway score e radiomica coinvolgono sia caratteristiche di eterogeneità testurale sia misure morfologiche e di distribuzione dell'intensità.

4.1 Pathway con risultati FDR-significativi

Pathway	Totale FDR < 0,05	Positive	Negative	Distribuzione per foglio	Associazione più forte
TUMOR	81	44	37	MICRO_CT: 7; MICRO_CT + FRR: 3; CTinvivo: 51; CTinvivo + FRR: 9; CTinvivo_shape: 11	original_ngtdm_Busyness (MICRO_CT, rho=0.514, FDR=0.0047)
PROLIFERATION	78	41	37	MICRO_CT: 7; MICRO_CT + FRR: 3; CTinvivo: 44; CTinvivo + FRR: 13; CTinvivo_shape: 11	original_glrlm_ShortRunLowGrayLevelEmphasis (CTinvivo, rho=-0.501, FDR=0.0089)
GLYCOLITIC-ACYD	74	43	31	CTinvivo: 53; CTinvivo + FRR: 10; CTinvivo_shape: 11	original_glszm_LargeAreaLowGrayLevelEmphasis (CTinvivo, rho=0.489, FDR=0.0045)
MSI-predictor	66	31	35	CTinvivo: 49; CTinvivo + FRR: 6; CTinvivo_shape: 11	original_ngtdm_Coarseness (CTinvivo, rho=-0.440, FDR=0.0265)
HYPERMUTATION	45	28	17	CTinvivo: 34; CTinvivo_shape: 11	original_shape_SurfaceVolumeRatio (CTinvivo_shape, rho=-0.425, FDR=0.0121)
HYPOXIA	23	15	8	CTinvivo: 23	original_firstorder_Uniformity (CTinvivo, rho=0.436, FDR=0.0422)
NEUTROPHILS	1	1	0	MICRO_CT + FRR: 1	original_gldm_DependenceEntropy (MICRO_CT + FRR, rho=0.410, FDR=0.0473)
TIS	1	0	1	CTexvivo + FRR: 1	original_ngtdm_Strength (CTexvivo + FRR, rho=-0.456, FDR=0.0400)

4.2 Pathway senza risultati FDR-significativi

Le seguenti pathway sono state analizzate ma non presentano righe con FDR < 0,05: APM, APMloss, APOPTOSIS, B-CELL, CITOTOXICITY, CYTOTOXIC CELLS, ENDOTHELIAL CELLS, IFN-DOWNREGULATION, IMMUNITY, INFLAMMATORY-CHEMOCHINES, LYMPHOID, MAGEs, MHC2, MICROENVIRONMENT, MYELOID, MYELOID-INFLAMMATION, STROMA, T-CELLS.

4.3 Interpretazione sintetica per sorgente radiomica

MicroCT

I risultati microCT significativi sono concentrati nelle pathway TUMOR e PROLIFERATION. In entrambi i casi compaiono associazioni positive con NGTDM Busyness, GLRLM GrayLevelNonUniformity, GLSZM LargeAreaHighGrayLevelEmphasis, GLDM GrayLevelNonUniformity, GLSZM LargeAreaEmphasis e GLSZM ZoneVariance. La feature NGTDM Coarseness è invece associata negativamente. Dopo il filtro FRR rimangono soprattutto le feature di non uniformità e large-area, mentre compare anche una singola associazione per NEUTROPHILS con GLDM DependenceEntropy.

CT ex vivo

Nel foglio completo CTexvivo non sono presenti risultati FDR-significativi. Nel foglio CTexvivo + FRR emerge un unico risultato: TIS è associata negativamente a NGTDM Strength (rho = -0,456; FDR = 0,040; N = 50). Questo suggerisce un segnale puntuale nel subset selezionato, ma non una struttura diffusa di associazioni corrette per test multipli nella CT ex vivo.

CT in vivo

La CT in vivo è la sorgente con il maggior numero di correlazioni FDR-significative. Le pathway con risultati principali sono TUMOR, PROLIFERATION, GLYCOLITIC-ACYD, MSI-predictor, HYPERMUTATION e HYPOXIA. Ricorrono feature di eterogeneità e distribuzione dei livelli di grigio, tra cui GLSZM LargeAreaHighGrayLevelEmphasis, GLRLM GrayLevelNonUniformity, GLDM GrayLevelNonUniformity, GLCM JointEntropy/JointEnergy, NGTDM Coarseness e NGTDM Busyness. Le feature shape CT in vivo sono significative per TUMOR, PROLIFERATION, GLYCOLITIC-ACYD, MSI-predictor e HYPERMUTATION, con pattern ricorrenti su SurfaceVolumeRatio, Maximum2DDiameterColumn, MinorAxisLength, MeshVolume e VoxelVolume.

4.4 Feature radiomiche più ricorrenti tra i risultati significativi

Feature	N risultati	Famiglia	Pathway coinvolte	Fogli
original_glszm_LargeAreaHighGrayLevelEmphasis	14	glszm	GLYCOLITIC-ACYD, HYPERMUTATION, HYPOXIA, MSI-predictor, PROLIFERATION, TUMOR	MICRO_CT, MICRO_CT + FRR, CTin vivo, CTin vivo + FRR
original_glrlm_GrayLevelNonUniformity	10	glrlm	GLYCOLITIC-ACYD, HYPERMUTATION, HYPOXIA, MSI-predictor, PROLIFERATION, TUMOR	MICRO_CT, MICRO_CT + FRR, CTin vivo
original_glszm_LargeAreaEmphasis	10	glszm	GLYCOLITIC-ACYD, HYPERMUTATION, HYPOXIA, MSI-predictor, PROLIFERATION, TUMOR	MICRO_CT, MICRO_CT + FRR, CTin vivo
original_glcm_JointEntropy	10	glcm	GLYCOLITIC-ACYD, HYPERMUTATION, HYPOXIA, MSI-predictor, PROLIFERATION, TUMOR	CTin vivo, CTin vivo + FRR
original_gldm_SmallDependenceLowGrayLevelEmphasis	9	gldm	GLYCOLITIC-ACYD, HYPERMUTATION, MSI-predictor, PROLIFERATION, TUMOR	CTin vivo, CTin vivo + FRR
original_gldm_GrayLevelNonUniformity	8	gldm	GLYCOLITIC-ACYD, HYPERMUTATION, HYPOXIA, MSI-predictor, PROLIFERATION, TUMOR	MICRO_CT, CTin vivo
original_ngtdm_Coarseness	8	ngtdm	GLYCOLITIC-ACYD, HYPERMUTATION, HYPOXIA, MSI-predictor, PROLIFERATION, TUMOR	MICRO_CT, CTin vivo
original_glszm_ZoneVariance	8	glszm	GLYCOLITIC-ACYD, HYPERMUTATION, HYPOXIA, MSI-predictor, PROLIFERATION, TUMOR	MICRO_CT, CTin vivo
original_ngtdm_Busyness	7	ngtdm	GLYCOLITIC-ACYD, HYPERMUTATION, MSI-predictor, PROLIFERATION, TUMOR	MICRO_CT, CTin vivo
original_glszm_SizeZoneNonUniformity	7	glszm	GLYCOLITIC-ACYD, HYPERMUTATION, MSI-predictor, PROLIFERATION, TUMOR	CTin vivo, CTin vivo + FRR
original_gldm_LargeDependenceHighGrayLevelEmphasis	7	gldm	GLYCOLITIC-ACYD, MSI-predictor, PROLIFERATION, TUMOR	CTin vivo, CTin vivo + FRR
original_ngtdm_Strength	6	ngtdm	GLYCOLITIC-ACYD, HYPERMUTATION, MSI-predictor, PROLIFERATION, TIS, TUMOR	CTex vivo + FRR, CTin vivo
original_firstorder_Uniformity	6	firstorder	GLYCOLITIC-ACYD, HYPERMUTATION, HYPOXIA, MSI-predictor, PROLIFERATION, TUMOR	CTin vivo
original_glcm_JointEnergy	6	glcm	GLYCOLITIC-ACYD, HYPERMUTATION, HYPOXIA, MSI-predictor, PROLIFERATION, TUMOR	CTin vivo

Feature	N risultati	Famiglia	Pathway coinvolte	Fogli
original_firstorder_Entropy	6	firstorder	GLYCOLITIC-ACYD, HYPERMUTATION, HYPOXIA, MSI-predictor, PROLIFERATION, TUMOR	CTinvivo
original_glcmm_SumEntropy	6	glcmm	GLYCOLITIC-ACYD, HYPERMUTATION, HYPOXIA, MSI-predictor, PROLIFERATION, TUMOR	CTinvivo
original_glrmm_ShortRunEmphasis	6	glrmm	GLYCOLITIC-ACYD, HYPERMUTATION, HYPOXIA, MSI-predictor, PROLIFERATION, TUMOR	CTinvivo
original_glrmm_RunLengthNonUniformityNormalized	6	glrmm	GLYCOLITIC-ACYD, HYPERMUTATION, HYPOXIA, MSI-predictor, PROLIFERATION, TUMOR	CTinvivo
original_firstorder_Skewness	6	firstorder	GLYCOLITIC-ACYD, PROLIFERATION, TUMOR	CTinvivo, CTinvivo + FRR
original_gldmm_LowGrayLevelEmphasis	6	gldmm	MSI-predictor, PROLIFERATION, TUMOR	CTinvivo, CTinvivo + FRR

5. Risultati significativi principali per pathway

In questa sezione sono riportati i risultati più rappresentativi per ciascuna pathway significativa. L'elenco completo di tutte le righe FDR < 0,05 è riportato nell'appendice in formato tabellare.

TUMOR

Totale risultati FDR-significativi: 81 (44 correlazioni positive, 37 negative).

Foglio	Feature	rho	p_value	FDR	N
MICRO_CT	original_ngtdmm_Busyness	0.514	5.09e-05	0.0047	56
MICRO_CT	original_glrmm_GrayLevelNonUniformity	0.480	1.80e-04	0.0077	56
MICRO_CT + FRR	original_glrmm_GrayLevelNonUniformity	0.480	1.80e-04	0.0035	56
MICRO_CT	original_glszm_LargeAreaHighGrayLevelEmphasis	0.471	2.50e-04	0.0077	56
MICRO_CT + FRR	original_glszm_LargeAreaHighGrayLevelEmphasis	0.471	2.50e-04	0.0035	56
CTinvivo	original_glrmm_ShortRunLowGrayLevelEmphasis	-0.464	4.14e-04	0.0255	54
MICRO_CT	original_gldmm_GrayLevelNonUniformity	0.459	3.75e-04	0.0087	56
CTinvivo	original_gldmm_SmallDependenceLowGrayLevelEmphasis	-0.450	6.32e-04	0.0255	54
CTinvivo + FRR	original_gldmm_SmallDependenceLowGrayLevelEmphasis	-0.450	6.32e-04	0.0141	54
CTinvivo	original_gldmm_LowGrayLevelEmphasis	-0.442	8.30e-04	0.0255	54
CTinvivo + FRR	original_gldmm_LowGrayLevelEmphasis	-0.442	8.30e-04	0.0141	54
MICRO_CT	original_ngtdmm_Coarseness	-0.435	7.99e-04	0.0149	56

PROLIFERATION

Totale risultati FDR-significativi: 78 (41 correlazioni positive, 37 negative).

Foglio	Feature	rho	p_value	FDR	N
CTinvivo	original_glrIm_ShortRunLowGrayLevelEmphasis	-0.501	1.16e-04	0.0089	54
MICRO_CT	original_ngtdm_Busyness	0.498	9.49e-05	0.0067	56
MICRO_CT	original_glszm_LargeAreaHighGrayLevelEmphasis	0.486	1.45e-04	0.0067	56
MICRO_CT + FRR	original_glszm_LargeAreaHighGrayLevelEmphasis	0.486	1.45e-04	0.0034	56
CTinvivo	original_gldm_LowGrayLevelEmphasis	-0.476	2.72e-04	0.0089	54
CTinvivo + FRR	original_gldm_LowGrayLevelEmphasis	-0.476	2.72e-04	0.0080	54
CTinvivo	original_glrIm_LowGrayLevelRunEmphasis	-0.475	2.88e-04	0.0089	54
MICRO_CT	original_glrIm_GrayLevelNonUniformity	0.471	2.46e-04	0.0076	56
MICRO_CT + FRR	original_glrIm_GrayLevelNonUniformity	0.471	2.46e-04	0.0034	56
MICRO_CT	original_gldm_GrayLevelNonUniformity	0.454	4.35e-04	0.0101	56
CTinvivo	original_glszm_LowGrayLevelZoneEmphasis	-0.454	5.71e-04	0.0094	54
CTinvivo + FRR	original_glszm_LowGrayLevelZoneEmphasis	-0.454	5.71e-04	0.0080	54

GLYCOLITIC-ACYD

Totale risultati FDR-significativi: 74 (43 correlazioni positive, 31 negative).

Foglio	Feature	rho	p_value	FDR	N
CTinvivo	original_glszm_LargeAreaLowGrayLevelEmphasis	0.489	1.78e-04	0.0045	54
CTinvivo	original_glszm_LargeAreaEmphasis	0.482	2.25e-04	0.0045	54
CTinvivo	original_glszm_ZoneVariance	0.482	2.25e-04	0.0045	54
CTinvivo	original_gldm_GrayLevelNonUniformity	0.479	2.45e-04	0.0045	54
CTinvivo	original_firstorder_Uniformity	0.478	2.53e-04	0.0045	54
CTinvivo	original_glrIm_GrayLevelNonUniformity	0.475	2.87e-04	0.0045	54
CTinvivo	original_glcm_JointEnergy	0.457	5.21e-04	0.0067	54
CTinvivo	original_ngtdm_Coarseness	-0.454	5.72e-04	0.0067	54
CTinvivo	original_glcm_JointEntropy	-0.449	6.59e-04	0.0068	54
CTinvivo + FRR	original_glcm_JointEntropy	-0.449	6.59e-04	0.0139	54
CTinvivo_shape	original_shape_Maximum2DDiameterRow	0.445	7.45e-04	0.0044	54

Foglio	Feature	rho	p_value	FDR	N
CTinvivo	original_gldm_SmallDependenceLowGrayLevelEmphasis	-0.439	9.06e-04	0.0077	54

MSI-predictor

Totale risultati FDR-significativi: 66 (31 correlazioni positive, 35 negative).

Foglio	Feature	rho	p_value	FDR	N
CTinvivo	original_ngtdm_Coarseness	-0.440	8.77e-04	0.0265	54
CTinvivo	original_gldm_SmallDependenceLowGrayLevelEmphasis	-0.418	0.0016	0.0265	54
CTinvivo + FRR	original_gldm_SmallDependenceLowGrayLevelEmphasis	-0.418	0.0016	0.0323	54
CTinvivo	original_gldm_GrayLevelNonUniformity	0.418	0.0016	0.0265	54
CTinvivo	original_glrlm_GrayLevelNonUniformity	0.417	0.0017	0.0265	54
CTinvivo_shape	original_shape_SurfaceVolumeRatio	-0.416	0.0017	0.0102	54
CTinvivo	original_glszm_SmallAreaLowGrayLevelEmphasis	-0.410	0.0021	0.0265	54
CTinvivo	original_glrlm_ShortRunLowGrayLevelEmphasis	-0.406	0.0023	0.0265	54
CTinvivo	original_glszm_GrayLevelNonUniformity	0.405	0.0024	0.0265	54
CTinvivo_shape	original_shape_Maximum2DDiameterColumn	0.401	0.0027	0.0102	54
CTinvivo	original_glszm_LargeAreaHighGrayLevelEmphasis	0.397	0.0030	0.0265	54
CTinvivo + FRR	original_glszm_LargeAreaHighGrayLevelEmphasis	0.397	0.0030	0.0323	54

HYPERMUTATION

Totale risultati FDR-significativi: 45 (28 correlazioni positive, 17 negative).

Foglio	Feature	rho	p_value	FDR	N
CTinvivo_shape	original_shape_SurfaceVolumeRatio	-0.425	0.0013	0.0121	54
CTinvivo	original_ngtdm_Coarseness	-0.418	0.0016	0.0459	54
CTinvivo	original_gldm_GrayLevelNonUniformity	0.410	0.0021	0.0459	54
CTinvivo	original_glrlm_GrayLevelNonUniformity	0.404	0.0025	0.0459	54
CTinvivo_shape	original_shape_Maximum2DDiameterColumn	0.393	0.0033	0.0121	54
CTinvivo_shape	original_shape_MinorAxisLength	0.386	0.0039	0.0121	54
CTinvivo	original_glszm_LargeAreaEmphasis	0.383	0.0042	0.0459	54
CTinvivo	original_glszm_ZoneVariance	0.383	0.0042	0.0459	54

Foglio	Feature	rho	p_value	FDR	N
CTinvivo_shape	original_shape_MeshVolume	0.382	0.0043	0.0121	54
CTinvivo_shape	original_shape_VoxelVolume	0.382	0.0043	0.0121	54
CTinvivo	original_gldm_SmallDependenceLowGrayLevelEmphasis	-0.381	0.0044	0.0459	54
CTinvivo	original_ngtdm_Busyness	0.376	0.0051	0.0459	54

HYPOXIA

Totale risultati FDR-significativi: 23 (15 correlazioni positive, 8 negative).

Foglio	Feature	rho	p_value	FDR	N
CTinvivo	original_firstorder_Uniformity	0.436	9.82e-04	0.0422	54
CTinvivo	original_gldm_JointEntropy	-0.415	0.0018	0.0422	54
CTinvivo	original_gldm_JointEnergy	0.405	0.0024	0.0422	54
CTinvivo	original_gldm_SumEntropy	-0.405	0.0024	0.0422	54
CTinvivo	original_firstorder_Entropy	-0.398	0.0029	0.0422	54
CTinvivo	original_gldm_DependenceNonUniformityNormalized	-0.398	0.0029	0.0422	54
CTinvivo	original_gldm_RunPercentage	-0.381	0.0045	0.0422	54
CTinvivo	original_gldm_GrayLevelNonUniformity	0.378	0.0049	0.0422	54
CTinvivo	original_gldm_Id	0.376	0.0051	0.0422	54
CTinvivo	original_gldm_Idm	0.375	0.0052	0.0422	54
CTinvivo	original_gldm_GrayLevelNonUniformityNormalized	0.365	0.0067	0.0422	54
CTinvivo	original_gldm_LargeAreaEmphasis	0.365	0.0067	0.0422	54

NEUTROPHILS

Totale risultati FDR-significativi: 1 (1 correlazioni positive, 0 negative).

Foglio	Feature	rho	p_value	FDR	N
MICRO_CT + FRR	original_gldm_DependenceEntropy	0.410	0.0017	0.0473	56

TIS

Totale risultati FDR-significativi: 1 (0 correlazioni positive, 1 negative).

Foglio	Feature	rho	p_value	FDR	N
CTexvivo + FRR	original_ngtdm_Strength	-0.456	8.69e-04	0.0400	50

Appendice A - Elenco completo dei risultati significativi

Le tabelle dell'appendice contengono tutte e sole le righe dei fogli allegati con FDR < 0,05. I risultati sono ordinati per foglio, pathway e FDR crescente. I valori rho positivi indicano associazione diretta; i valori rho negativi associazione inversa.

MICRO_CT - Micro CT - tutte le feature non shape

Pathway	Feature	rho	p_value	FDR	N
PROLIFERATION	original_ngtdm_Busyness	0.498	9.49e-05	0.0067	56
PROLIFERATION	original_glszm_LargeAreaHighGrayLevelEmphasis	0.486	1.45e-04	0.0067	56
PROLIFERATION	original_glrlm_GrayLevelNonUniformity	0.471	2.46e-04	0.0076	56
PROLIFERATION	original_gldm_GrayLevelNonUniformity	0.454	4.35e-04	0.0101	56
PROLIFERATION	original_ngtdm_Coarseness	-0.433	8.67e-04	0.0161	56
PROLIFERATION	original_glszm_LargeAreaEmphasis	0.386	0.0033	0.0442	56
PROLIFERATION	original_glszm_ZoneVariance	0.386	0.0033	0.0442	56
TUMOR	original_ngtdm_Busyness	0.514	5.09e-05	0.0047	56
TUMOR	original_glrlm_GrayLevelNonUniformity	0.480	1.80e-04	0.0077	56
TUMOR	original_glszm_LargeAreaHighGrayLevelEmphasis	0.471	2.50e-04	0.0077	56
TUMOR	original_gldm_GrayLevelNonUniformity	0.459	3.75e-04	0.0087	56
TUMOR	original_ngtdm_Coarseness	-0.435	7.99e-04	0.0149	56
TUMOR	original_glszm_LargeAreaEmphasis	0.385	0.0034	0.0450	56
TUMOR	original_glszm_ZoneVariance	0.385	0.0034	0.0450	56

MICRO_CT + FRR - Micro CT - feature selezionate FRR

Pathway	Feature	rho	p_value	FDR	N
NEUTROPHILS	original_gldm_DependenceEntropy	0.410	0.0017	0.0473	56
PROLIFERATION	original_glszm_LargeAreaHighGrayLevelEmphasis	0.486	1.45e-04	0.0034	56
PROLIFERATION	original_glrlm_GrayLevelNonUniformity	0.471	2.46e-04	0.0034	56
PROLIFERATION	original_glszm_LargeAreaEmphasis	0.386	0.0033	0.0310	56

Pathway	Feature	rho	p_value	FDR	N
TUMOR	original_glrIm_GrayLevelNonUniformity	0.480	1.80e-04	0.0035	56
TUMOR	original_glszm_LargeAreaHighGrayLevelEmphasis	0.471	2.50e-04	0.0035	56
TUMOR	original_glszm_LargeAreaEmphasis	0.385	0.0034	0.0316	56

CTexvivo + FRR - CT ex vivo - feature selezionate FRR

Pathway	Feature	rho	p_value	FDR	N
TIS	original_ngtdm_Strength	-0.456	8.69e-04	0.0400	50

CTinvivo - CT in vivo - tutte le feature non shape

Pathway	Feature	rho	p_value	FDR	N
GLYCOLITIC-ACYD	original_glszm_LargeAreaLowGrayLevelEmphasis	0.489	1.78e-04	0.0045	54
GLYCOLITIC-ACYD	original_glszm_LargeAreaEmphasis	0.482	2.25e-04	0.0045	54
GLYCOLITIC-ACYD	original_glszm_ZoneVariance	0.482	2.25e-04	0.0045	54
GLYCOLITIC-ACYD	original_gldm_GrayLevelNonUniformity	0.479	2.45e-04	0.0045	54
GLYCOLITIC-ACYD	original_firstorder_Uniformity	0.478	2.53e-04	0.0045	54
GLYCOLITIC-ACYD	original_glrIm_GrayLevelNonUniformity	0.475	2.87e-04	0.0045	54
GLYCOLITIC-ACYD	original_glcM_JointEnergy	0.457	5.21e-04	0.0067	54
GLYCOLITIC-ACYD	original_ngtdm_Coarseness	-0.454	5.72e-04	0.0067	54
GLYCOLITIC-ACYD	original_glcM_JointEntropy	-0.449	6.59e-04	0.0068	54
GLYCOLITIC-ACYD	original_gldm_SmallDependenceLowGrayLevelEmphasis	-0.439	9.06e-04	0.0077	54
GLYCOLITIC-ACYD	original_glcM_Id	0.435	0.0010	0.0077	54
GLYCOLITIC-ACYD	original_glcM_Idm	0.430	0.0012	0.0077	54
GLYCOLITIC-ACYD	original_glszm_LargeAreaHighGrayLevelEmphasis	0.428	0.0012	0.0077	54
GLYCOLITIC-ACYD	original_glrIm_RunPercentage	-0.428	0.0012	0.0077	54
GLYCOLITIC-ACYD	original_ngtdm_Busyness	0.427	0.0013	0.0077	54
GLYCOLITIC-ACYD	original_firstorder_Entropy	-0.424	0.0014	0.0077	54
GLYCOLITIC-ACYD	original_glcM_DifferenceEntropy	-0.421	0.0015	0.0077	54
GLYCOLITIC-ACYD	original_glcM_Idn	0.420	0.0016	0.0077	54

Pathway	Feature	rho	p_value	FDR	N
GLYCOLITIC-ACYD	original_glrIm_RunLengthNonUniformity	0.419	0.0016	0.0077	54
GLYCOLITIC-ACYD	original_glcM_DifferenceAverage	-0.418	0.0017	0.0077	54
GLYCOLITIC-ACYD	original_glcM_SumEntropy	-0.416	0.0018	0.0078	54
GLYCOLITIC-ACYD	original_glcM_MaximumProbability	0.413	0.0019	0.0078	54
GLYCOLITIC-ACYD	original_glrIm_LongRunEmphasis	0.412	0.0019	0.0078	54
GLYCOLITIC-ACYD	original_glszm_GrayLevelNonUniformity	0.408	0.0022	0.0085	54
GLYCOLITIC-ACYD	original_glrIm_RunVariance	0.404	0.0024	0.0091	54
GLYCOLITIC-ACYD	original_gldm_DependenceNonUniformity	0.403	0.0025	0.0091	54
GLYCOLITIC-ACYD	original_glrIm_ShortRunEmphasis	-0.400	0.0027	0.0095	54
GLYCOLITIC-ACYD	original_ngtdm_Strength	-0.398	0.0029	0.0095	54
GLYCOLITIC-ACYD	original_gldm_DependenceNonUniformityNormalized	-0.396	0.0030	0.0095	54
GLYCOLITIC-ACYD	original_glrIm_RunLengthNonUniformityNormalized	-0.396	0.0031	0.0095	54
GLYCOLITIC-ACYD	original_glrIm_GrayLevelNonUniformityNormalized	0.392	0.0033	0.0098	54
GLYCOLITIC-ACYD	original_gldm_SmallDependenceEmphasis	-0.392	0.0034	0.0098	54
GLYCOLITIC-ACYD	original_gldm_LargeDependenceEmphasis	0.389	0.0037	0.0102	54
GLYCOLITIC-ACYD	original_glszm_ZonePercentage	-0.388	0.0037	0.0102	54
GLYCOLITIC-ACYD	original_glcM_Contrast	-0.386	0.0040	0.0106	54
GLYCOLITIC-ACYD	original_glszm_SmallAreaLowGrayLevelEmphasis	-0.383	0.0043	0.0110	54
GLYCOLITIC-ACYD	original_glcM_Idmn	0.380	0.0046	0.0116	54
GLYCOLITIC-ACYD	original_ngtdm_Contrast	-0.376	0.0050	0.0123	54
GLYCOLITIC-ACYD	original_glcM_DifferenceVariance	-0.359	0.0078	0.0185	54
GLYCOLITIC-ACYD	original_gldm_LargeDependenceLowGrayLevelEmphasis	0.358	0.0079	0.0185	54
GLYCOLITIC-ACYD	original_firstorder_Skewness	-0.354	0.0087	0.0196	54
GLYCOLITIC-ACYD	original_glszm_SizeZoneNonUniformity	0.351	0.0093	0.0207	54
GLYCOLITIC-ACYD	original_glrIm_LongRunHighGrayLevelEmphasis	0.348	0.0099	0.0213	54
GLYCOLITIC-ACYD	original_ngtdm_Complexity	-0.344	0.0108	0.0228	54

Pathway	Feature	rho	p_value	FDR	N
GLYCOLITIC-ACYD	original_gldm_SmallDependenceHighGrayLevelEmphasis	-0.343	0.0111	0.0230	54
GLYCOLITIC-ACYD	original_gldm_LargeDependenceHighGrayLevelEmphasis	0.342	0.0114	0.0231	54
GLYCOLITIC-ACYD	original_gldm_DependenceVariance	0.319	0.0187	0.0370	54
GLYCOLITIC-ACYD	original_glrlm_ShortRunLowGrayLevelEmphasis	-0.318	0.0191	0.0370	54
GLYCOLITIC-ACYD	original_firstorder_Median	0.314	0.0206	0.0391	54
GLYCOLITIC-ACYD	original_firstorder_Kurtosis	0.311	0.0222	0.0413	54
GLYCOLITIC-ACYD	original_glszm_GrayLevelVariance	-0.307	0.0237	0.0433	54
GLYCOLITIC-ACYD	original_gldm_SumSquares	-0.306	0.0246	0.0439	54
GLYCOLITIC-ACYD	original_firstorder_InterquartileRange	-0.298	0.0284	0.0497	54
HYPERMUTATION	original_ngtdm_Coarseness	-0.418	0.0016	0.0459	54
HYPERMUTATION	original_gldm_GrayLevelNonUniformity	0.410	0.0021	0.0459	54
HYPERMUTATION	original_glrlm_GrayLevelNonUniformity	0.404	0.0025	0.0459	54
HYPERMUTATION	original_glszm_LargeAreaEmphasis	0.383	0.0042	0.0459	54
HYPERMUTATION	original_glszm_ZoneVariance	0.383	0.0042	0.0459	54
HYPERMUTATION	original_gldm_SmallDependenceLowGrayLevelEmphasis	-0.381	0.0044	0.0459	54
HYPERMUTATION	original_ngtdm_Busyness	0.376	0.0051	0.0459	54
HYPERMUTATION	original_glszm_LargeAreaLowGrayLevelEmphasis	0.375	0.0052	0.0459	54
HYPERMUTATION	original_glszm_LargeAreaHighGrayLevelEmphasis	0.372	0.0057	0.0459	54
HYPERMUTATION	original_glszm_GrayLevelNonUniformity	0.363	0.0069	0.0459	54
HYPERMUTATION	original_gldm_DependenceNonUniformity	0.362	0.0071	0.0459	54
HYPERMUTATION	original_glrlm_RunPercentage	-0.361	0.0073	0.0459	54
HYPERMUTATION	original_firstorder_Uniformity	0.361	0.0074	0.0459	54
HYPERMUTATION	original_glrlm_RunLengthNonUniformity	0.356	0.0082	0.0459	54
HYPERMUTATION	original_ngtdm_Strength	-0.354	0.0086	0.0459	54
HYPERMUTATION	original_glrlm_ShortRunEmphasis	-0.354	0.0087	0.0459	54

Pathway	Feature	rho	p_value	FDR	N
HYPERMUTATION	original_glcM_Idm	0.350	0.0095	0.0459	54
HYPERMUTATION	original_glrIm_ShortRunLowGrayLevelEmphasis	-0.350	0.0095	0.0459	54
HYPERMUTATION	original_glrIm_RunLengthNonUniformityNormalized	-0.349	0.0096	0.0459	54
HYPERMUTATION	original_glszm_SmallAreaLowGrayLevelEmphasis	-0.348	0.0100	0.0459	54
HYPERMUTATION	original_gldm_SmallDependenceEmphasis	-0.345	0.0105	0.0459	54
HYPERMUTATION	original_glcM_JointEntropy	-0.344	0.0109	0.0459	54
HYPERMUTATION	original_glcM_Id	0.342	0.0114	0.0459	54
HYPERMUTATION	original_glszm_ZonePercentage	-0.334	0.0135	0.0464	54
HYPERMUTATION	original_glrIm_LongRunEmphasis	0.334	0.0135	0.0464	54
HYPERMUTATION	original_firstorder_Entropy	-0.334	0.0136	0.0464	54
HYPERMUTATION	original_glcM_JointEnergy	0.333	0.0139	0.0464	54
HYPERMUTATION	original_glcM_Idn	0.333	0.0140	0.0464	54
HYPERMUTATION	original_glcM_SumEntropy	-0.328	0.0155	0.0472	54
HYPERMUTATION	original_glcM_DifferenceAverage	-0.328	0.0155	0.0472	54
HYPERMUTATION	original_gldm_DependenceNonUniformityNormalized	-0.326	0.0162	0.0472	54
HYPERMUTATION	original_gldm_LargeDependenceEmphasis	0.326	0.0162	0.0472	54
HYPERMUTATION	original_glszm_SizeZoneNonUniformity	0.324	0.0169	0.0477	54
HYPERMUTATION	original_glcM_DifferenceEntropy	-0.322	0.0177	0.0485	54
HYPOXIA	original_firstorder_Uniformity	0.436	9.82e-04	0.0422	54
HYPOXIA	original_glcM_JointEntropy	-0.415	0.0018	0.0422	54
HYPOXIA	original_glcM_JointEnergy	0.405	0.0024	0.0422	54
HYPOXIA	original_glcM_SumEntropy	-0.405	0.0024	0.0422	54
HYPOXIA	original_firstorder_Entropy	-0.398	0.0029	0.0422	54
HYPOXIA	original_gldm_DependenceNonUniformityNormalized	-0.398	0.0029	0.0422	54
HYPOXIA	original_glrIm_RunPercentage	-0.381	0.0045	0.0422	54
HYPOXIA	original_gldm_GrayLevelNonUniformity	0.378	0.0049	0.0422	54
HYPOXIA	original_glcM_Id	0.376	0.0051	0.0422	54
HYPOXIA	original_glcM_Idm	0.375	0.0052	0.0422	54

Pathway	Feature	rho	p_value	FDR	N
HYPOXIA	original_glrIm_GrayLevelNonUniformityNormalized	0.365	0.0067	0.0422	54
HYPOXIA	original_glszm_LargeAreaEmphasis	0.365	0.0067	0.0422	54
HYPOXIA	original_glszm_ZoneVariance	0.365	0.0067	0.0422	54
HYPOXIA	original_glrIm_GrayLevelNonUniformity	0.361	0.0073	0.0422	54
HYPOXIA	original_gldm_MaximumProbability	0.358	0.0079	0.0422	54
HYPOXIA	original_glszm_LargeAreaLowGrayLevelEmphasis	0.356	0.0083	0.0422	54
HYPOXIA	original_glrIm_LongRunEmphasis	0.354	0.0087	0.0422	54
HYPOXIA	original_glrIm_ShortRunEmphasis	-0.353	0.0089	0.0422	54
HYPOXIA	original_ngtdm_Coarseness	-0.352	0.0089	0.0422	54
HYPOXIA	original_gldm_LargeDependenceEmphasis	0.349	0.0097	0.0422	54
HYPOXIA	original_glrIm_RunLengthNonUniformityNormalized	-0.348	0.0099	0.0422	54
HYPOXIA	original_glrIm_RunVariance	0.348	0.0100	0.0422	54
HYPOXIA	original_glszm_LargeAreaHighGrayLevelEmphasis	0.340	0.0118	0.0479	54
MSI-predictor	original_ngtdm_Coarseness	-0.440	8.77e-04	0.0265	54
MSI-predictor	original_gldm_SmallDependenceLowGrayLevelEmphasis	-0.418	0.0016	0.0265	54
MSI-predictor	original_gldm_GrayLevelNonUniformity	0.418	0.0016	0.0265	54
MSI-predictor	original_glrIm_GrayLevelNonUniformity	0.417	0.0017	0.0265	54
MSI-predictor	original_glszm_SmallAreaLowGrayLevelEmphasis	-0.410	0.0021	0.0265	54
MSI-predictor	original_glrIm_ShortRunLowGrayLevelEmphasis	-0.406	0.0023	0.0265	54
MSI-predictor	original_glszm_GrayLevelNonUniformity	0.405	0.0024	0.0265	54
MSI-predictor	original_glszm_LargeAreaHighGrayLevelEmphasis	0.397	0.0030	0.0265	54
MSI-predictor	original_firstorder_Uniformity	0.385	0.0040	0.0265	54
MSI-predictor	original_ngtdm_Strength	-0.384	0.0041	0.0265	54
MSI-predictor	original_ngtdm_Busyness	0.381	0.0045	0.0265	54
MSI-predictor	original_glszm_GrayLevelVariance	-0.378	0.0048	0.0265	54

Pathway	Feature	rho	p_value	FDR	N
MSI-predictor	original_glszm_LargeAreaEmphasis	0.377	0.0050	0.0265	54
MSI-predictor	original_glszm_ZoneVariance	0.377	0.0050	0.0265	54
MSI-predictor	original_gldm_LowGrayLevelEmphasis	-0.377	0.0050	0.0265	54
MSI-predictor	original_glcmm_SumEntropy	-0.376	0.0050	0.0265	54
MSI-predictor	original_firstorder_Entropy	-0.376	0.0051	0.0265	54
MSI-predictor	original_glszm_LowGrayLevelZoneEmphasis	-0.374	0.0053	0.0265	54
MSI-predictor	original_glrlm_LowGrayLevelRunEmphasis	-0.373	0.0054	0.0265	54
MSI-predictor	original_glcmm_JointEntropy	-0.371	0.0057	0.0265	54
MSI-predictor	original_glrlm_RunLengthNonUniformity	0.367	0.0063	0.0274	54
MSI-predictor	original_gldm_DependenceNonUniformity	0.366	0.0065	0.0274	54
MSI-predictor	original_glrlm_GrayLevelNonUniformityNormalized	0.363	0.0071	0.0285	54
MSI-predictor	original_glrlm_ShortRunEmphasis	-0.358	0.0079	0.0302	54
MSI-predictor	original_glrlm_RunLengthNonUniformityNormalized	-0.357	0.0081	0.0302	54
MSI-predictor	original_gldm_SmallDependenceEmphasis	-0.344	0.0108	0.0346	54
MSI-predictor	original_glszm_LargeAreaLowGrayLevelEmphasis	0.344	0.0110	0.0346	54
MSI-predictor	original_firstorder_InterquartileRange	-0.341	0.0116	0.0346	54
MSI-predictor	original_glcmm_DifferenceAverage	-0.340	0.0118	0.0346	54
MSI-predictor	original_glcmm_DifferenceEntropy	-0.339	0.0122	0.0346	54
MSI-predictor	original_glcmm_Idn	0.338	0.0125	0.0346	54
MSI-predictor	original_glszm_SizeZoneNonUniformity	0.337	0.0126	0.0346	54
MSI-predictor	original_ngtdm_Contrast	-0.336	0.0131	0.0346	54
MSI-predictor	original_glcmm_SumSquares	-0.335	0.0132	0.0346	54
MSI-predictor	original_glszm_ZonePercentage	-0.335	0.0132	0.0346	54
MSI-predictor	original_glrlm_RunPercentage	-0.333	0.0138	0.0346	54
MSI-predictor	original_gldm_GrayLevelVariance	-0.333	0.0140	0.0346	54

Pathway	Feature	rho	p_value	FDR	N
MSI-predictor	original_glcmldm	0.331	0.0146	0.0346	54
MSI-predictor	original_firstorder_Kurtosis	0.330	0.0147	0.0346	54
MSI-predictor	original_gldm_DependenceNonUniformityNormalized	-0.330	0.0149	0.0346	54
MSI-predictor	original_firstorder_RobustMeanAbsoluteDeviation	-0.326	0.0161	0.0365	54
MSI-predictor	original_glcmldmn	0.323	0.0173	0.0369	54
MSI-predictor	original_glcml_Contrast	-0.323	0.0174	0.0369	54
MSI-predictor	original_glcml_Id	0.322	0.0175	0.0369	54
MSI-predictor	original_glcml_DifferenceVariance	-0.315	0.0203	0.0419	54
MSI-predictor	original_glcml_ClusterTendency	-0.314	0.0209	0.0422	54
MSI-predictor	original_glcml_JointEnergy	0.310	0.0224	0.0444	54
MSI-predictor	original_glrml_GrayLevelVariance	-0.309	0.0232	0.0450	54
MSI-predictor	original_gldm_LargeDependenceHighGrayLevelEmphasis	0.305	0.0250	0.0474	54
PROLIFERATION	original_glrml_ShortRunLowGrayLevelEmphasis	-0.501	1.16e-04	0.0089	54
PROLIFERATION	original_gldm_LowGrayLevelEmphasis	-0.476	2.72e-04	0.0089	54
PROLIFERATION	original_glrml_LowGrayLevelRunEmphasis	-0.475	2.88e-04	0.0089	54
PROLIFERATION	original_glszm_LowGrayLevelZoneEmphasis	-0.454	5.71e-04	0.0094	54
PROLIFERATION	original_ngtdm_Coarseness	-0.447	6.94e-04	0.0094	54
PROLIFERATION	original_gldm_SmallDependenceLowGrayLevelEmphasis	-0.447	7.06e-04	0.0094	54
PROLIFERATION	original_ngtdm_Strength	-0.447	7.11e-04	0.0094	54
PROLIFERATION	original_glszm_GrayLevelNonUniformity	0.438	9.29e-04	0.0108	54
PROLIFERATION	original_glrml_GrayLevelNonUniformity	0.430	0.0012	0.0110	54
PROLIFERATION	original_glcml_SumEntropy	-0.422	0.0015	0.0110	54
PROLIFERATION	original_glszm_SmallAreaLowGrayLevelEmphasis	-0.421	0.0015	0.0110	54
PROLIFERATION	original_firstorder_RobustMeanAbsoluteDeviation	-0.416	0.0018	0.0110	54
PROLIFERATION	original_firstorder_InterquartileRange	-0.416	0.0018	0.0110	54
PROLIFERATION	original_firstorder_Uniformity	0.415	0.0018	0.0110	54
PROLIFERATION	original_firstorder_Median	0.414	0.0018	0.0110	54

Pathway	Feature	rho	p_value	FDR	N
PROLIFERATION	original_gldm_GrayLevelNonUniformity	0.413	0.0019	0.0110	54
PROLIFERATION	original_glszm_SizeZoneNonUniformity	0.410	0.0021	0.0110	54
PROLIFERATION	original_firstorder_Mean	0.409	0.0022	0.0110	54
PROLIFERATION	original_glszm_LargeAreaHighGrayLevelEmphasis	0.405	0.0024	0.0110	54
PROLIFERATION	original_firstorder_RootMeanSquared	-0.405	0.0024	0.0110	54
PROLIFERATION	original_firstorder_Entropy	-0.402	0.0026	0.0113	54
PROLIFERATION	original_firstorder_10Percentile	0.400	0.0028	0.0117	54
PROLIFERATION	original_glrlm_RunLengthNonUniformity	0.394	0.0032	0.0131	54
PROLIFERATION	original_firstorder_Skewness	-0.387	0.0039	0.0150	54
PROLIFERATION	original_glrlm_GrayLevelNonUniformityNormalized	0.384	0.0041	0.0154	54
PROLIFERATION	original_gldm_SumSquares	-0.379	0.0047	0.0167	54
PROLIFERATION	original_gldm_JointEntropy	-0.376	0.0050	0.0170	54
PROLIFERATION	original_gldm_LargeDependenceHighGrayLevelEmphasis	0.376	0.0051	0.0170	54
PROLIFERATION	original_firstorder_MeanAbsoluteDeviation	-0.374	0.0054	0.0171	54
PROLIFERATION	original_gldm_DependenceNonUniformity	0.373	0.0055	0.0171	54
PROLIFERATION	original_glrlm_LongRunHighGrayLevelEmphasis	0.366	0.0065	0.0187	54
PROLIFERATION	original_ngtdm_Busyness	0.365	0.0067	0.0187	54
PROLIFERATION	original_glszm_GrayLevelVariance	-0.364	0.0068	0.0187	54
PROLIFERATION	original_gldm_ClusterTendency	-0.364	0.0068	0.0187	54
PROLIFERATION	original_firstorder_Variance	-0.346	0.0104	0.0276	54
PROLIFERATION	original_glszm_ZoneVariance	0.343	0.0111	0.0278	54
PROLIFERATION	original_glszm_LargeAreaEmphasis	0.343	0.0111	0.0278	54
PROLIFERATION	original_gldm_GrayLevelVariance	-0.341	0.0117	0.0287	54
PROLIFERATION	original_gldm_JointEnergy	0.338	0.0123	0.0294	54
PROLIFERATION	original_gldm_ClusterProminence	-0.333	0.0137	0.0319	54
PROLIFERATION	original_ngtdm_Contrast	-0.320	0.0183	0.0411	54

Pathway	Feature	rho	p_value	FDR	N
PROLIFERATION	original_gldm_DependenceEntropy	-0.319	0.0185	0.0411	54
PROLIFERATION	original_glrlm_ShortRunEmphasis	-0.312	0.0217	0.0469	54
PROLIFERATION	original_glrlm_RunLengthNonUniformityNormalized	-0.311	0.0222	0.0469	54
TUMOR	original_glrlm_ShortRunLowGrayLevelEmphasis	-0.464	4.14e-04	0.0255	54
TUMOR	original_gldm_SmallDependenceLowGrayLevelEmphasis	-0.450	6.32e-04	0.0255	54
TUMOR	original_gldm_LowGrayLevelEmphasis	-0.442	8.30e-04	0.0255	54
TUMOR	original_glrlm_LowGrayLevelRunEmphasis	-0.427	0.0013	0.0255	54
TUMOR	original_firstorder_Uniformity	0.411	0.0020	0.0255	54
TUMOR	original_ngtdm_Coarseness	-0.404	0.0025	0.0255	54
TUMOR	original_gldm_SumEntropy	-0.403	0.0025	0.0255	54
TUMOR	original_gldm_GrayLevelNonUniformity	0.395	0.0031	0.0255	54
TUMOR	original_glrlm_GrayLevelNonUniformity	0.395	0.0031	0.0255	54
TUMOR	original_firstorder_Entropy	-0.392	0.0034	0.0255	54
TUMOR	original_firstorder_RobustMeanAbsoluteDeviation	-0.389	0.0037	0.0255	54
TUMOR	original_firstorder_InterquartileRange	-0.387	0.0039	0.0255	54
TUMOR	original_glszm_LargeAreaHighGrayLevelEmphasis	0.384	0.0042	0.0255	54
TUMOR	original_firstorder_RootMeanSquared	-0.383	0.0042	0.0255	54
TUMOR	original_glrlm_LongRunHighGrayLevelEmphasis	0.381	0.0044	0.0255	54
TUMOR	original_glszm_LowGrayLevelZoneEmphasis	-0.377	0.0050	0.0255	54
TUMOR	original_gldm_JointEntropy	-0.376	0.0051	0.0255	54
TUMOR	original_firstorder_10Percentile	0.374	0.0053	0.0255	54
TUMOR	original_glszm_SmallAreaLowGrayLevelEmphasis	-0.373	0.0054	0.0255	54
TUMOR	original_gldm_LargeDependenceHighGrayLevelEmphasis	0.371	0.0057	0.0255	54
TUMOR	original_ngtdm_Strength	-0.371	0.0057	0.0255	54
TUMOR	original_firstorder_Mean	0.362	0.0072	0.0281	54

Pathway	Feature	rho	p_value	FDR	N
TUMOR	original_glszm_LargeAreaEmphasis	0.361	0.0073	0.0281	54
TUMOR	original_glszm_ZoneVariance	0.361	0.0073	0.0281	54
TUMOR	original_firstorder_MeanAbsoluteDeviation	-0.358	0.0078	0.0290	54
TUMOR	original_firstorder_Median	0.355	0.0084	0.0302	54
TUMOR	original_glrlm_GrayLevelNonUniformityNormalized	0.352	0.0090	0.0302	54
TUMOR	original_gldm_JointEnergy	0.352	0.0091	0.0302	54
TUMOR	original_gldm_SumSquares	-0.347	0.0102	0.0319	54
TUMOR	original_firstorder_Skewness	-0.346	0.0103	0.0319	54
TUMOR	original_gldm_DependenceNonUniformity	0.341	0.0117	0.0347	54
TUMOR	original_glszm_GrayLevelNonUniformity	0.337	0.0127	0.0347	54
TUMOR	original_firstorder_Variance	-0.336	0.0129	0.0347	54
TUMOR	original_glrlm_RunLengthNonUniformity	0.336	0.0130	0.0347	54
TUMOR	original_ngtdm_Busyness	0.336	0.0131	0.0347	54
TUMOR	original_glrlm_ShortRunEmphasis	-0.333	0.0138	0.0357	54
TUMOR	original_glrlm_RunLengthNonUniformityNormalized	-0.330	0.0147	0.0370	54
TUMOR	original_glszm_LargeAreaLowGrayLevelEmphasis	0.327	0.0160	0.0380	54
TUMOR	original_glrlm_RunPercentage	-0.327	0.0160	0.0380	54
TUMOR	original_ngtdm_Contrast	-0.324	0.0169	0.0392	54
TUMOR	original_gldm_Id	0.321	0.0179	0.0398	54
TUMOR	original_gldm_Idm	0.321	0.0180	0.0398	54
TUMOR	original_gldm_ClusterTendency	-0.320	0.0185	0.0398	54
TUMOR	original_gldm_DifferenceEntropy	-0.319	0.0188	0.0398	54
TUMOR	original_gldm_DifferenceAverage	-0.315	0.0205	0.0423	54
TUMOR	original_gldm_Idn	0.312	0.0216	0.0430	54
TUMOR	original_gldm_GrayLevelVariance	-0.312	0.0217	0.0430	54
TUMOR	original_glszm_ZonePercentage	-0.308	0.0232	0.0450	54
TUMOR	original_gldm_SmallDependenceEmphasis	-0.307	0.0239	0.0453	54

Pathway	Feature	rho	p_value	FDR	N
TUMOR	original_glszm_SizeZoneNonUniformity	0.303	0.0261	0.0479	54
TUMOR	original_gldm_DependenceNonUniformityNormalized	-0.302	0.0263	0.0479	54

CTin vivo + FRR - CT in vivo - feature selezionate FRR

Pathway	Feature	rho	p_value	FDR	N
GLYCOLITIC-ACYD	original_glcmm_JointEntropy	-0.449	6.59e-04	0.0139	54
GLYCOLITIC-ACYD	original_gldm_SmallDependenceLowGrayLevelEmphasis	-0.439	9.06e-04	0.0139	54
GLYCOLITIC-ACYD	original_glszm_LargeAreaHighGrayLevelEmphasis	0.428	0.0012	0.0139	54
GLYCOLITIC-ACYD	original_gldm_LargeDependenceEmphasis	0.389	0.0037	0.0271	54
GLYCOLITIC-ACYD	original_glcmm_Contrast	-0.386	0.0040	0.0271	54
GLYCOLITIC-ACYD	original_gldm_LargeDependenceLowGrayLevelEmphasis	0.358	0.0079	0.0389	54
GLYCOLITIC-ACYD	original_firstorder_Skewness	-0.354	0.0087	0.0389	54
GLYCOLITIC-ACYD	original_glszm_SizeZoneNonUniformity	0.351	0.0093	0.0389	54
GLYCOLITIC-ACYD	original_ngtdm_Complexity	-0.344	0.0108	0.0389	54
GLYCOLITIC-ACYD	original_gldm_LargeDependenceHighGrayLevelEmphasis	0.342	0.0114	0.0389	54
MSI-predictor	original_gldm_SmallDependenceLowGrayLevelEmphasis	-0.418	0.0016	0.0323	54
MSI-predictor	original_glszm_LargeAreaHighGrayLevelEmphasis	0.397	0.0030	0.0323	54
MSI-predictor	original_glszm_GrayLevelVariance	-0.378	0.0048	0.0323	54
MSI-predictor	original_gldm_LowGrayLevelEmphasis	-0.377	0.0050	0.0323	54
MSI-predictor	original_glszm_LowGrayLevelZoneEmphasis	-0.374	0.0053	0.0323	54
MSI-predictor	original_glcmm_JointEntropy	-0.371	0.0057	0.0323	54
PROLIFERATION	original_gldm_LowGrayLevelEmphasis	-0.476	2.72e-04	0.0080	54
PROLIFERATION	original_glszm_LowGrayLevelZoneEmphasis	-0.454	5.71e-04	0.0080	54
PROLIFERATION	original_gldm_SmallDependenceLowGrayLevelEmphasis	-0.447	7.06e-04	0.0080	54
PROLIFERATION	original_firstorder_Median	0.414	0.0018	0.0134	54
PROLIFERATION	original_glszm_SizeZoneNonUniformity	0.410	0.0021	0.0134	54

Pathway	Feature	rho	p_value	FDR	N
PROLIFERATION	original_glszm_LargeAreaHighGrayLevelEmphasis	0.405	0.0024	0.0134	54
PROLIFERATION	original_firstorder_Skewness	-0.387	0.0039	0.0188	54
PROLIFERATION	original_glcmm_JointEntropy	-0.376	0.0050	0.0194	54
PROLIFERATION	original_gldm_LargeDependenceHighGrayLevelEmphasis	0.376	0.0051	0.0194	54
PROLIFERATION	original_glszm_GrayLevelVariance	-0.364	0.0068	0.0232	54
PROLIFERATION	original_firstorder_Variance	-0.346	0.0104	0.0320	54
PROLIFERATION	original_glcmm_ClusterProminence	-0.333	0.0137	0.0389	54
PROLIFERATION	original_gldm_DependenceEntropy	-0.319	0.0185	0.0485	54
TUMOR	original_gldm_SmallDependenceLowGrayLevelEmphasis	-0.450	6.32e-04	0.0141	54
TUMOR	original_gldm_LowGrayLevelEmphasis	-0.442	8.30e-04	0.0141	54
TUMOR	original_glszm_LargeAreaHighGrayLevelEmphasis	0.384	0.0042	0.0325	54
TUMOR	original_glszm_LowGrayLevelZoneEmphasis	-0.377	0.0050	0.0325	54
TUMOR	original_glcmm_JointEntropy	-0.376	0.0051	0.0325	54
TUMOR	original_gldm_LargeDependenceHighGrayLevelEmphasis	0.371	0.0057	0.0325	54
TUMOR	original_firstorder_Median	0.355	0.0084	0.0410	54
TUMOR	original_firstorder_Skewness	-0.346	0.0103	0.0437	54
TUMOR	original_firstorder_Variance	-0.336	0.0129	0.0486	54

CTinvivo_shape - CT in vivo - sole feature di shape

Pathway	Feature	rho	p_value	FDR	N
GLYCOLITIC-ACYD	original_shape_Maximum2D DiameterRow	0.445	7.45e-04	0.0044	54
GLYCOLITIC-ACYD	original_shape_MinorAxisLength	0.431	0.0012	0.0044	54
GLYCOLITIC-ACYD	original_shape_MeshVolume	0.423	0.0014	0.0044	54
GLYCOLITIC-ACYD	original_shape_VoxelVolume	0.423	0.0014	0.0044	54
GLYCOLITIC-ACYD	original_shape_SurfaceVolumeRatio	-0.420	0.0016	0.0044	54
GLYCOLITIC-ACYD	original_shape_Maximum2D DiameterColumn	0.405	0.0024	0.0052	54
GLYCOLITIC-ACYD	original_shape_SurfaceArea	0.399	0.0028	0.0052	54

Pathway	Feature	rho	p_value	FDR	N
GLYCOLITIC-ACYD	original_shape_MajorAxisLength	0.397	0.0030	0.0052	54
GLYCOLITIC-ACYD	original_shape_Maximum2D DiameterSlice	0.387	0.0038	0.0059	54
GLYCOLITIC-ACYD	original_shape_LeastAxisLength	0.381	0.0045	0.0059	54
GLYCOLITIC-ACYD	original_shape_Maximum3D Diameter	0.379	0.0047	0.0059	54
HYPERMUTATION	original_shape_SurfaceVolumeRatio	-0.425	0.0013	0.0121	54
HYPERMUTATION	original_shape_Maximum2D DiameterColumn	0.393	0.0033	0.0121	54
HYPERMUTATION	original_shape_MinorAxisLength	0.386	0.0039	0.0121	54
HYPERMUTATION	original_shape_MeshVolume	0.382	0.0043	0.0121	54
HYPERMUTATION	original_shape_VoxelVolume	0.382	0.0043	0.0121	54
HYPERMUTATION	original_shape_LeastAxisLength	0.373	0.0055	0.0128	54
HYPERMUTATION	original_shape_Maximum2D DiameterRow	0.343	0.0112	0.0197	54
HYPERMUTATION	original_shape_SurfaceArea	0.342	0.0113	0.0197	54
HYPERMUTATION	original_shape_MajorAxisLength	0.325	0.0164	0.0252	54
HYPERMUTATION	original_shape_Maximum2D DiameterSlice	0.321	0.0180	0.0252	54
HYPERMUTATION	original_shape_Maximum3D Diameter	0.313	0.0212	0.0269	54
MSI-predictor	original_shape_SurfaceVolumeRatio	-0.416	0.0017	0.0102	54
MSI-predictor	original_shape_Maximum2D DiameterColumn	0.401	0.0027	0.0102	54
MSI-predictor	original_shape_MinorAxisLength	0.390	0.0035	0.0102	54
MSI-predictor	original_shape_MeshVolume	0.387	0.0038	0.0102	54
MSI-predictor	original_shape_VoxelVolume	0.387	0.0038	0.0102	54
MSI-predictor	original_shape_LeastAxisLength	0.382	0.0044	0.0102	54
MSI-predictor	original_shape_SurfaceArea	0.352	0.0091	0.0159	54
MSI-predictor	original_shape_Maximum2D DiameterRow	0.348	0.0099	0.0159	54
MSI-predictor	original_shape_MajorAxisLength	0.347	0.0102	0.0159	54

Pathway	Feature	rho	p_value	FDR	N
MSI-predictor	original_shape_Maximum2D DiameterSlice	0.328	0.0156	0.0213	54
MSI-predictor	original_shape_Maximum3D Diameter	0.324	0.0167	0.0213	54
PROLIFERATION	original_shape_Maximum2D DiameterColumn	0.405	0.0024	0.0137	54
PROLIFERATION	original_shape_MinorAxisLength	0.387	0.0039	0.0137	54
PROLIFERATION	original_shape_MeshVolume	0.379	0.0047	0.0137	54
PROLIFERATION	original_shape_VoxelVolume	0.379	0.0047	0.0137	54
PROLIFERATION	original_shape_LeastAxisLength	0.375	0.0052	0.0137	54
PROLIFERATION	original_shape_SurfaceArea	0.370	0.0059	0.0137	54
PROLIFERATION	original_shape_MajorAxisLength	0.360	0.0075	0.0137	54
PROLIFERATION	original_shape_Maximum2D DiameterRow	0.355	0.0085	0.0137	54
PROLIFERATION	original_shape_Maximum3D Diameter	0.349	0.0096	0.0137	54
PROLIFERATION	original_shape_SurfaceVolumeRatio	-0.345	0.0105	0.0137	54
PROLIFERATION	original_shape_Maximum2D DiameterSlice	0.345	0.0107	0.0137	54
TUMOR	original_shape_SurfaceVolumeRatio	-0.402	0.0026	0.0205	54
TUMOR	original_shape_Maximum2D DiameterColumn	0.368	0.0061	0.0205	54
TUMOR	original_shape_MeshVolume	0.362	0.0072	0.0205	54
TUMOR	original_shape_VoxelVolume	0.362	0.0072	0.0205	54
TUMOR	original_shape_MinorAxisLength	0.361	0.0073	0.0205	54
TUMOR	original_shape_LeastAxisLength	0.338	0.0126	0.0275	54
TUMOR	original_shape_SurfaceArea	0.325	0.0166	0.0275	54
TUMOR	original_shape_Maximum2D DiameterSlice	0.324	0.0168	0.0275	54
TUMOR	original_shape_MajorAxisLength	0.322	0.0177	0.0275	54
TUMOR	original_shape_Maximum2D DiameterRow	0.308	0.0235	0.0310	54
TUMOR	original_shape_Maximum3D Diameter	0.306	0.0243	0.0310	54

Report ultima analisi: pathway TME

Notebook: analisi_Leo.ipynb

1. Sintesi esecutiva

Il notebook analizza l'associazione tra l'espressione genica normalizzata e feature radiomiche estratte da tre tipi di imaging: micro CT, CT ex vivo e CT in vivo. L'analisi è stata organizzata per pathway, con confronto gene-feature tramite correlazione di Spearman, correzione FDR Benjamini-Hochberg, selezione di feature non ridondanti (FRR) e PCA sui geni della pathway.

- Le pathway analizzate sono: STROMA, Endothelial cells, Hypoxia, TIS, T-cells, Myeloid, Myeloid inflammation, Inflammatory chemokines e Cytotoxicity.
- Le feature di shape sono state escluse dalle analisi di correlazione; sulle feature rimanenti sono stati eseguiti i test gene-feature.
- Dopo correzione FDR, quasi tutte le analisi Spearman non mostrano risultati significativi. L'unico risultato significativo compare nella pathway Cytotoxicity, dopo FRR, su CT ex vivo.
- Le PCA descrivono bene alcune pathway compatte (varianza rappresentata da PC1 molto alta), per esempio T-cells e Cytotoxicity, ma le correlazioni tra PC1 e feature radiomiche non risultano significative dopo FDR.
- I modelli di regressione e Random Forest sono esplorativi e limitati alla pathway STROMA; nessun modello viene classificato come robusto/presentabile perché la validazione incrociata ha R2 medio negativo.

Risultato significativo corretto per FDR

Pathway	Analisi	Imaging	Gene	Feature	rho	p	FDR	n
Cytotoxicity	Feature non ridondanti (FRR)	CT ex vivo	GZMA	original_ngtdm_Strength	-0.513	1.39e-04	0.0319	50

Questo risultato è significativo per $FDR < 0,05$ ed è l'unico risultato Spearman significativo emerso tra le analisi gene-feature. La direzione negativa indica che, nel campione analizzato, valori più elevati di GZMA sono associati a valori più bassi della feature radiomica original_ngtdm_Strength nella CT ex vivo, dopo riduzione alle feature non ridondanti.




Figura 1. Conteggio dei risultati Spearman significativi per pathway. La pathway Cytotoxicity contiene l'unico risultato significativo dopo correzione FDR.

2. Obiettivo e struttura del notebook

L'obiettivo del notebook è costruire una prima analisi radiogenomica orientata a specifiche classi/pathway, confrontando i profili di espressione genica con le feature radiomiche disponibili. Il notebook parte da un'introduzione metodologica alla regressione lineare e poi implementa un flusso ripetuto per pathway.

3. Dati utilizzati e pre-processing

- Dati genici: foglio Google geni_normalizzati_R_pathway, con un foglio separato per ciascuna pathway.
- Dati radiomici micro CT: radiomics_microCT.csv.
- Dati radiomici CT ex vivo: out_CTconv_FIXED.csv.
- Dati radiomici CT in vivo: out_CTinvivo_roiOrig.csv.
- Gli ID dei pazienti vengono estratti numericamente dai nomi delle colonne/campi, convertiti in interi e usati per allineare dati genici e radiomici.
- Le feature radiomiche che iniziano con original_shape vengono escluse; restano 93 feature radiomiche non-shape nelle analisi complete.
- Le analisi FRR usano liste di feature non ridondanti già definite nel codice: 28 per micro CT, 46 per CT ex vivo e 34 per CT in vivo.
- La significatività statistica è valutata con FDR Benjamini-Hochberg. Il criterio principale usato nel notebook è $FDR < 0,05$; per le correlazioni Spearman viene inoltre controllata l'intensità della correlazione tramite soglie su $|\rho|$.

4. Pathway analizzate

Pathway	Geni	Test per imaging (93 feature)	Test FRR micro/ex vivo/in vivo	Significativi Spearman	PC1 %
STROMA	6	558	276/204/168	0	65.2
Endothelial cells	11	1023	506/374/308	0	58.1
Hypoxia	10	930	460/340/280	0	28.2
TIS	18	1674	828/612/504	0	35.7
T-cells	5	465	230/170/140	0	73.9
Myeloid	42	3906	1932/1428/1176	0	21.4
Myeloid inflammation	10	930	460/340/280	0	39.9
Inflammatory chemokines	5	465	230/170/140	0	50.6
Cytotoxicity	5	465	230/170/140	1	70.1

Il numero di test nelle analisi complete è pari al numero di geni x 93 feature non-shape. Nelle analisi FRR il numero di test cambia in funzione del numero di feature non ridondanti selezionate per ciascun imaging.

5. Correlazioni Spearman gene-feature

Per ogni pathway sono state calcolate correlazioni Spearman tra ogni gene e ogni feature radiomica, separatamente per micro CT, CT ex vivo e CT in vivo. La stessa analisi è stata ripetuta dopo selezione delle feature non ridondanti (FRR).

5.2 STROMA

La pathway STROMA comprende 6 geni. Sono state eseguite analisi sulle 93 feature non-shape e sulle feature non ridondanti FRR per le tre modalità di imaging.

Analisi	Imaging	Test	Sig.	Migliore trend riportato	rho	p	FDR
Tutte le feature	micro CT	558	0	LRRC32 -> original_firstorder_Skewness	0.457	3.97e-04	0.2212
Tutte le feature	CT ex vivo	558	0	PDGFRB -> original_glszm_SmallAreaLowGrayLevelEmphasis	-0.442	0.0013	0.4529
Tutte le feature	CT in vivo	558	0	ADAM12 -> original_glrlm_ShortRunLowGrayLevelEmphasis	-0.398	0.0029	0.1116
Feature non ridondanti (FRR)	micro CT	168	0	LRRC32 -> original_glcmm_ClustersShade	0.394	0.0027	0.4474
Feature non ridondanti (FRR)	CT ex vivo	276	0	PDGFRB -> original_glszm_SmallAreaLowGrayLevelEmphasis	-0.442	0.0013	0.2240
Feature non ridondanti (FRR)	CT in vivo	204	0	ADAM12 -> original_gldm_LargeDependenceHighGrayLevelEmphasis	0.427	0.0013	0.0837

Per STROMA non emergono associazioni Spearman significative dopo correzione FDR. I valori con p non corretto basso restano trend esplorativi e non vanno considerati risultati definitivi.

5.3 Endothelial cells

La pathway Endothelial cells comprende 11 geni. Sono state eseguite analisi sulle 93 feature non-shape e sulle feature non ridondanti FRR per le tre modalità di imaging.

Analisi	Imaging	Test	Sig.	Migliore trend riportato	rho	p	FDR
Tutte le feature	micro CT	1023	0	BCL6B -> original_glrlm_LongRunEmphasis	-0.363	0.0060	0.4653
Tutte le feature	CT ex vivo	1023	0	MYCT1 -> original_firstorder_TotalEnergy	-0.460	7.70e-04	0.3937
Tutte le feature	CT in vivo	1023	0	BCL6B -> original_glrlm_GrayLevelVariance	0.408	0.0022	0.1917
Feature non ridondanti (FRR)	micro CT	308	0	MYCT1 -> original_glcmm_ClustersShade	0.408	0.0018	0.5592
Feature non ridondanti (FRR)	CT ex vivo	506	0	MYCT1 -> original_firstorder_Energy	-0.460	7.70e-04	0.3895
Feature non ridondanti (FRR)	CT in vivo	374	0	CDH5 -> original_glcmm_ClustersProminence	0.461	4.53e-04	0.1113

Per Endothelial cells non emergono associazioni Spearman significative dopo correzione FDR.

5.4 Hypoxia

La pathway Hypoxia comprende 10 geni. Sono state eseguite analisi sulle 93 feature non-shape e sulle feature non ridondanti FRR per le tre modalità di imaging.

Analisi	Imaging	Test	Sig.	Migliore trend riportato	rho	p	FDR
Tutte le feature	micro CT	930	0	P4HA2 -> original_gldm_LowGrayLevelEmphasis	0.319	0.0167	0.4060
Tutte le feature	CT ex vivo	930	0	P4HA2 -> original_gldm_DependenceNonUniformityNormalized	0.502	2.00e-04	0.1864
Tutte le feature	CT in vivo	930	0	ALDOC -> original_glszm_GrayLevelNonUniformity	0.508	8.80e-05	0.0822

Analisi	Imaging	Test	Sig.	Migliore trend riportato	rho	p	FDR
Feature non ridondanti (FRR)	micro CT	280	0	ALDOC -> original_glszm_LargeAreaHighGrayLevelEmphasis	0.425	0.0011	0.3085
Feature non ridondanti (FRR)	CT ex vivo	460	0	P4HA2 -> original_gldm_DependenceNonUniformityNormalized	0.502	2.00e-04	0.0922
Feature non ridondanti (FRR)	CT in vivo	340	0	ALDOC -> original_glszm_SizeZoneNonUniformity	0.411	0.0020	0.1192

Per Hypoxia non emergono associazioni Spearman significative dopo correzione FDR.

5.5 TIS

La pathway TIS comprende 18 geni. Sono state eseguite analisi sulle 93 feature non-shape e sulle feature non ridondanti FRR per le tre modalità di imaging.

Analisi	Imaging	Test	Sig.	Migliore trend riportato	rho	p	FDR
Tutte le feature	micro CT	1674	0	LAG3 -> original_firstorder_Kurtosis	-0.440	6.99e-04	0.9994
Tutte le feature	CT ex vivo	1674	0	STAT1 -> original_gldm_DependenceNonUniformity	0.491	2.97e-04	0.3329
Tutte le feature	CT in vivo	1674	0	HLA-E -> original_gldm_ClusterProminence	0.416	0.0018	0.2560
Feature non ridondanti (FRR)	micro CT	504	0	LAG3 -> original_firstorder_Kurtosis	-0.440	6.99e-04	0.3524
Feature non ridondanti (FRR)	CT ex vivo	828	0	STAT1 -> original_gldm_DependenceNonUniformity	0.491	2.97e-04	0.1646
Feature non ridondanti (FRR)	CT in vivo	612	0	HLA-E -> original_gldm_ClusterProminence	0.416	0.0018	0.2941

Per TIS non emergono associazioni Spearman significative dopo correzione FDR.

5.6 T-cells

La pathway T-cells comprende 5 geni. Sono state eseguite analisi sulle 93 feature non-shape e sulle feature non ridondanti FRR per le tre modalità di imaging.

Analisi	Imaging	Test	Sig.	Migliore trend riportato	rho	p	FDR
Tutte le feature	micro CT	465	0	CD6 -> original_gldm_LargeDependenceEmphasis	-0.257	0.0554	0.6105
Tutte le feature	CT ex vivo	465	0	CD6 -> original_glszm_LargeAreaLowGrayLevelEmphasis	0.394	0.0047	0.3110
Tutte le feature	CT in vivo	465	0	TRAT1 -> original_ngtdm_Busyness	-0.159	0.2503	0.9993
Feature non ridondanti (FRR)	micro CT	140	0	CD3G -> original_firstorder_InterquartileRange	0.368	0.0053	0.7428
Feature non ridondanti (FRR)	CT ex vivo	230	0	CD3D -> original_ngtdm_Strength	-0.392	0.0049	0.3468
Feature non ridondanti (FRR)	CT in vivo	170	0	CD3D -> original_firstorder_Energy	-0.206	0.1343	0.9993

Per T-cells non emergono associazioni Spearman significative dopo correzione FDR.

5.7 Myeloid

La pathway Myeloid comprende 42 geni. Sono state eseguite analisi sulle 93 feature non-shape e sulle feature non ridondanti FRR per le tre modalità di imaging.

Analisi	Imaging	Test	Sig.	Migliore trend riportato	rho	p	FDR
Tutte le feature	micro CT	3906	0	TLR8 -> original_glcmm_Correlation	0.450	5.07e-04	0.3723
Tutte le feature	CT ex vivo	3906	0	P2RY13 -> original_glszm_SizeZoneNonUniformity	0.398	0.0042	0.4241
Tutte le feature	CT in vivo	3906	0	P2RY13 -> original_glrmm_GrayLevelNonUniformityNormalized	-0.301	0.0268	0.9641
Feature non ridondanti (FRR)	micro CT	1176	0	SERPINA1 -> original_glcmm_ClusterProminence	0.469	2.64e-04	0.2055
Feature non ridondanti (FRR)	CT ex vivo	1932	0	ITGAM -> original_glszm_SmallAreaHighGrayLevelEmphasis	0.434	0.0017	0.5489
Feature non ridondanti (FRR)	CT in vivo	1428	0	CSF1R -> original_glszm_ZoneEntropy	-0.310	0.0223	0.9208

Per Myeloid non emergono associazioni Spearman significative dopo correzione FDR.

5.8 Myeloid inflammation

La pathway Myeloid inflammation comprende 10 geni. Sono state eseguite analisi sulle 93 feature non-shape e sulle feature non ridondanti FRR per le tre modalità di imaging.

Analisi	Imaging	Test	Sig.	Migliore trend riportato	rho	p	FDR
Tutte le feature	micro CT	930	0	IL6 -> original_firstorder_Skewness	0.418	0.0013	0.8782
Tutte le feature	CT ex vivo	930	0	FOSL1 -> original_glszm_SmallAreaLowGrayLevelEmphasis	-0.421	0.0023	0.8254
Tutte le feature	CT in vivo	930	0	IER3 -> original_gldm_DependenceVariance	0.432	0.0011	0.5146
Feature non ridondanti (FRR)	micro CT	280	0	CCL20 -> original_gldm_LargeDependenceHighGrayLevelEmphasis	0.406	0.0019	0.5288
Feature non ridondanti (FRR)	CT ex vivo	460	0	FOSL1 -> original_glszm_SmallAreaLowGrayLevelEmphasis	-0.421	0.0023	0.6492
Feature non ridondanti (FRR)	CT in vivo	340	0	IER3 -> original_gldm_LargeDependenceHighGrayLevelEmphasis	0.381	0.0044	0.6020

Per Myeloid inflammation non emergono associazioni Spearman significative dopo correzione FDR.

5.9 Inflammatory chemokines

La pathway Inflammatory chemokines comprende 5 geni. Sono state eseguite analisi sulle 93 feature non-shape e sulle feature non ridondanti FRR per le tre modalità di imaging.

Analisi	Imaging	Test	Sig.	Migliore trend riportato	rho	p	FDR
Tutte le feature	micro CT	465	0	CCL7 -> original_firstorder_TotalEnergy	0.175	0.1978	0.9506
Tutte le feature	CT ex vivo	465	0	CCL8 -> original_ngtdm_Complexity	-0.212	0.1391	0.9995
Tutte le feature	CT in vivo	465	0	CCL2 -> original_glrml_GrayLevelNonUniformity	-0.279	0.0411	0.7046
Feature non ridondanti (FRR)	micro CT	140	0	CCL2 -> original_firstorder_Energy	-0.132	0.3330	0.9567
Feature non ridondanti (FRR)	CT ex vivo	230	0	CCL2 -> original_firstorder_Kurtosis	-0.109	0.4513	0.9916
Feature non ridondanti (FRR)	CT in vivo	170	0	CCL7 -> original_glszm_ZoneEntropy	-0.389	0.0037	0.6245

Per Inflammatory chemokines non emergono associazioni Spearman significative dopo correzione FDR.

5.10 Cytotoxicity

La pathway Cytotoxicity comprende 5 geni. Sono state eseguite analisi sulle 93 feature non-shape e sulle feature non ridondanti FRR per le tre modalità di imaging.

Analisi	Imaging	Test	Sig.	Migliore trend riportato	rho	p	FDR
Tutte le feature	micro CT	465	0	GZMB -> original_ngtdm_Strength	-0.323	0.0153	0.7412
Tutte le feature	CT ex vivo	465	0	GZMA -> original_ngtdm_Strength	-0.513	1.39e-04	0.0646
Tutte le feature	CT in vivo	465	0	PRF1 -> original_ngtdm_Busyness	-0.221	0.1086	0.9969
Feature non ridondanti (FRR)	micro CT	140	0	GZMA -> original_firstorder_InterquartileRange	0.353	0.0077	0.4691
Feature non ridondanti (FRR)	CT ex vivo	230	1	GZMA -> original_ngtdm_Strength	-0.513	1.39e-04	0.0319
Feature non ridondanti (FRR)	CT in vivo	170	0	GNLY -> original_firstorder_Energy	0.156	0.2593	0.9937

In questa pathway compare l'unico risultato significativo: dopo FRR su CT ex vivo, GZMA e original_ngtdm_Strength mostrano una correlazione negativa significativa dopo FDR (rho = -0,513; p = 0,000139; FDR = 0,0319; n = 50). Le altre associazioni della stessa pathway non superano la soglia FDR < 0,05.

6. PCA sui geni delle pathway

Per ogni pathway il notebook standardizza la matrice genica e calcola la prima componente principale (PC1). La PC1 sintetizza il segnale congiunto dei geni della pathway; successivamente viene correlata con le feature radiomiche **micro CT**, con le feature FRR e, in una variante, con rimozione degli outlier radiomici.




Figura 4. Percentuale di varianza genica spiegata dalla PC1 per ciascuna pathway.

Pathway	PC1 varianza spiegata	Test PCA totali riportati	Risultati PCA significativi	Interpretazione
T-cells	73.9%	214	0	PC1 molto rappresentativa
Cytotoxicity	70.1%	214	0	PC1 molto rappresentativa
STROMA	65.2%	307	0	PC1 molto rappresentativa
Endothelial cells	58.1%	214	0	PC1 moderatamente rappresentativa
Inflammatory chemokines	50.6%	214	0	PC1 moderatamente rappresentativa
Myeloid inflammation	39.9%	214	0	Segnale distribuito su più componenti
TIS	35.7%	214	0	Segnale distribuito su più componenti
Hypoxia	28.2%	214	0	Segnale distribuito su più componenti
Myeloid	21.4%	214	0	Segnale distribuito su più componenti

La PC1 spiega una quota elevata di varianza in T-cells, Cytotoxicity e STROMA, suggerendo che in queste pathway i geni tendono a muoversi in modo più coordinato. Tuttavia, nessuna delle correlazioni PC1-feature raggiunge la significatività FDR nel notebook, quindi la PCA non produce marker radiomici confermati.

7. Gestione degli outlier radiomici

In alcune analisi PCA e nelle regressioni per STROMA il notebook rimuove outlier sulle feature radiomiche usando limiti basati sull'intervallo interquartile: $Q1 - 3 \cdot IQR$ e $Q3 + 3 \cdot IQR$. Nel caso STROMA con rimozione globale degli outlier micro CT vengono eliminati 24 pazienti e il dataset passa da 56 a 32 pazienti comuni.

- La rimozione globale elimina il paziente se è outlier in almeno una feature radiomica.
- La rimozione feature-specifica ricalcola gli outlier separatamente per ciascuna feature prima della correlazione.
- Questa strategia aumenta la pulizia dei dati ma riduce il numero di campioni, con impatto sulla stabilità statistica e sui modelli multivariati.

8. Regressione lineare multipla e Machine Learning

Ambito dei modelli ML nel notebook

Questa sezione riguarda esclusivamente STROMA. Non sono state fatte le stesse analisi ML per Endothelial cells, Hypoxia, TIS, T-cells, Myeloid, Myeloid inflammation, Inflammatory chemokines o Cytotoxicity. Tali modelli verranno applicati.

La parte multivariata prova a predire ciascuna feature radiomica micro CT a partire dai geni di STROMA. Vengono eseguiti modelli di regressione lineare multipla, controlli di multicollinearità tramite VIF, test sui residui, p-value robusti, correzione FDR sui modelli e validazione incrociata K-fold. La qualità finale dei modelli è valutata soprattutto tramite CV_R2_mean: valori negativi indicano che il modello generalizza peggio di una previsione banale basata sulla media.

Strategia	Top feature per FDR	R2	Adj R2	p modello	FDR	CV R2 medio	Modelli FDR<0,05	Modelli presentabili	Qualità
Regressione STROMA senza rimozione outlier	original_glmcointEnergy	0.378	0.302	4.87e-04	0.0135	-6.635	11	0	Non validato: CV_R2 negativo
Regressione STROMA con rimozione outlier radiomici	original_firstorder_10Percentile	0.661	0.579	6.30e-05	0.0058	-0.475	4	0	Non validato: CV_R2 negativo
Regressione STROMA con outlier rimossi e geni collineari rimossi	original_firstorder_Skewness	0.442	0.383	8.43e-04	0.0784	-3.644	0	0	Non significativo

La regressione senza outlier trova diversi modelli con FDR < 0,05, ma tutti sono marcati come non validati per CV_R2 medio negativo. Dopo rimozione globale degli outlier, quattro feature first-order risultano significative per FDR, ma anche in questo caso la validazione resta negativa. Dopo ulteriore rimozione dei geni collineari non rimangono modelli significativi. In sintesi, la parte regressiva evidenzia segnali statistici interni al campione, ma non produce un modello robusto generalizzabile.

Nel modello STROMA con rimozione dei geni collineari, il notebook rimuove i geni altamente correlati tra loro e mantiene un set ridotto di predittori.

- Geni rimossi: ['OLFML2B', 'FAP', 'COL6A3'].
- Geni mantenuti: ['ADAM12', 'LRRC32', 'PDGFRB'].
- Dopo questa riduzione il VIF scende a valori prossimi a 1-1,5, ma i modelli non risultano più significativi dopo FDR.

8.1 Figure diagnostiche dei modelli STROMA




Figura 5. Modello STROMA senza rimozione outlier: confronto tra valori osservati e predetti. La dispersione dei punti e la presenza di un osservato estremo confermano che il modello non è stabile, coerentemente con il CV_R2 negativo.




Figura 6. Modello STROMA dopo rimozione outlier: residui rispetto ai valori predetti. I residui sono centrati attorno a zero, ma la sola diagnosi grafica non è sufficiente a rendere il modello presentabile, perché la validazione incrociata rimane negativa.




Figura 7. Modello STROMA dopo rimozione outlier: valori osservati vs predetti. Il grafico mostra una relazione visiva più ordinata rispetto al modello senza outlier, ma i risultati rimangono non validati per CV_R2 medio negativo.

9. Interpretazione complessiva dei risultati

- Nelle analisi complete gene-feature, anche quando alcuni p-value non corretti sono bassi, la correzione multipla rende i risultati non significativi. Questo è atteso dato l'elevato numero di confronti.
- La riduzione FRR abbassa il numero di test e rende più favorevole la correzione multipla; infatti l'unico risultato significativo emerge proprio in questa fase.
- La PCA mostra che alcune pathway hanno un asse genico dominante, ma tale asse non si traduce in associazioni radiomiche FDR-significative nelle analisi riportate.
- Le regressioni su STROMA trovano modelli statisticamente interessanti nel training set, soprattutto per feature first-order dopo rimozione outlier, ma la validazione incrociata negativa impedisce di considerarli robusti.
- Il Random Forest su STROMA produce performance molto deboli: questo suggerisce cautela e necessita di campioni maggiori, tuning e validazione indipendente.